

## **Εφαρμογές Μηχανικής Μάθησης για κατανόηση εργασιακών τάσεων και διακράτηση προσωπικού**

Programme Name: MSc Artificial Intelligence  
Student ID Number: 100-24438  
Lecturer's Name: Mr. Ioannis Gialamas  
**Word Count:** (20.235)

## Περίληψη

Η παρούσα διπλωματική εργασία διερευνά το πολυδιάστατο φαινόμενο της εθελούσιας αποχώρησης των εργαζομένων (employee turnover) στο σύγχρονο επιχειρηματικό περιβάλλον, συνδυάζοντας τη θεωρητική ανάλυση των νέων εργασιακών τάσεων με την πρακτική εφαρμογή της Μηχανικής Μάθησης. Η έρευνα διαρθρώνεται σε δύο σκέλη: την ανάλυση της ελληνικής πραγματικότητας μέσω πρωτογενούς έρευνας και την ανάπτυξη προγνωστικών μοντέλων μέσω δευτερογενών δεδομένων.

Στο πρώτο σκέλος, η συλλογή δεδομένων από 120 Έλληνες υπαλλήλους γραφείου (white-collar workers) αποκάλυψε ένα εργατικό δυναμικό με υψηλά επίπεδα συναισθηματικής εξάντλησης και μια έντονη, ανικανοποίητη ανάγκη για ευέλικτα μοντέλα εργασίας, με το υβριδικό μοντέλο να προκρίνεται ως το ιδανικό. Παρά τη θετική στάση των εργαζομένων απέναντι σε τάσεις όπως το Job Hopping και το Quiet Quitting, η εφαρμογή τους στην πράξη συχνά αναχαιτίζεται από την ανάγκη για εργασιακή ασφάλεια ή από αισθήματα «οικονομικού εγκλωβισμού».

Στο δεύτερο σκέλος, εφαρμόστηκαν αλγόριθμοι Μηχανικής Μάθησης (όπως SVM, Logistic Regression, Random Forest και XGBoost) στο αναγνωρισμένο σύνολο δεδομένων "IBM HR Analytics". Τα αποτελέσματα έδειξαν ότι οι αλγόριθμοι SVM και Logistic Regression (με τη χρήση της τεχνικής SMOTE για την εξισορρόπηση των δεδομένων) παρουσιάζουν την υψηλότερη προγνωστική ικανότητα. Οι κρίσιμότεροι παράγοντες ώθησης προς την αποχώρηση αναδείχθηκαν οι υπερωρίες, τα συχνά επαγγελματικά ταξίδια και το χαμηλό ιεραρχικό επίπεδο.

Η μελέτη καταλήγει σε στρατηγικές προτάσεις για τη Διοίκηση Ανθρώπινου Δυναμικού, τονίζοντας την ανάγκη για μετάβαση σε μια ανθρωποκεντρική, data-driven κουλτούρα που προάγει την ισορροπία επαγγελματικής και προσωπικής ζωής (work-life balance) και την έμπρακτη υποστήριξη της ευεξίας των εργαζομένων ως βασικούς πυλώνες διακράτησης ταλέντων.

## Abstract

The following thesis explores the multidimensional phenomenon of voluntary employee turnover in the modern business environment by combining a theoretical analysis of contemporary labor trends with the practical application of Machine Learning. The research is structured into two main parts: the analysis of the Greek labor market through primary research and the development of predictive models using secondary data.

In the first part, data collected from 120 Greek white-collar workers revealed a workforce experiencing high levels of emotional exhaustion and a strong, unmet need for flexible work arrangements, with the hybrid model identified as the ideal preference. Despite positive attitudes toward emerging trends such as Job Hopping and Quiet Quitting, their actual implementation is often hindered by the need for job security or feelings of "financial entrapment".

In the second part, various Machine Learning algorithms (including SVM, Logistic Regression, Random Forest, and XGBoost) were applied to the "IBM HR Analytics" dataset. The results showed that SVM and Logistic Regression (using the SMOTE technique for data balancing) exhibit the highest predictive performance. The most critical factors driving turnover were identified as overtime, frequent business travel, and low hierarchical levels.

The study concludes with strategic recommendations for Human Resource Management, emphasizing the need to transition toward a human-centric, data-driven culture. Such a culture should prioritize work-life balance and actively support employee well-being as fundamental pillars for talent retention and organizational competitiveness.

# ΠΕΡΙΕΧΟΜΕΝΑ

|                                                                                               |           |
|-----------------------------------------------------------------------------------------------|-----------|
| Περίληψη.....                                                                                 | 2         |
| Abstract .....                                                                                | 3         |
| <b>1. Εισαγωγή .....</b>                                                                      | <b>6</b>  |
| 1.1 Πλαίσιο της έρευνας .....                                                                 | 6         |
| 1.2 Ορισμός του προβλήματος.....                                                              | 7         |
| 1.3 Ερευνητικά ερωτήματα και προκλήσεις .....                                                 | 7         |
| 1.4 Σκοπός και στόχοι .....                                                                   | 8         |
| <b>2. Θεωρητικό Υπόβαθρο &amp; Βιβλιογραφική Ανασκόπηση .....</b>                             | <b>9</b>  |
| 2.1 Εννοιολογική προσέγγιση του Turnover .....                                                | 9         |
| 2.1.1 Οικειοθελής αποχώρηση .....                                                             | 9         |
| 2.1.2 Αναγκαστική αποχώρηση .....                                                             | 9         |
| 2.2 Θεωρίες οργανωσιακής συμπεριφοράς .....                                                   | 10        |
| 2.2.1 Θεωρία της ώθησης και της έλξης .....                                                   | 10        |
| 2.2.2 Εταιρική δέσμευση και ικανοποίηση από την εργασία .....                                 | 10        |
| 2.3 Τάσεις των τελευταίων χρόνων που επηρεάζουν σημαντικά το turnover .....                   | 11        |
| 2.3.1 Job Hopping .....                                                                       | 11        |
| 2.3.2 Quiet Quitting .....                                                                    | 12        |
| 2.3.3 Εργασιακή ευεξία & Work-Life Balance .....                                              | 12        |
| 2.4 People Analytics.....                                                                     | 13        |
| 2.4.1 Ορισμός και εξέλιξη.....                                                                | 13        |
| 2.4.2 Η σημασία της Προγνωστικής ανάλυσης στο Turnover.....                                   | 14        |
| 2.4.3 Σύγχρονες τεχνικές και Μηχανική Μάθηση .....                                            | 14        |
| <b>3. Ερευνητική Μεθοδολογία.....</b>                                                         | <b>14</b> |
| 3.1 Σχεδιασμός πρωτογενούς έρευνας .....                                                      | 14        |
| 3.1.1 Περιγραφή του ερωτηματολογίου .....                                                     | 14        |
| 3.1.2 Δειγματοληψία και χαρακτηριστικά δείγματος .....                                        | 15        |
| 3.1.3 Στατιστική ανάλυση αποτελεσμάτων ερωτηματολογίου με Python .....                        | 16        |
| 3.2 Χρήση πρακτικών Μηχανικής Μάθησης για πρόβλεψη προθέσεων εγκατάλειψης .....               | 16        |
| 3.3 Εργαλεία και εφαρμογές που χρησιμοποιήθηκαν κατά την διαδικασία.....                      | 17        |
| 3.3.1 Συλλογή, χαρτογράφηση και αξιολόγηση πηγών .....                                        | 17        |
| 3.3.2 Συγγραφή, ακαδημαϊκή παράφραση και τεχνική επεξεργασία .....                            | 18        |
| <b>4. Ανάλυση πρωτογενών δεδομένων και κατανόηση ελληνικών τάσεων .....</b>                   | <b>18</b> |
| 4.1 Προφίλ δείγματος.....                                                                     | 18        |
| 4.1.1 Περιγραφή περιεχομένων ερωτηματολογίου.....                                             | 19        |
| 4.1.2 Περιγραφή συλλεχθέντων δεδομένων και προεπεξεργασία .....                               | 20        |
| 4.2 Μονομετάβλητη ερευνητική ανάλυση δεδομένων – EDA .....                                    | 23        |
| 4.2.1 Δημογραφικά στοιχεία και χαρακτηριστικά απασχόλησης .....                               | 24        |
| 4.2.2 Απόψεις/συμπεριφορές σχετικά με την τάση Job Hopping .....                              | 25        |
| 4.2.3 Απόψεις/συμπεριφορές σχετικά με την τάση Quiet Quitting .....                           | 27        |
| 4.2.4 Απόψεις/συμπεριφορές σχετικά με την τάση για ευεξία .....                               | 29        |
| 4.3 Διμετάβλητη ανάλυση δεδομένων – πίνακας συσχετίσεων και ομαδοποιημένα ραβδογράμματα ..... | 32        |
| 4.3.1 Πίνακας συσχετίσεων Spearman για τις Likert μεταβλητές.....                             | 33        |
| 4.3.2 Cramer’s V για κατηγορικές συσχετίσεις .....                                            | 34        |

|                                                                                      |            |
|--------------------------------------------------------------------------------------|------------|
| 4.3.3 Ομαδοποιημένα ραβδογράμματα (Grouped Bar Charts) .....                         | 38         |
| <b>4.4 Ομαδοποίηση εργαζομένων με πρακτικές Μηχανικής Μάθησης – Clustering .....</b> | <b>47</b>  |
| 4.4.1 Εύρεση βέλτιστου αριθμού συστάδων K μέσω Elbow Method & Silhouette Score.....  | 48         |
| 4.4.2 Εφαρμογή αλγορίθμου K-Prototypes και ανάλυση αποτελεσμάτων .....               | 51         |
| <b>5. Ανάλυση δευτερογενών δεδομένων &amp; Μοντελοποίηση (EDA &amp; ML) .....</b>    | <b>54</b>  |
| 5.1 Προεπεξεργασία δεδομένων.....                                                    | 54         |
| 5.2 Ερευνητική ανάλυση δεδομένων – EDA.....                                          | 56         |
| 5.2.1 Περιγραφική Στατιστική και Μονομετάβλητη ανάλυση κατανομών .....               | 56         |
| 5.2.2 Ανάλυση και Διαχείριση Ακραίων Τιμών .....                                     | 61         |
| 5.2.3 Διμετάβλητη ανάλυση στην εξαρτημένη μεταβλητή Attrition .....                  | 64         |
| 5.2.4 Ανάλυση Γραμμικών Συσχετίσεων (Correlation Matrix / Heatmap).....              | 68         |
| 5.3 Feature Engineering .....                                                        | 70         |
| 5.3.1 Κωδικοποίηση Κατηγορικών Μεταβλητών (One-Hot Encoding) .....                   | 70         |
| 5.3.2 Κανονικοποίηση αριθμητικών χαρακτηριστικών (Feature Scaling).....              | 71         |
| 5.4 Ανάπτυξη προγνωστικών μοντέλων .....                                             | 72         |
| 5.4.1 Feature engineering προ εκπαίδευσης .....                                      | 72         |
| 5.4.2 Διαδικασία εκπαίδευσης/δοκιμής μοντέλων και μετρικές αξιολόγησης .....         | 73         |
| 5.4.3 Μοντέλα που εκπαιδεύτηκαν .....                                                | 76         |
| 5.4.4 Τεχνική Παραγωγής Συνθετικών Δεδομένων SMOTE .....                             | 78         |
| 5.5 Αξιολόγηση μοντέλων.....                                                         | 78         |
| 5.5.1 Ανάλυση επιδόσεων βασικών μοντέλων .....                                       | 78         |
| 5.5.2 Επιπτώσεις της τεχνικής SMOTE και Συγκριτική αξιολόγηση .....                  | 80         |
| 5.5.3 Επιχειρησιακά συμπεράσματα επιλογής μοντέλου και ερμηνευσιμότητα.....          | 80         |
| 5.5.4 Περαιτέρω βελτιστοποίηση μοντέλων για μελλοντική ακρίβεια .....                | 81         |
| <b>6. Συμπεράσματα &amp; Προτάσεις .....</b>                                         | <b>83</b>  |
| 6.1 Σύνοψη ευρημάτων πρώτου σκέλους – Ερωτηματολογίου .....                          | 83         |
| 6.2 Σύνοψη ευρημάτων δεύτερου σκέλους – Ενδοεταιρικών δεδομένων .....                | 84         |
| 6.3 Συλλογική αξιολόγηση και στρατηγικές προτάσεις έλξης και διακράτησης .....       | 84         |
| 6.4 Προτάσεις για μελλοντική έρευνα.....                                             | 85         |
| <b>Βιβλιογραφία.....</b>                                                             | <b>87</b>  |
| <b>Παράρτημα Ι – Γλωσσάριο .....</b>                                                 | <b>89</b>  |
| <b>Παράρτημα ΙΙ – Ερωτηματολόγιο και Κώδικας .....</b>                               | <b>93</b>  |
| <b>Παράρτημα ΙΙΙ – Εικόνες .....</b>                                                 | <b>104</b> |

# 1. Εισαγωγή

## 1.1 Πλαίσιο της έρευνας

Στο σύγχρονο, έντονα ανταγωνιστικό επιχειρηματικό περιβάλλον, η διατήρηση του προσωπικού αποτελεί μία από τις σημαντικότερες προκλήσεις για τη βιωσιμότητα των οργανισμών. Η κοινωνία αδιαμφισβήτητα αλλάζει συνεχώς και ραγδαία. Μετά την πανδημία του Covid-19, πολλοί άνθρωποι άρχισαν να δουλεύουν εξ' αποστάσεως ή υβριδικά, φέρνοντας στο επίκεντρο της προσοχής τους την ανάγκη για ψυχοσωματική ευεξία. Κάτι τέτοιο κάνει τους εργαζόμενους να έχουν διαφορετικές προτεραιότητες και, κατ' επέκταση, διαφορετικούς/επιπρόσθετους λόγους για να εγκαταλείψουν την τρέχουσα θέση τους. Συνεπώς, υπάρχουν πλέον καινούριες αιτίες για κάποιον εργαζόμενο να αλλάξει εργοδότη.

Έρευνες δείχνουν πως το 53% των εργαζομένων δηλώνουν ότι είναι πλέον πιο πιθανό να θέσουν την υγεία και την ευεξία τους πάνω από την εργασία σε σχέση με την προ-πανδημίας εποχή. (Great Expectations: Making Hybrid Work Work, 2022). Οι ίδιες έρευνες δείξαν πως το 47% των ερωτηθέντων απάντησε ότι είναι πιο πιθανό να δώσει προτεραιότητα στην προσωπική και οικογενειακή ζωή έναντι της καριέρας (Great Expectations: Making Hybrid Work Work, 2022).

Επιπροσθέτως, το φαινόμενο της συχνής εναλλαγής εργοδοτών, γνωστό ως job-hopping, είναι πλέον συχνή πρακτική στην αγορά εργασίας, καθώς οι εργαζόμενοι αναζητούν διαρκώς βελτιωμένες απολαβές και συνθήκες εργασίας (Park, 2024).

Η εθελούσια αποχώρηση των εργαζομένων (voluntary turnover) προκαλεί αλυσιδωτές αντιδράσεις στους οργανισμούς. Σε βραχυπρόθεσμο επίπεδο, το κόστος είναι άμεσα οικονομικό, περιλαμβάνοντας δαπάνες για τη διαδικασία προσέλκυσης, επιλογής, πρόσληψης και εκπαίδευσης νέου προσωπικού. Ωστόσο, οι μακροπρόθεσμες συνέπειες είναι συχνά πιο επιβλαβείς, καθώς η αποχώρηση έμπειρων στελεχών οδηγεί σε απώλεια γνώσης στις εταιρείες και αυξημένο φόρτο εργασίας για το προσωπικό που απομένει. Η κατάσταση αυτή δημιουργεί έναν φαύλο κύκλο επαγγελματικής εξουθένωσης (burnout) και μειωμένης ικανοποίησης, γεγονός που μπορεί να πυροδοτήσει περαιτέρω κύματα παραιτήσεων (Hom, Allen, & Griffith, 2019).

Στο πλαίσιο αυτό, η παρούσα διπλωματική εργασία επικεντρώνεται στην ανάλυση των σύγχρονων τάσεων της αγοράς εργασίας και, ύστερα, στην παρουσίαση μεθόδων πρόβλεψης του turnover μέσω της αξιοποίησης των People Analytics. Η μετάβαση από την παραδοσιακή διαχείριση ανθρώπινου δυναμικού σε προσεγγίσεις στηριγμένες στα δεδομένα (data-driven HR) επιτρέπει στις εταιρείες να εντοπίζουν έγκαιρα εργαζομένους που παρουσιάζουν τάσεις αποχώρησης και να προλαμβάνουν τις ζημιές. Χρησιμοποιώντας τεχνικές Τεχνητής Νοημοσύνης (TN) και Μηχανικής Μάθησης, αποσκοπείται η μετατροπή των ιστορικών δεδομένων των εργαζομένων σε προληπτική στρατηγική, προσφέροντας μια βαθιά θεωρητική και πρακτική διερεύνηση του τρόπου με τον οποίο η τεχνολογία μπορεί να θωρακίσει τη δέσμευση του προσωπικού (Zhao, 2018).

## 1.2 Ορισμός του προβλήματος

Το κεντρικό πρόβλημα που καλείται να αντιμετωπίσει η παρούσα μελέτη εστιάζεται στην αδυναμία των σύγχρονων οργανισμών να προβλέψουν και να διαχειριστούν αποτελεσματικά την εθελούσια εγκαταληψη από το προσωπικό τους, αλλά και την έλξη καινούριου προσωπικού σε ένα περιβάλλον μεταβαλλόμενων αξιών. Η παραδοσιακή προσέγγιση αποδεικνύεται ανεπαρκής, καθώς το κόστος της αποχώρησης ενός υπαλλήλου, ειδικά σε θέσεις γραφείου και υψηλής εξειδίκευσης, είναι πολυεπίπεδο.

Επιπλέον, η οικονομική επιβάρυνση για έναν οργανισμό δεν περιορίζεται μόνο στην εκκαθάριση του μισθού, αλλά χωρίζεται σε δύο κύριες κατηγορίες.

Η πρώτη είναι το άμεσο κόστος. Περιλαμβάνει τις δαπάνες αγγελιών, τη χρήση πλατφορμών εύρεσης εργασίας, τις εργατοώρες του τμήματος HR για συνεντεύξεις, καθώς και το κόστος εκπαίδευσης (onboarding) του αντικαταστάτη.

Η δεύτερη είναι το έμμεσο κόστος. Είναι συχνά δυσδιάκριτο αλλά πιο δαπανηρό. Αφορά την απώλεια παραγωγικότητας κατά το διάστημα που η θέση παραμένει κενή, τη μείωση του ηθικού της ομάδας, την πιθανή διατάραξη των σχέσεων με τους με τους πελάτες και την αργή και σταθερή διάβρωση της ομάδας από το φόρτο εργασίας που οδηγεί σε burnout. Όλα τα προαναφερθέντα μπορούν κάλλιστα να συντελέσουν συνδιαστικά στην επιπλέον απώλεια προσωπικού, το οποίο υπο υγιέστερες εργασιακές συνθήκες θα παρέμενε.

## 1.3 Ερευνητικά ερωτήματα και προκλήσεις

Στο πλαίσιο αυτό, αναδύεται η ανάγκη για μια βαθύτερη κατανόηση των αιτιών που τροφοδοτούν την απώλεια προσωπικού και τις νέες τάσεις (job-hopping, quiet quitting). Συνεπώς, θα επιχειρηθεί η απάντηση στα παρακάτω ερευνητικά ερωτήματα:

1. Πόσο ψηλά βάζει ο Έλληνας την εργασία στη ζωή του;
2. Ποια είναι η συνολική στάση του Έλληνα γύρω από το job-hopping και το quiet quitting;
3. Τι συμπεριφορικά μοτίβα παρατηρούνται στην ελληνική πραγματικότητα;
4. Πόσο καλά μπορεί να προβλεφθεί η εργασιακή αποχώρηση με πρακτικές μηχανικής μάθησης;
5. Ποιοι αλγόριθμοι είναι καταλληλότεροι για κάτι τέτοιο;
6. Ποιες μεταβλητές-χαρακτηριστικά αποτελούν καλές ενδείξεις για την απώλεια προσωπικού;
7. Τι μπορεί να κάνει μια επιχείρηση πρακτικά, με βάση τα προαναφερθέντα ευρήματα, για να αντιμετωπίσει ένα από τα πιο διαχρονικά και εξελισσόμενα προβλήματα της, την απώλεια προσωπικού;

## 1.4 Σκοπός και στόχοι

Ο κεντρικός σκοπός της παρούσας διπλωματικής εργασίας είναι η διερεύνηση των παραγόντων που οδηγούν στην οικειοθελή αποχώρηση των εργαζομένων στη σύγχρονη εποχή, καθώς και η αξιολόγηση των δυνατοτήτων των αλγορίθμων μηχανικής μάθησης στην έγκαιρη πρόβλεψη αυτής της τάσης. Η μελέτη φιλοδοξεί να γεφυρώσει το χάσμα μεταξύ της θεωρητικής κατανόησης των νέων τάσεων της αγοράς (όπως το quiet quitting) και της πρακτικής εφαρμογής προηγμένων αναλυτικών μεθόδων. Για την επίτευξη του ανωτέρω σκοπού, ορίζονται οι εξής επιμέρους στόχοι:

Διερεύνηση τάσεων μέσω της Ελληνικής πραγματικότητας: Η συλλογή και ανάλυση πρωτογενών δεδομένων μέσω ερωτηματολογίου, με σκοπό την καταγραφή των στάσεων, των συμπεριφορών, των αξιών και των προτεραιοτήτων των Ελλήνων υπαλλήλων γραφείου μετά την πανδημική κρίση.

Ανάπτυξη και αξιολόγηση προγνωστικών μοντέλων: Η εφαρμογή αλγορίθμων μηχανικής μάθησης (π.χ. Random Forests, XGBoost κ.ο.κ.) σε δευτερογενή και δημόσια σύνολα δεδομένων, για τον εντοπισμό μοτίβων που προμηνύουν την αποχώρηση.

Ερμηνευσιμότητα και ανάλυση σπουδαιότητας: Η μετάβαση από την απλή στατιστική ακρίβεια στην κατανόηση των αιτιωδών παραγόντων. Στόχος είναι να προσδιοριστούν οι παράγοντες (π.χ. ισορροπία ζωής, αμοιβή, περιβάλλον) που βαραίνουν περισσότερο στην απόφαση του εργαζομένου.

Διατύπωση στρατηγικών προτάσεων (Managerial Implications): Η σύνθεση των ευρημάτων της πρωτογενούς και δευτερογενούς έρευνας για τη διαμόρφωση πρακτικών εργαλείων και τακτικών, τα οποία θα επιτρέψουν στα στελέχη Διοίκησης Ανθρώπινου Δυναμικού να δρουν προληπτικά.

Ο απώτερος στόχος της τρέχουσας μελέτης δεν αφορά μόνο στη μεγιστοποίηση της προβλεπτικής ακρίβειας, αλλά και στην εξαγωγή ουσιαστικών και αξιοποιήσιμων συμπερασμάτων στο πλαίσιο των πρακτικών human analytics. Τα συμπεράσματα αυτά θα μπορούσαν να εμπλουτίσουν τη στρατηγική οπτική της διοίκησης αναφορικά με τις σύγχρονες τάσεις του ανθρώπινου δυναμικού, καθώς και να συμβάλουν στη διαμόρφωση αποτελεσματικών πρακτικών αντιμετώπισης ενός εκ των σημαντικότερων προβλημάτων που καλούνται να διαχειριστούν σε καθημερινή βάση.



## **2. Θεωρητικό Υπόβαθρο & Βιβλιογραφική Ανασκόπηση**

### **2.1 Εννοιολογική προσέγγιση του Turnover**

Ο όρος Employee Turnover αναφέρεται στον ρυθμό με τον οποίο οι εργαζόμενοι εγκαταλείπουν έναν οργανισμό και αντικαθίστανται από νέο προσωπικό. Σύμφωνα με τους Hom et al. (Hom, Allen, & Griffith, 2019), η κατανόηση του turnover δεν πρέπει να περιορίζεται σε έναν απλό αριθμό, αλλά να αναλύεται βάσει της πηγής της απόφασης (ποιος αποφάσισε τη λήξη της συνεργασίας) και τη δυνατότητα ελέγχου από την πλευρά της εταιρείας. Οι δύο βασικές κατηγορίες αποχώρησης είναι η οικειοθελής και η αναγκαστική.

#### **2.1.1 Οικειοθελής αποχώρηση**

Η οικειοθελής αποχώρηση συμβαίνει όταν η πρωτοβουλία για τη διακοπή της εργασιακής σχέσης ανήκει στον εργαζόμενο. Αυτή είναι και η μορφή αποχώρησης για την οποία παρουσιάζεται το μεγαλύτερο ενδιαφέρον στην παρούσα διπλωματική, καθώς συνδέεται άμεσα με την ικανοποίηση, τη δέσμευση και τις εναλλακτικές ευκαιρίες στην αγορά εργασίας.

Οι Hom et al. (Hom, Allen, & Griffith, 2019) προχωρούν σε περαιτέρω κατηγοριοποίηση της οικειοθελούς αποχώρησης σε Λειτουργική (Functional) και Δυσλειτουργική (Dysfunctional). Λειτουργική ονομάζεται η αποχώρηση κατά την οποία αποχωρούν οι εργαζόμενοι με χαμηλή απόδοση, επιτρέποντας στην εταιρεία να ανανεώσει το προσωπικό της με πιο ικανά στελέχη. Απεναντίας, η δυσλειτουργική αποχώρηση αφορά στους λεγόμενους “High performers” που διαλέγουν να λήξουν τη συνεργασία τους με την εταιρεία.

Επιπροσθέτως, σύμφωνα με τους Hom et al. (Hom, Allen, & Griffith, 2019), δύο ακόμα πτυχές της οικειοθελούς αποχώρησης είναι η Αποφεύξιμη (Avoidable) και Μη Αποφεύξιμη (Unavoidable). Αποφεύξιμες λέγονται οι αποχωρήσεις που θα μπορούσαν να είχαν προληφθεί με διοικητικές παρεμβάσεις (π.χ. αύξηση μισθού και καλύτερες απολαβές, ευελιξία κ.ο.κ.). Εδώ είναι που η Μηχανική Μάθηση μπορεί να προσφέρει τη μέγιστη αξία. Από την άλλη, Μη Αποφεύξιμη ονομάζεται η αποχώρηση για λόγους εκτός του ελέγχου της εταιρείας, όπως οικογενειακά θέματα, πιθανά προβλήματα υγείας κ.ο.κ.

#### **2.1.2 Αναγκαστική αποχώρηση**

Ακολουθεί η ανάλυση της αναγκαστικής αποχώρησης, η οποία προκύπτει όταν η πρωτοβουλία ανήκει στον εργοδότη. Συνήθως λαμβάνει τη μορφή απόλυσης ή διακοπής σύμβασης. Οι τρεις βασικότεροι λόγοι τέτοιας πρωτοβουλίας είναι η ανεπαρκής απόδοση, πειθαρχικά παραπτώματα και αναδιάρθρωση (downsizing).

Ο όρος ανεπαρκής απόδοση αναφέρεται στο σενάριο όπου ο εργαζόμενος δεν ανταποκρίνεται στις απαιτήσεις της θέσης, δημιουργώντας έτσι περισσότερη ζημιά παρά οφέλη.

Προχωρώντας στον όρο πειθαρχικά παραπτώματα αναφερόμαστε στην παραβίαση των κανόνων του οργανισμού, όπως τακτική αντιεπαγγελματική συμπεριφορά σε αλληλεπιδράσεις με το προσωπικό/πελάτες της εταιρείας, κλοπή εξοπλισμού, παρενόχληση κ.ο.κ.

Τέλος, ο όρος αναδιάρθρωση αναφέρεται σε στρατηγικές αποφάσεις για μείωση κόστους ή αλλαγή επιχειρηματικού μοντέλου που οδηγούν σε περικοπές θέσεων εργασίας. Πρόσφατα παραδείγματα περιλαμβάνουν τις μαζικές απολύσεις της Oracle σε 30,000 εργαζομένους για λόγους αύξησης των υποδομών Τεχνητής Νοημοσύνης τους (Markman, 2026).

## **2.2 Θεωρίες οργανωσιακής συμπεριφοράς**

Επεκτείνοντας στα προαναφερθέντα, θα αναλυθούν οι ψυχολογικοί και εταιρικοί μηχανισμοί που ωθούν έναν εργαζόμενο στην έξοδο ή τη διατήρηση του σε έναν οργανισμό. Η σύνθεση της κλασικής θεωρίας των Hom et al. (Hom, Allen, & Griffith, 2019) με τα πρόσφατα ευρήματα του άρθρου των Dias et al. (Dias, Cruz, Luis, Jardim da Palma, & Pereira, 2025), μας επιτρέπει να κατανοήσουμε το turnover όχι ως ένα τυχαίο γεγονός, αλλά ως το αποτέλεσμα της αλληλεπίδρασης διαφόρων παραγόντων.

### **2.2.1 Θεωρία της ώθησης και της έλξης**

Η θεωρία της ώθησης και της έλξης παραμένει το θεμέλιο του turnover (Hom, Allen, & Griffith, 2019), αλλά οι Dias et al. (Dias, Cruz, Luis, Jardim da Palma, & Pereira, 2025) την εμπλουτίζουν με τη διάσταση της "επαγγελματικής μετάβασης". Σύμφωνα με το άρθρο τους, λοιπόν, η απόφαση για turnover δεν είναι μια γραμμική αντίδραση, αλλά μια στάθμιση επαγγελματικών παραγόντων.

Αρχικά, Παράγοντες ώθησης ονομάζονται οι λόγοι που κάποιος εργαζόμενος «ωθείται» μακριά από την εταιρεία για πληθώρα λόγων. Κάποιοι από τους Παράγοντες ώθησης (Push factors), πέρα από την έλλειψη ικανοποίησης (Hom, Allen, & Griffith, 2019), περιλαμβάνουν την επαγγελματική στασιμότητα και την έλλειψη υποστήριξης από τη διοίκηση (Dias, Cruz, Luis, Jardim da Palma, & Pereira, 2025). Όταν το τρέχον περιβάλλον δεν προσφέρει κάποιο ξεκάθαρο ή ελκυστικό μονοπάτι ανόδου σε βάθος χρόνων, ο εργαζόμενος «ωθείται» στην έξοδο.

Προχωρώντας, οι Παράγοντες έλξης (pull factors) είναι το ανάποδο από τους προαναφερθέντες παράγοντες, δηλαδή είναι λόγοι που προσελκύουν τους εργαζομένους σε μία θέση κάποιας εταιρείας. Κλασικοί Παράγοντες έλξης περιλαμβάνουν ικανοποιητικές απολαβές και προνόμια, ευελιξία δουλειάς και απόσταση από κατοικία. Ωστόσο, σύμφωνα με τη μελέτη των Dias et al (Dias, Cruz, Luis, Jardim da Palma, & Pereira, 2025), πολλοί εργαζόμενοι έλκονται και από τη φήμη του οργανισμού και την υπόσχεση για καλύτερη ισορροπία μεταξύ επαγγελματικής και προσωπικής ζωής. Ένας εξίσου σημαντικός παράγοντας έλξης, πλέον, αποτελεί τη δυνατότητα υβριδικής εργασίας.

### **2.2.2 Εταιρική δέσμευση και ικανοποίηση από την εργασία**

Η εργασιακή ικανοποίηση, παρά τους κλασικούς ορισμούς της ως συναισθηματική κατάσταση (Hom, Allen, & Griffith, 2019), δείχνει να είναι, σύμφωνα με πιο πρόσφατες μελέτες, πολυπαραγοντική (Dias, Cruz, Luis, Jardim da Palma, & Pereira, 2025). Συνδέεται άμεσα με την αίσθηση "επαγγελματικής ασφάλειας" και την ποιότητα των σχέσεων με τους συναδέλφους. Αν ένας από αυτούς τους πυλώνες καταρρεύσει, η πρόθεση αποχώρησης αυξάνεται εκθετικά.

Στη συνέχεια η εταιρική δέσμευση, η οποία ορίζεται ως ο ψυχολογικός δεσμός που αναπτύσσει ο εργαζόμενος με τον οργανισμό στον οποίο απασχολείται, παίζει εξίσου σημαντικό ρόλο στη διατήρηση του ανθρώπινου κεφαλαίου. Διακρίνεται από τρία μέρη (Meyer, 1991).

Σύμφωνα, λοιπόν, με το κλασικό τριμελές μοντέλο των Meyer και Allen (Meyer, 1991), το οποίο αποτελεί τη βάση για τις αναλύσεις των Hom et al. (Hom, Allen, & Griffith, 2019), το πρώτο είδος δέσμευσης είναι η Συναισθηματική (Affective Commitment). Πρόκειται για την ισχυρότερη μορφή δέσμευσης. Ο εργαζόμενος νιώθει συναισθηματικά δεμένος με την εταιρεία, αποδέχεται πλήρως τις αξίες της και αισθάνεται ότι "ανήκει" εκεί. Οι εργαζόμενοι με υψηλή συναισθηματική δέσμευση έχουν τις λιγότερες πιθανότητες να αποχωρήσουν, καθώς η εργασία τους προσφέρει εσωτερική ικανοποίηση.

Η δεύτερη μορφή δέσμευσης είναι η Κανονιστική (Normative Commitment). Εδώ, η δέσμευση πηγάζει από ένα αίσθημα ηθικής υποχρέωσης ή καθήκοντος. Ο εργαζόμενος μπορεί να αισθάνεται ότι η εταιρεία επένδυσε σε αυτόν (π.χ. μέσω εκπαίδευσης) ή ότι του στάθηκε σε μια δύσκολη στιγμή, και ως εκ τούτου θεωρεί "λάθος" ή "αχάριστο" να παραιτηθεί τη δεδομένη στιγμή. Αυτό μπορεί να λειτουργήσει ως προσωρινός ανασταλτικός παράγοντας, αλλά είναι λιγότερο ισχυρή μορφή δέσμευσης από τη Συναισθηματική σε βάθος χρόνου.

Η τρίτη μορφή είναι η δέσμευση Συνέχειας (Continuance Commitment). Αυτή η μορφή δέσμευσης βασίζεται στην αξιολόγηση του κόστους και του οφέλους. Ο εργαζόμενος παραμένει επειδή οι απώλειες από μια ενδεχόμενη παραίτηση (π.χ. απώλεια προνομίων, σύνταξης, μισθού ή έλλειψη εναλλακτικών θέσεων στην αγορά) είναι μεγαλύτερες από το όφελος της αποχώρησης. Συνεπώς, σε τέτοια σενάρια ο εργαζόμενος μένει στην εταιρεία "εγκλωβισμένος". Αν εμφανιστεί μια εξωτερική πρόταση που καλύπτει το κενό απολαβών του (Θεωρία της έλξης - Κεφάλαιο 2.2.1), η δέσμευση αυτή καταρρέει αμέσως.

## **2.3 Τάσεις των τελευταίων χρόνων που επηρεάζουν σημαντικά το turnover**

Σε αυτήν την ενότητα θα αναλυθούν τρεις από τις πιο συνηθισμένες σύγχρονες τάσεις των εργαζομένων τα τελευταία χρόνια, με άμεση επίδραση στο turnover. Οι τρεις αυτές τάσεις είναι το Job Hopping, το Quiet Quitting (ή αλλιώς Silent Quitting) και η αναπροσαρμογή των προτεραιοτήτων των εργαζομένων σε μια πιο ευεξιοκεντρική ζωή.

### **2.3.1 Job Hopping**

Το φαινόμενο του Job Hopping (συχνή εναλλαγή εργοδοτών σε σύντομα χρονικά διαστήματα) δεν θεωρείται πλέον ένδειξη αστάθειας, αλλά στρατηγική επιλογή καριέρας. Σύμφωνα με τον Pandley (Pandley, 2019), η τάση αλλαγής εργοδότη συνήθως ανά 1-2 έτη είναι ιδιαίτερα έντονη στη γενιά των Millennials, οι οποίοι αντιμετωπίζουν την εργασία ως μέσο απόκτησης ποικίλων εμπειριών και ταχείας μισθολογικής εξέλιξης.

Τα κίνητρα πίσω από τέτοιες πρακτικές περιλαμβάνουν, σύμφωνα με τον Pandley, την αναζήτηση καλύτερων παροχών και η έλλειψη προκλήσεων. Ως αποτέλεσμα, δημιουργείται μια κουλτούρα κινητικότητας όπου η πρόθεση παραμονής μειώνεται δραστικά αν ο οργανισμός δεν προσφέρει συνεχή επανεκπαίδευση και ανταγωνιστικά πακέτα απολαβών.

### 2.3.2 Quiet Quitting

Το δεύτερο σύνθημα φαινόμενο, το Quiet Quitting, περιγράφει την κατάσταση όπου ο εργαζόμενος αποφασίζει να σταματήσει να καταβάλλει έντονη και υπερβάλλουσα προσπάθεια, περιορίζοντας τις ενασχολήσεις του αυστηρά στις περιγραφές των καθηκόντων του. Παραδείγματος χάριν, κάποιος προγραμματιστής Junior επιπέδου με βασικές αρμοδιότητες την παροχή συγκεκριμένων παραδοτέων διαλέγει να περιορίζεται μόνο σε αυτό, παρουσιάζοντας λιγότερη συμμετοχή σε ομαδικά προβλήματα, λιγότερη προθυμία βοήθειας συναδέλφων, έντονη απάθεια και αδιαφορία σε καθημερινή βάση.

Σύμφωνα με τον Bolino (Bolino & Klotz, 2022), το Quiet Quitting είναι μια αντίδραση στην επαγγελματική εξουθένωση. Επισημαίνει πως ενώ ο εργαζόμενος παραμένει τυπικά στην εταιρεία, η ψυχολογική του αποδέσμευση αποτελεί προοικονομία του turnover. Τέτοια τάση είναι δύσκολο να εντοπιστεί από τα People Analytics, καθώς ο υπάλληλος δεν έχει φύγει ακόμη, αλλά η μειωμένη του δέσμευση επηρεάζει την παραγωγικότητα της ομάδας και συχνά καταλήγει σε οικειοθελή αποχώρηση μόλις βρεθεί μια ελκυστική εναλλακτική.

Η εν λόγω τάση μπορεί να θεωρηθεί και ως η επιχειρησιακή έκφραση της Δέσμευσης Συνέχειας, που αναλύθηκε στο Κεφάλαιο 2.2.2, καθώς ένας εργαζόμενος που εκτελεί αυτήν την πρακτική, έχοντας αξιολογήσει τα οφέλη και τα κόστη της γρήγορης αποχώρησης του, διαλέγει να μείνει γιατί πιθανώς δεν έχει βρει άμεση εναλλακτική. Όπως προκύπτει από την ανάλυση του Bolino (Bolino & Klotz, 2022), όταν η συναισθηματική σύνδεση με τον οργανισμό απουσιάζει, ο εργαζόμενος παραμένει στη θέση του αποκλειστικά λόγω του κόστους αποχώρησης (Continuance Commitment), υιοθετώντας μια στάση ελάχιστης προσπάθειας ως μέσο διατήρησης της προσωπικής του ευεξίας.

### 2.3.3 Εργασιακή ευεξία & Work-Life Balance

Η τελευταία μοντέρνα τάση που θα αναλυθεί έκανε την εμφάνιση της κατά τη διάρκεια της πανδημίας, η οποία ήταν και ο καταλύτης για τη «Μεγάλη Επαναξιολόγηση» (The Great Reshuffle). Σύμφωνα με τα ευρήματα του Microsoft Work Trend Index (Great Expectations: Making Hybrid Work Work, 2022), η ευελιξία (υβριδική ή remote εργασία) δε θεωρείται πλέον προνόμιο αλλά βασική απαίτηση, καθώς από 31.000 συμμετέχοντες της έρευνας αυτής, το 53% των εργαζομένων επισήμανε πως είναι πιο πιθανό να θέσει την υγεία και την ευεξία του πάνω από την εργασία. Επιπρόσθετα, το 47% των εν λόγω ερωτηθέντων δίνει προτεραιότητα στην προσωπική ζωή έναντι της καριέρας.

Η μορφή ευημερίας που επηρεάζει άμεσα το εργασιακό turnover και καθορίζει σημαντικά τις σύγχρονες τάσεις της αγοράς εργασίας ονομάζεται Εργασιακή Ευημερία (Employee Well-being). Παρά την πολυδιάστατη φύση της, αναφέρεται στη συνολική ποιότητα και εμπειρία ενός εργαζομένου. Έχει πλαισιωθεί πολλαπλές φορές στο παρελθόν, από διαφορετικούς ερευνητές. Ωστόσο, σύμφωνα με τους Aroorva et al (Pandey, Maheshwari, & Malik, 2024), κατόπιν βιβλιογραφικής ανασκόπησης τους, η εργασιακή ευεξία πλαισιώνεται μεταξύ πέντε διαστάσεων, της σωματικής, της ψυχικής, της κοινωνικής, της οικονομικής και της πνευματικής.

Η ψυχολογική ευημερία αναφέρεται στις πνευματικές και συναισθηματικές πτυχές της συνολικής υγείας ενός ατόμου. Αφορά τον τρόπο με τον οποίο τα άτομα αντιλαμβάνονται και

ανταπεξέρχονται στο εργασιακό τους περιβάλλον, συμπεριλαμβανομένης της αίσθησης του σκοπού, της αυτοεκτίμησης και της γενικότερης ψυχικής τους υγείας.

Η κοινωνική ευημερία περιλαμβάνει την ποιότητα και τη δύναμη των διαπροσωπικών σχέσεων και των κοινωνικών αλληλεπιδράσεων ενός ατόμου. Περιλαμβάνει πτυχές όπως η κοινωνική υποστήριξη, η επικοινωνία με τους συναδέλφους, η ομαδική εργασία και η αίσθηση του ανήκειν στον εργασιακό χώρο. Η κοινωνική ευημερία αντανακλά το πόσο καλά συνδέονται τα άτομα με τους άλλους, καθώς και τις θετικές ή αρνητικές επιπτώσεις αυτών των αλληλεπιδράσεων στη συνολική τους ευεξία.

Στη συνέχεια, η σωματική ευημερία σχετίζεται με την υγεία και τη σωματική λειτουργία του ατόμου. Αφορά τον αντίκτυπο των σωματικών απαιτήσεων της εργασίας στην υγεία του ατόμου και την ικανότητά του να διατηρεί έναν υγιεινό τρόπο ζωής.

Προχωρώντας, η οικονομική ευημερία αναφέρεται στη σταθερότητα και την ικανοποίηση που σχετίζεται με την οικονομική κατάσταση και τους πόρους ενός ατόμου. Περιλαμβάνει παράγοντες όπως η επάρκεια εισοδήματος, η οικονομική ασφάλεια και η ικανότητα αποτελεσματικής διαχείρισης των προσωπικών οικονομικών.

Τέλος, η πνευματική ευημερία περιλαμβάνει την αίσθηση του σκοπού, του νοήματος και της ευθυγράμμισης με τις αξίες και τα πιστεύω του ατόμου. Αντανακλά το πώς η αίσθηση του σκοπού και η εσωτερική γαλήνη επηρεάζουν τη συνολική εργασιακή ικανοποίηση και την προσωπική πλήρωση (Pandey, Maheshwari, & Malik, 2024).

Ένας εργαζόμενος που έχει ενσωματωθεί σε έναν οργανισμό βιώνει με διαφορετικό τρόπο την καθημερινότητά του. Ένα μεγάλο κομμάτι, λοιπόν, που επηρεάζει τις πέντε προαναφερθείσες διαστάσεις είναι η εργασιακή κουλτούρα μιας εταιρείας, η οποία υποστηρίζεται τόσο από το τμήμα ανθρωπίνου δυναμικού όσο και από τους ίδιους τους εργαζόμενους της. Όταν μια εταιρεία αποτυγχάνει να παρέχει μια εργασιακή κουλτούρα με προτεραιότητα στην ισορροπία μεταξύ επαγγελματικής και προσωπικής ζωής (work-life balance), στην ομαδικότητα και στην αξιοκρατική επιβράβευση του προσωπικού της, κινδυνεύει να χάσει το την ελκυστικότητα της (Pandey, Maheshwari, & Malik, 2024) στα μάτια του ενεργού/μελλοντικού προσωπικού της. Συνεπώς, οργανισμοί που αποτυγχάνουν να προσφέρουν τα προαναφερθέντα έρχονται αντιμέτωποι με υψηλά ποσοστά turnover, καθώς οι εργαζόμενοι παραιτούνται αναζητώντας ποιοτικότερο χρόνο ψυχική γαλήνη.

## **2.4 People Analytics**

### **2.4.1 Ορισμός και εξέλιξη**

Τα People Analytics ορίζονται ως η συστηματική εφαρμογή στατιστικών μεθόδων και τεχνολογιών πληροφορικής στα δεδομένα του ανθρώπινου δυναμικού, με σκοπό τη βελτίωση των επιχειρηματικών αποτελεσμάτων. Σύμφωνα με τον Fitz-enz (Fitz-enz & Mattox, 2014), η εξέλιξη του κλάδου χωρίζεται σε τρία στάδια, εκ των οποίων το πρώτο είναι η Περιγραφική ανάλυση (Descriptive analysis), το δεύτερο η Διαγνωστική ανάλυση. (Diagnostic analysis) και το τρίτο η Προγνωστική ανάλυση (Predictive analysis).

## 2.4.2 Η σημασία της Προγνωστικής ανάλυσης στο Turnover

Η προγνωστική ανάλυση αποτελεί ένα σημαντικό εργαλείο για τη διαχείριση της κινητικότητας. Οι Guenole et al. (Guenole, 2017) επισημαίνουν ότι η αξία των People Analytics δεν έγκειται μόνο στην πρόβλεψη, αλλά στην κατανόηση των κινήτρων.

Στην περίπτωση του turnover, το HR Analytics μεταφράζει τους παράγοντες έλξης και ώθησης (βλ. Κεφάλαιο 2.2.1) σε τρεις κατηγορίες μεταβλητών. Η πρώτη κατηγορία περιλαμβάνει τα δημογραφικά δεδομένα (ηλικία, οικογενειακή κατάσταση, απόσταση από το γραφείο κ.ο.κ.), η δεύτερη τα επαγγελματικά δεδομένα (μισθός σε σχέση με την αγορά, έτη στην ίδια θέση, αριθμός προαγωγών) και τα δεδομένα συμπεριφοράς (συμμετοχή σε εκπαιδεύσεις, χρήση αδειών, βαθμολογίες απόδοσης).

## 2.4.3 Σύγχρονες τεχνικές και Μηχανική Μάθηση

Όπως υποστηρίζει ο Park (Park, 2024), η χρήση της Μηχανικής Μάθησης (Machine Learning) επιτρέπει την επεξεργασία τεράστιων όγκων δεδομένων που η παραδοσιακή στατιστική αδυνατούσε να διαχειριστεί. Κατ' επέκταση, η χρήση Random Forests και Gradient Boosting (XGBoost) επιτρέπει τον εντοπισμό μη γραμμικών συσχετίσεων στα σύνολα δεδομένων. Για παράδειγμα, ένας υπάλληλος μπορεί να μη φεύγει λόγω χαμηλού μισθού, αλλά λόγω του συνδυασμού χαμηλού μισθού και μεγάλης απόστασης από το σπίτι.

Η σύγχρονη τάση στα People Analytics επιβάλλει τη χρήση "διαφανών" μοντέλων. Τα στελέχη HR πρέπει να γνωρίζουν όχι μόνο ποιος θα φύγει, αλλά και γιατί, ώστε να σχεδιάσουν εξατομικευμένα πλάνα διατήρησης προσωπικού.

# 3. Ερευνητική Μεθοδολογία

## 3.1 Σχεδιασμός πρωτογενούς έρευνας

Προχωρώντας στη διαδικασία της ερευνητικής μεθοδολογίας, θα γίνει απόπειρα σύγκρισης των σύγχρονων στάσεων των εργαζομένων γραφείου της Ελλάδας με τις προαναφερθείσες τάσεις που αναπτύχθηκαν στην βιβλιογραφική ανασκόπηση. Αυτό θα πραγματοποιηθεί με τη χρήση ερωτηματολογίου, με βασικό σκοπό τη συλλογή πρωτογενών δεδομένων από την Ελληνική αγορά εργασίας μέσω Google Forms. Ενώ τα δευτερογενή δεδομένα (Kaggle dataset) που θα χρησιμοποιηθούν κατά την εφαρμογή Μηχανικής Μάθησης θα δείξουν το τι συνέβη, η πρωτογενής έρευνα αποσκοπεί στο να εξηγήσει το γιατί, εστιάζοντας στις αναδυόμενες τάσεις της ελληνικής πραγματικότητας.

### 3.1.1 Περιγραφή του ερωτηματολογίου

Το ερωτηματολόγιο θα δομηθεί ως ένα εργαλείο μέτρησης, βασισμένο σε αναγνωρισμένες ακαδημαϊκές κλίμακες, προσαρμοσμένες στις ανάγκες της παρούσας μελέτης. Βασικός στόχος του είναι η παροχή στοχευμένων ερωτήσεων που θα αντικατοπτρίζουν τόσο απόψεις όσο και

συμπεριφορές, έτσι ώστε οι τεχνικές Clustering που θα εφαρμοστούν στα συλλεχθέντα δεδομένα του να μπορούν να αναγνωρίσουν τι κρύβει η ελληνική αγορά εργασίας. Θα χωρίζεται σε τέσσερις βασικούς άξονες.

Ο πρώτος άξονας αφορά στο Job Hopping (Βασισμένος στον Pandey, 2019). Θα περιλαμβάνει ερωτήσεις που διερευνούν την αντίληψη του εργαζόμενου για τη συχνή αλλαγή εργοδότη ως μέσο επαγγελματικής ανέλιξης και τη στάση του απέναντι στη μακροχρόνια παραμονή σε έναν οργανισμό.

Ο δεύτερος άξονας αφορά στο Quiet Quitting & δέσμευση (Βασισμένος στον Bolino, 2023). Θα περιλαμβάνει χρήση ερωτήσεων που μετρούν κατά πόσο ο εργαζόμενος περιορίζεται στα ελάχιστα καθήκοντα ή αν διατηρεί τη διάθεση για υπερβάλλουσα προσπάθεια.

Ο τρίτος άξονας αφορά στο Burnout & Ευεξία (Βασισμένος στο Microsoft Work Trend Index). Θα περιλαμβάνει ερωτήσεις που αξιολογούν τα επίπεδα εργασιακού στρες και τη σημασία που δίνει το άτομο στην ισορροπία επαγγελματικής/προσωπικής ζωής ως κριτήριο παραμονής.

Ο τέταρτος και τελευταίος άξονας αφορά στην πρόθεση αποχώρησης του ερωτώμενου. Θα περιλαμβάνει την εξαρτημένη μεταβλητή της έρευνας, η οποία μετρά την πιθανότητα ο εργαζόμενος να αναζητήσει νέα εργασία στους επόμενους 6 έως 12 μήνες. Ο εν λόγω άξονας θα βοηθήσει στη γεφύρωση των προαναφερθέντων αξόνων με την εργασιακή κινητικότητα και θα συντελέσει στη διεξαγωγή συμπερασμάτων σχετικά με τις σύγχρονες τάσεις στην Ελληνική αγορά.

### **3.1.2 Δειγματοληψία και χαρακτηριστικά δείγματος**

Η επιλογή του δείγματος θα γίνει με τη μέθοδο της σκόπιμης δειγματοληψίας (purposive sampling) και της δειγματοληψίας χιονοστιβάδας (snowball sampling) μέσω κοινωνικών και επαγγελματικών δικτύων (LinkedIn, Reddit). Το επίκεντρο της έρευνας θα είναι αποκλειστικά η ελληνική αγορά, με έμφαση σε υπαλλήλους γραφείου (white-collar workers), καθώς αυτοί επηρεάστηκαν περισσότερο από τις αλλαγές στο υβριδικό μοντέλο εργασίας. Επιπροσθέτως, για την επίτευξη ενός υψηλότερου ποσοστού απόκρισης, δόθηκε έμφαση στη σύντομη φύση του ερωτηματολογίου κατά την προώθηση του, με μία συνοπτική περιγραφή της θεματολογίας και έμφαση στην απλότητα των ερωτήσεων.

Όσον αφορά στις ηλικιακές ομάδες, θα δοθεί ιδιαίτερη έμφαση στη σύγκριση μεταξύ των Millennials και της Gen Z, καθώς η βιβλιογραφία (Pandley, 2019) υποδεικνύει ότι αυτές οι ομάδες ηγούνται των τάσεων job hopping και quiet quitting. Επιπλέον, θα καταγράφονται το επίπεδο εκπαίδευσης, τα έτη προϋπηρεσίας, ο κλάδος δραστηριότητας (π.χ. Τεχνολογία, Τράπεζες, Παροχή Υπηρεσιών) και το τρέχον μοντέλο εργασίας (Δια ζώσης, Υβριδικό, Απομακρυσμένο).

Λόγω της διερευνητικής φύσης της μελέτης και της μη-πιθανοτικής δειγματοληψίας, δεν πραγματοποιήθηκε εκ των προτέρων power analysis. Ωστόσο, τα αποτελέσματα ερμηνεύονται με προσοχή, λαμβάνοντας υπόψη το μέγεθος του δείγματος και τον περιορισμό στη γενίκευση.

Τέλος, το ερωτηματολόγιο θα είναι αυστηρώς ανώνυμο και θα ακολουθεί τις οδηγίες του GDPR, κάτι που είναι υποχρεωτικό για κάθε ακαδημαϊκή έρευνα που συλλέγει δεδομένα στην Ελλάδα/ΕΕ.

### 3.1.3 Στατιστική ανάλυση αποτελεσμάτων ερωτηματολογίου με Python

Μετά τη συλλογή των πρωτογενών δεδομένων, θα ακολουθήσει η φάση της επεξεργασίας και ανάλυσης με τη χρήση της γλώσσας προγραμματισμού Python. Η επιλογή της Python βασίζεται στην ευελιξία της και στην πληθώρα εξειδικευμένων βιβλιοθηκών (Pandas, NumPy, SciPy, Matplotlib/Seaborn) που επιτρέπουν μια πιο εκτενή ανάλυση από τις παραδοσιακές στατιστικές μεθόδους. Η διαδικασία της ανάλυσης θα δομηθεί στα παρακάτω στάδια.

Το πρώτο αφορά στον καθαρισμό και προεπεξεργασία δεδομένων (Data Wrangling). Εκεί θα πραγματοποιηθεί έλεγχος για ελλειπείς τιμές (missing values), ανίχνευση ακραίων τιμών (outliers) και κωδικοποίηση των ποιοτικών απαντήσεων (π.χ. μετατροπή των κλιμάκων Likert σε αριθμητικές τιμές) για τη διευκόλυνση της στατιστικής επεξεργασίας.

Έπειτα, στο δεύτερο στάδιο θα πραγματοποιηθεί περιγραφική στατιστική (Descriptive Statistics). Θα γίνει υπολογισμός μέσων όρων, τυπικών αποκλίσεων και συχνοτήτων για τις κύριες μεταβλητές (Burnout score, όφελος Job Hopping, όφελος Quiet Quitting). Η οπτικοποίηση θα πραγματοποιηθεί μέσω σύνθετων διαγραμμάτων (Bar plots, Histograms) για την κατανόηση της κατανομής των απαντήσεων.

Ύστερα, στο τρίτο στάδιο θα γίνει ανάλυση συσχέτισης (Correlation Analysis) μεταξύ των τιμών. Με τη χρήση του συντελεστή Pearson ή Spearman θα γίνει ο προσδιορισμός της σχέσης μεταξύ των μεταβλητών. Παραδείγματος χάριν, θα εξεταστεί η συσχέτιση μεταξύ του επιπέδου ευεξίας και της πρόθεσης αποχώρησης. Επιπρόσθετα, θα χρησιμοποιηθούν ομαδοποιημένα ραβδογράμματα για διμετάβλητη ανάλυση βασισμένα στο θεωρητικό υπόβαθρο και την υπάρχουσα βιβλιογραφία, με στόχο την κατανόηση και σύγκριση των σύγχρονων τάσεων/συμπεριφορών με την υπάρχουσα βιβλιογραφία.

Στο τέταρτο και τελευταίο βήμα θα κλείσει η διαδικασία με την εφαρμογή του αλγορίθμου K-Prototypes για συσταδοποίηση. Ο εν λόγω αλγόριθμος θα συντελέσει στην εύρεση και κατανόηση των παραγόντων που διαχωρίζουν τους Έλληνες white-collar workers.

## 3.2 Χρήση πρακτικών Μηχανικής Μάθησης για πρόβλεψη προθέσεων εγκατάλειψης

Στο δεύτερο σκέλος της ερευνητικής μεθοδολογίας, εφαρμόζονται τεχνικές Μηχανικής Μάθησης (Machine Learning) σε δευτερογενή δεδομένα, με στόχο την προγνωστική μοντελοποίηση του turnover. Η ανάλυση θα βασιστεί στο σύνολο δεδομένων της IBM με όνομα IBM HR Analytics, από την πλατφόρμα Kaggle. Το εν λόγω dataset, παρά το γεγονός ότι είναι συνθετικό, έχει χρησιμοποιηθεί από πολλές έρευνες στο παρελθόν και αποτελεί καλή βάση για την παρουσίαση μιας proof-of-concept εφαρμογής. Ακολουθούν τα στάδια που συντελούν τη μεθοδολογική προσέγγιση.

Πριν την εφαρμογή των μοντέλων, θα πραγματοποιηθεί στατιστική ανάλυση για τον εντοπισμό συσχετίσεων μεταξύ των μεταβλητών (π.χ. συσχέτιση υπερωριών και αποχώρησης). Συνδυαστικά με οπτικοποίηση των δεδομένων, θα αναδειχθούν τα κρίσιμα χαρακτηριστικά (features) που τροφοδοτούν το φαινόμενο.



Στη συνέχεια θα ακολουθήσει η προεπεξεργασία και επιλογή χαρακτηριστικών (Feature Engineering). Σε αυτό το βήμα περιλαμβάνεται ο καθαρισμός των δεδομένων, η διαχείριση ελλειπών τιμών και την κωδικοποίηση κατηγορικών μεταβλητών. Ιδιαίτερη έμφαση θα δοθεί στην αντιμετώπιση της ανισόρροπης κατανομής των κλάσεων (class imbalance), χρησιμοποιώντας τεχνικές όπως το SMOTE, ώστε το μοντέλο να εκπαιδευτεί αποτελεσματικά στον εντοπισμό των υπαλλήλων που αποχωρούν.

Ύστερα θα δοκιμαστεί μια πληθώρα αλγορίθμων εποπτευόμενης μάθησης (Supervised Learning), συμπεριλαμβανομένων των Logistic Regression, Random Forests, Extreme Gradient Boosting, Light Gradient Boosting Machine & Support Vector Machine. Η αξιολόγηση της απόδοσης των μοντέλων δε θα κριθεί μόνο βάσει της ακρίβειας (Accuracy), αλλά κυρίως μέσω δεικτών όπως το F1-Score, το Precision, το Recall και η AUC-ROC καμπύλη, που είναι καταλληλότεροι για προβλήματα πρόβλεψης αποχώρησης.

Ο στόχος αυτής της διαδικασίας είναι διττός. Αφενός, αποσκοπεί στην ανάδειξη της προγνωστικής ισχύος της Μηχανικής Μάθησης στον εντοπισμό "υψηλού κινδύνου" υπαλλήλων πριν την οριστική τους απόφαση. Αφετέρου, επιδιώκει τη δημιουργία ενός πρωτοκόλλου δράσης. Το πρωτόκολλο αυτό θα περιλαμβάνει τα βήματα που πάρθηκαν κατά τη διεξαγωγή συμπερασμάτων αυτής της έρευνας. Ο ενδιαφερόμενος αναγνώστης θα μπορεί, συνεπώς, να μελετήσει τα βήματα αυτά και να προσπαθήσει να τα επαναλάβει για δικούς του ερευνητικούς ή επιχειρηματικούς σκοπούς.

### **3.3 Εργαλεία και εφαρμογές που χρησιμοποιήθηκαν κατά την διαδικασία**

Στο παρόν κεφάλαιο παρατίθενται τα ψηφιακά εργαλεία και οι εφαρμογές που αξιοποιήθηκαν κατά τον σχεδιασμό, τη συλλογή βιβλιογραφίας και τη συγγραφή της μελέτης. Η επιλογή των εργαλείων έγινε με γνώμονα τη μεγιστοποίηση της ερευνητικής αποδοτικότητας, τη διασφάλιση της επιστημονικής ακρίβειας και τη βελτιστοποίηση της δομικής συνοχής του τελικού κειμένου.

#### **3.3.1 Συλλογή, χαρτογράφηση και αξιολόγηση πηγών**

Το στάδιο της βιβλιογραφικής ανασκόπησης υποστηρίχθηκε από εξειδικευμένα εργαλεία που επέτρεψαν τη μετάβαση από την απλή αναζήτηση στη συστηματική σύνθεση της γνώσης. Το πρώτο απο αυτά, το Litmaps, χρησιμοποιήθηκε ως εργαλείο οπτικοποίησης των βιβλιογραφικών δικτύων. Μέσω της ανάλυσης αναφορών που προσφέρει, η ιστοσελίδα Litmaps επέτρεψε τον εντοπισμό των σημαντικότερων μελετών και τη σύνδεσή τους με νεότερες έρευνες, διασφαλίζοντας ότι η μελέτη καλύπτει όλο το φάσμα της εξέλιξης του turnover και των People Analytics.

Ύστερα ακολουθεί ο συνδυασμός των ιστοσελιδών Google Scholar και DOAJ (Directory of Open Access Journals), τα οποία αποτέλεσαν τις κύριες βάσεις για την ανάκτηση επιστημονικών άρθρων και μελετών. Η συνδυαστική τους χρήση εξασφάλισε πρόσβαση σε έγκυρα περιοδικά, ενισχύοντας την πολυφωνία της βιβλιογραφικής τεκμηρίωσης.

Στην συνέχεια, το Gemini (Large Language Model – LLM) αξιοποιήθηκε ως ψηφιακός βοηθός στην προκαταρκτική αξιολόγηση των πηγών. Μέσω της παραγωγής συνόψεων, κατέστη δυνατός ο γρήγορος διαχωρισμός των πηγών σε σχετικές, δευτερεύουσες και μη σχετικές, βελτιώνοντας σημαντικά τη διαχείριση του ερευνητικού χρόνου.

Τέλος, η οργάνωση του υλικού ολοκληρώθηκε με τη δημιουργία ενός αρχείου καταγραφής πηγών, όπου κάθε πηγή συνοδεύεται από σύντομο σχολιασμό σχετικά με τη συμβολή της στην έρευνα, διευκολύνοντας την επαναεπίσκεψη και τη διασταύρωση των στοιχείων κατά τη συγγραφή.

### **3.3.2 Συγγραφή, ακαδημαϊκή παράφραση και τεχνική επεξεργασία**

Για τη διασφάλιση της ακαδημαϊκής ακεραιότητας και της γλωσσικής ποιότητας του κειμένου, χρησιμοποιήθηκαν δυο ισχυρά εργαλεία. Το πρώτο από αυτά είναι, ξανά, το Gemini LLM, για παράφραση και υφολογική προσαρμογή. Χρησιμοποιήθηκε για την αναδιατύπωση σύνθετων εννοιών, την παράφραση πηγών και την απόδοση ξενόγλωσσων όρων στην ελληνική ακαδημαϊκή ορολογία. Η διαδικασία αυτή δεν ήταν αυτοματοποιημένη, καθώς τα παραγόμενα κείμενα υποβλήθηκαν σε αυστηρό κριτικό έλεγχο και περαιτέρω επεξεργασία από τον ερευνητή, ώστε να διατηρηθεί η ακρίβεια των νοημάτων και η πρωτοτυπία του λόγου.

Ζωτικής σημασίας πτυχή για την επίτευξη ενός γλωσσικά ομοιόμορφου αποτελέσματος αποτελεί η σωστή ορθογραφία και η έλλειψη τυπογραφικών σφαλμάτων από το τελικό αποτέλεσμα. Αυτό διασφαλίστηκε με την βοήθεια της ιστοσελίδας [textgents.com](https://textgents.com), μέσω της οποίας πραγματοποιήθηκε ο τελικός έλεγχος και η διόρθωση του κειμένου σε ορθογραφικό και συντακτικό επίπεδο.

## **4. Ανάλυση πρωτογενών δεδομένων και κατανόηση ελληνικών τάσεων**

Στην τρέχουσα ενότητα παρουσιάζεται η διαδικασία συλλογής και ανάλυσης πρωτογενών δεδομένων στην Ελλάδα, σχετικά με τις σύγχρονες τάσεις στην αγορά εργασίας. Το πρώτο αυτό σκέλος της μελέτης είναι κρίσιμο για τη διαμόρφωση μακροχρόνιας στρατηγικής σε έναν οργανισμό. Συνδυαστικά με τα ευρήματα από το δεύτερο σκέλος της μελέτης (*Κεφάλαιο 5*), καθίσταται εφικτή η κατανόηση των συνθηκών τόσο εντός όσο και εκτός του εργασιακού περιβάλλοντος μιας εταιρείας. Η εμβάθυνση στα δύο αυτά επίπεδα, συνεπώς, αποσκοπεί να τροφοδοτήσει τον οργανισμό με στρατηγικές έλξης (talent acquisition) και διακράτησης (talent retention) προσωπικού, μειώνοντας ορισμένα από τα πιο διαχρονικά και δαπανηρά κόστη του.

### **4.1 Προφίλ δείγματος**

Η συλλογή των πρωτογενών δεδομένων ολοκληρώθηκε με τη βοήθεια του προαναφερθέντος ερωτηματολογίου που αποτελείται από 33 σύντομες υποχρεωτικές ερωτήσεις. Απευθύνεται αποκλειστικά σε εργαζόμενους γραφείου και πνευματικής εργασίας (white-collar workers) που δραστηριοποιούνται στην ελληνική αγορά. Δομήθηκε με στόχο την ολοκλήρωση του σε περίπου 5-10 λεπτά για να μην κουράζει τους συμμετέχοντες, με ερωτήσεις που εστιάζουν στην καταγραφή απόψεων και συμπεριφορών.

Οι κλίμακες που παρέχονται στις επιλογές απάντησης κάθε ερώτησης έχουν ξεκάθαρες μονάδες μέτρησης (π.χ. έτη, μήνες, μέρες), διασφαλίζοντας έτσι ακρίβεια στην ποιότητα των δεδομένων. Επιπροσθέτως, οι απαντήσεις του συλλέχθηκαν με πλήρη ανωνυμία και τα δεδομένα

χρησιμοποιήθηκαν αποκλειστικά για στατιστική ανάλυση στο πλαίσιο της παρούσας ακαδημαϊκής μελέτης, τηρώντας όλες τις διατάξεις του Ευρωπαϊκού Κανονισμού Προστασίας Δεδομένων (GDPR).

Πέραν των ερωτήσεων δημογραφικού χαρακτήρα, ενσωματώθηκαν ερωτήσεις συμπεριφορικού τύπου (π.χ. «Πόσους εργοδότες έχετε αλλάξει κατά την τελευταία 5ετία;») και αποτύπωσης αντιλήψεων (π.χ. «Αισθάνεστε ότι η προσπάθειά σας ανταμείβεται δίκαια;»). Ο απώτερος στόχος της χρήσης ερωτήσεων τέτοιας φύσης είναι η σαφέστερη χαρτογράφηση των απαιτήσεων, των προσδοκιών και των τακτικών που επιστρατεύουν οι εργαζόμενοι ανά ηλικιακή ομάδα, προσφέροντας στη διοίκηση τα απαραίτητα εφόδια για τον σχεδιασμό ενός στρατηγικού πλάνου αντιμετώπισης της εθελούσιας αποχώρησης (attrition) και ενίσχυσης της ελκυστικότητας του οργανισμού.

#### 4.1.1 Περιγραφή περιεχομένων ερωτηματολογίου

Όπως εξηγήθηκε στο *Υποκεφάλαιο 3.1.1*, το ερωτηματολόγιο χωρίζεται σε ερωτήσεις τεσσάρων σκελών. Πέραν των ερωτήσεων δημογραφικής φύσης περιέχει ερωτήσεις για την κατανόηση των τάσεων γύρω από τις τακτικές Job Hopping και Quiet Quitting, αλλά και των τάσεων ευεξίας και πρόθεσης αποχώρησης των εργαζομένων. Ακολουθούν οι αριθμημένες ερωτήσεις του ερωτηματολογίου για κάθε σκέλος ξεχωριστά, με εικόνες του πλήρους ερωτηματολογίου στο Παράρτημα II.

1. Φύλο : (Ανδρας, Γυναίκα, Άλλο)
2. Ηλικιακή Ομάδα : (18-25, 26-41, 42-57, 58+ )
3. Επίπεδο Εκπαίδευσης : (Δευτεροβάθμια Εκπαίδευση, Πτυχίο ΑΕΙ-ΤΕΙ, Μεταπτυχιακό Δίπλωμα, Διδακτορικό Δίπλωμα)
4. Εργάζεστε ως "White-Collar Worker" σε έναν εργοδότη ή παραπάνω από έναν; : (Δεν είμαι White-Collar Worker, Δουλεύω σε έναν εργοδότη, Δουλεύω σε παραπάνω από έναν εργοδότη)
5. Κλάδος Απασχόλησης : (Τεχνολογία & Πληροφορική, Οικονομικά, Τράπεζες & Ασφάλειες, Μάρκετινγκ & Επικοινωνία, Ανθρώπινο Δυναμικό (HR), Διοικητική Υποστήριξη, Πωλήσεις & Εξυπηρέτηση Πελατών, Άλλο)
6. Ιεραρχικό Επίπεδο Θέσης : (Entry Level, Mid-level, Senior, Management, Executive)
7. Μέγεθος Εταιρείας : (Πολύ μικρή [έως 10 άτομα], Μικρομεσαία [11-250 άτομα], Μεγάλη - Πολυεθνική [250+ άτομα])
8. Συνολική Εργασιακή Εμπειρία (σε έτη) : (0-2, 3-5, 6-10, 11-20, 20+)
9. Χρόνος Παραμονής στον Τρέχοντα Εργοδότη : (Λιγότερο από 1 έτος, 1-2 έτη, 3-5 έτη, Πάνω από 5 έτη)
10. Ικανοποίηση από την τρέχουσα εργασία : (Κλίμακα 1 [Καθόλου] έως 5 [Πάρα πολύ])
11. Ικανοποίηση από τις τρέχουσες οικονομικές απολαβές : (Κλίμακα 1 [Καθόλου] έως 5 [Πάρα πολύ])
12. Ιδανικό μέγιστο διάστημα παραμονής σε έναν εργοδότη : (Λιγότερο από 1 έτος, 1-2 έτη, 3-5 έτη, Πάνω από 5 έτη)
13. Συχνότητα ενημέρωσης επαγγελματικού προφίλ / παρακολούθησης αγγελιών : (Πολύ σπάνια, Κάθε χρόνο, Κάθε 6 μήνες, Κάθε 3 μήνες, Κάθε μήνα, Κάθε εβδομάδα ή πιο συχνά)
14. Συχνότητα σκέψης αλλαγής εργοδότη : (Δεν το σκέφτομαι, Κάθε χρόνο, Κάθε 6 μήνες, Κάθε 3 μήνες, Κάθε μήνα, Κάθε εβδομάδα)
15. Γνώση του όρου "Job Hopping" : (Ναι, Όχι)

16. Βαθμός χρησιμότητας/όφελους του Job Hopping για τον εργαζόμενο : (Κλίμακα 1 [Καθόλου ωφέλιμη] έως 5 [Πολύ ωφέλιμη])
17. Προσωπική εφαρμογή της πρακτικής Job Hopping στο παρελθόν : (Ναι, Όχι)
18. Επιθυμία αλλαγής εργοδότη στην παρούσα χρονική στιγμή (Εξαρτημένη Μεταβλητή) : (Ναι, Όχι)
19. Αριθμός αλλαγής εργοδοτών κατά την τελευταία 5ετία : (0, 1, 2, 3+)
20. Αίσθηση δίκαιης ανταμοιβής (οικονομικά ή ηθικά) : (Καθόλου, Λίγο, Μέτρια, Πολύ, Πάρα πολύ)
21. Συχνότητα καταβολής της ελάχιστης δυνατής προσπάθειας για διατήρηση της θέσης : (Δεν το κάνω, Πολύ σπάνια, Σπάνια, Μέτρια, Συχνά, Πολύ συχνά)
22. Σκέψη αλλαγής εργοδότη το τελευταίο τρίμηνο η οποία αποτράπηκε λόγω ασύμφορων συνθηκών αποχώρησης : (Ναι, Όχι)
23. Προσωπική εφαρμογή της πρακτικής "Quiet Quitting" : (Ναι, Όχι, Δεν ξέρω - Δεν απαντώ)
24. Βαθμός οφέλους του Quiet Quitting για τον εργαζόμενο (π.χ. ψυχική υγεία) : (Κλίμακα 1 [Πολύ λίγο] έως 5 [Πάρα πολύ])
25. Τρέχον μοντέλο εργασίας : (Δια ζώσης [On-Site], Τηλεργασία [Remote], Υβριδικό [Hybrid])
26. Προτιμώμενο μοντέλο εργασίας (αν υπήρχε επιλογή) : (Δια ζώσης [On-Site], Τηλεργασία [Remote], Υβριδικό [Hybrid])
27. Συχνότητα εργασίας εκτός του συμβατικού ωραρίου (ημέρες ανά έτος) : (Πολύ λίγο [1-15 μέρες], Λίγο [16-30 μέρες], Μέτρια [31-60 μέρες], Πολύ [61-90 μέρες], Πάρα πολύ [91+ μέρες])
28. Συχνότητα αίσθησης συναισθηματικής εξάντλησης στο τέλος της ημέρας : (Πολύ λίγες φορές τον χρόνο, Λίγες φορές τον χρόνο, Μέτρια συχνότητα, Πολλές φορές τον χρόνο, Πάρα πολλές φορές τον χρόνο)
29. Επίπεδο βιωματικού εργασιακού άγχους (stress) στην καθημερινότητα : (Καθόλου έντονο, Λίγο έντονο, Μέτρια έντονο, Πολύ έντονο, Πάρα πολύ έντονο)
30. Βαθμός σύνδεσης του άγχους με το εφαρμοζόμενο μοντέλο εργασίας : (Δεν ξέρω - Δεν απαντώ, Καμία σύνδεση μεταξύ τους, Ελάχιστη σύνδεση, Μέτρια σύνδεση, Άμεση σύνδεση)
31. Αντίληψη έμπρακτου ενδιαφέροντος του εργοδότη για την ευεξία (well-being) των υπαλλήλων : (Δεν ξέρω, Δεν ενδιαφέρεται, Λίγο ενδιαφέρον, Μέτριο ενδιαφέρον, Ενδιαφέρεται, Πολύ ενδιαφέρον)
32. Βαθμός ιεράρχησης της εργασίας σε σχέση με την προσωπική ζωή : (Κλίμακα 1 [Πολύ χαμηλά] έως 5 [Πολύ υψηλά])
33. Πιθανότητα αλλαγής εργοδότη εντός των επόμενων 12 μηνών : (Κλίμακα 1 [Απίθανο] έως 5 [Πολύ πιθανό])

Οι παραπάνω ερωτήσεις θα παράξουν τρία είδη μεταβλητών. Συγκεκριμένα: Ονομαστικές Κατηγορικές μεταβλητές (ερωτήσεις 1, 4, 5, 15, 17, 18, 22, 23, 25, 26), Τακτικές Κατηγορικές μεταβλητές (ερωτήσεις 2, 3, 6, 7, 8, 9, 10, 11, 16, 24, 32, 33, 12, 13, 14, 20, 21, 27, 28, 29, 30, 31) και μία Διακριτή Ποσοτική μεταβλητή (ερώτηση 19).

#### 4.1.2 Περιγραφή συλλεχθέντων δεδομένων και προεπεξεργασία

Η συλλογή των δεδομένων απέδωσε ένα αρχικό δείγμα 120 αποκρίσεων, μέγεθος το οποίο κρίθηκε επαρκές για την εξαγωγή ουσιαστικών συμπερασμάτων αναλογικά με τους χρονικούς

περιορισμούς της μελέτης. Τα δεδομένα αποθηκεύτηκαν σε αρχείο μορφής .csv για λόγους συμβατότητας και βέλτιστης επεξεργασίας μέσω της γλώσσας προγραμματισμού Python.

Επειδή κάθε στήλη του αρχικού αρχείου έφερε ως τίτλο ολόκληρο το κείμενο της εκάστοτε ερώτησης, κρίθηκε απαραίτητη η μετονομασία και των 33 στηλών σε βραχύτερους κωδικούς (π.χ. q1, q2) για την υποβοήθηση της προγραμματιστικής διαχείρισης. Η διαδικασία αυτή υλοποιήθηκε μέσω της εφαρμογής ενός δομημένου λεξικού αντιστοίχισης (mapping dictionary), δείγμα του οποίου παρουσιάζεται στις παρακάτω εικόνες:

```
renaming = {  
    '1. Φύλο': 'q1_gender',  
    '2. Ηλικιακή Ομάδα': 'q2_age_group',  
    '3. Επίπεδο Εκπαίδευσης': 'q3_education_level',  
    '4. Εργάζεστε, ως "White-Collar Worker" (Εργαζόμενος γραφείου/πνευματική
```

*Εικόνα 1 – Παράδειγμα Renaming dictionary*

```
# renaming based on the "renaming" dictionary  
dataset = dataset.rename(columns=renaming)  
print(dataset.info())
```

*Εικόνα 2 - Renaming χρησιμοποιώντας το dictionary*

Στο επόμενο στάδιο πραγματοποιήθηκε έλεγχος για τον εντοπισμό ελλειπόν τιμών (missing values). Παρά τον υποχρεωτικό χαρακτήρα των ερωτήσεων, στη μεταβλητή του κλάδου απασχόλησης (q5\_industry) εντοπίστηκαν επτά κενές εγγραφές. Για την αποφυγή απώλειας της πληροφορίας των υπόλοιπων απαντήσεων των συγκεκριμένων παρατηρήσεων, οι κενές τιμές αντικαταστάθηκαν με την κατηγορία «Άλλο».

Επιπλέον, πραγματοποιήθηκε φιλτράρισμα των δεδομένων με βάση τη μεταβλητή ελέγχου q4\_white\_collar\_status. Καθώς η έρευνα εστιάζει αποκλειστικά σε white-collar εργαζόμενους, απομακρύνθηκαν από το τελικό δείγμα όλες οι παρατηρήσεις που έφεραν την τιμή «Δεν είμαι White-Collar Worker», διασφαλίζοντας έτσι τη καθαρότητα του εξεταστέου πληθυσμού.

Κατά την αρχική περιγραφική οπτικοποίηση των δεδομένων, διαπιστώθηκε ότι η μεταβλητή q5\_industry παρουσίαζε έντονο πρόβλημα πολυδιασπασιμότητας, περιλαμβάνοντας αρχικά 40 διαφορετικές καταγραφές. Πολλές εξ αυτών περιέγραφαν τον ίδιο κλάδο με διαφορετική διατύπωση, ενώ αρκετές αποτελούσαν συνδυασμούς κλάδων (π.χ. «Ανθρώπινο Δυναμικό (HR), Πωλήσεις & Εξυπηρέτηση Πελατών»). Η μείωση των κατηγοριών κρίθηκε απαραίτητη, καθώς η υψηλή διασπορά θα διάβρωνε την αξιοπιστία των μετέπειτα στατιστικών ελέγχων και του αλγορίθμου συσταδοποίησης (clustering).

Για την εξομάλυνση του προβλήματος επιστρατεύτηκαν Regular Expressions (regex) στην Python, μέσω των οποίων εντοπίστηκαν κοινά μοτίβα και απομονώθηκαν τρεις νέοι, διακριτοί κλάδοι με σημαντική συχνότητα: ο Δημόσιος Τομέας, οι Δικηγορικές Υπηρεσίες και ο τομέας

Υγείας/Φαρμακευτικών. Παράλληλα, οι συνδυαστικές απαντήσεις απλοποιήθηκαν με βάση την αξιολόγηση της εννοιολογικής βαρύτητας των συνιστωσών τους. Για παράδειγμα, η καταγραφή «Διοικητική Υποστήριξη, Πωλήσεις & Εξυπηρέτηση Πελατών» κατηγοριοποιήθηκε ως «Διοικητική Υποστήριξη», θεωρώντας ότι περιγράφει διοικητική θέση εντός του τμήματος πωλήσεων.

Επιπροσθέτως, ακολουθώντας τη μεθοδολογική προσέγγιση του Kuhn (Kuhn & Kjell, 2019), όταν μια κατηγορική μεταβλητή εμφανίζει μεγάλο πλήθος κλάδων, ενδείκνυται η ομαδοποίηση των χαμηλής συχνότητας παρατηρήσεων σε μια κοινή κατηγορία. Μετά την πρώτη φάση σύμπτυξης (που μείωσε τις κατηγορίες από 40 σε 15), υπολογίστηκε η σχετική συχνότητα εμφάνισης της καθεμίας. Όσες κατηγορίες κατείχαν ποσοστό εμφάνισης μικρότερο του 2% στο δείγμα, συγχωνεύτηκαν στην ενιαία κατηγορία «Άλλο». Η διαδικασία αυτή κατέληξε στη διαμόρφωση των εξής επτά τελικών κλάδων απασχόλησης:

1. Τεχνολογία & Πληροφορική (συχνότητα εμφάνισης ~38%)
2. Άλλο (συχνότητα εμφάνισης ~13%)
3. Δημόσιος Τομέας (συχνότητα εμφάνισης ~13%)
4. Διοικητική Υποστήριξη (συχνότητα εμφάνισης ~12%)
5. Οικονομικά, Τράπεζες & Ασφάλειες (συχνότητα εμφάνισης ~11%)
6. Πωλήσεις & Εξυπηρέτηση Πελατών (συχνότητα εμφάνισης ~7.5%)
7. Μάρκετινγκ & Επικοινωνία (συχνότητα εμφάνισης ~2.5%)
8. Ανθρώπινο Δυναμικό (συχνότητα εμφάνισης ~2.5%)

Τέλος, παρατηρήθηκε ότι στη μεταβλητή q8 κάποιες τιμές αλλοιώθηκαν κατά τη μετατροπή του αρχείου σε μορφή csv. Συγκεκριμένα επηρεάστηκαν οι ακόλουθες τιμές: ('6-10' σε '10-Jun', '3-5' σε '5-Mar' & '11-20' σε '20-Nov'). Η επίλυση του προβλήματος πραγματοποιήθηκε με ένα λεξικό αντιστοίχισης και την συνάρτηση replace( ) όπως φαίνεται παρακάτω:

```
#q8_total_experience column got it's content's converted accidentally during the
initial csv file conversion, and contains some dates instead of year ranges (ex.
10-Jun instead of 6-10)
#the following dictionary map will fix the issue:
q8_fix_mapping = {
    '10-Jun': '6-10',
    '5-Mar': '3-5',
    '20-Nov': '11-20'
}
#using the replace function for this action
dataset['q8_total_experience'] = dataset['q8_total_experience'].replace
(q8_fix_mapping)
```

Εικόνα 3 - Διόρθωση q8

## 4.2 Μονομετάβλητη ερευνητική ανάλυση δεδομένων – EDA

Προχωρώντας στο στάδιο της εξερεύνησης του συνόλου δεδομένων του ερωτηματολογίου, θα δοθεί έμφαση στην κατανόηση των συσχετίσεων μεταξύ των δεδομένων. Το πρώτο βήμα του σταδίου, η μονομετάβλητη ανάλυση στις μεταβλητές του συνόλου, θα γίνει με την βοήθεια οριζοντίων ραβδογραμμάτων. Η επιλογή του εν λόγω γραφήματος κρίθηκε σωστή βάσει της φύσης των μεταβλητών, οι οποίες είναι κυρίως κατηγορικές. Η εξαίρεση (ερώτηση 19), παρά την ποσοτική της φύση, αποτελείται από τέσσερις ξεχωριστές τιμές. Συνεπώς, θα αντιμετωπιστεί και αυτή ως κατηγορική για εύκολη οπτικοποίηση.

Με την βοήθεια των Python βιβλιοθηκών Seaborn και Matplotlib δημιουργήθηκαν τα εν λόγω οριζόντια ραβδογράμματα κάθε ταξινομημένης μεταβλητής, παραλείποντας την στήλη Timestamp, καθώς δεν προσφέρει κάποια σημασιολογική αξία. Παρακάτω φαίνεται ο κώδικας που χρησιμοποιήθηκε:

```
def column_distributions(dataset):
    ds_cols = dataset.columns
    for col in ds_cols:
        if col != 'Timestamp':
            plt.figure(figsize=(10, 6))


            # the below code will help ordering the plots
            row_order = dataset[col].value_counts().index
            #normalizing the data too to know the percentages each category occupies
            normalized_data = dataset[col].value_counts(normalize=True)
            print(f'Normalized frequencies of column:', normalized_data)
            # creating the plots horizontally
            sb.countplot(
                y=col,
                hue=dataset[col],
                data=dataset,
                order=row_order,
                palette='Blues_r' # using Blues_r to have the most frequent
                                categories with the deeper hue of blue
            )
            plt.title(f'Distribution of Column : {col}', fontsize=14, pad=15)
            plt.xlabel('Count', fontsize=12)
            plt.ylabel('Industry', fontsize=12)
            plt.tight_layout()
            plt.show()

column_distributions(dataset)
```


Εικόνα 4 - Μέθοδος οπτικοποίησης των μεταβλητών

### 4.2.1 Δημογραφικά στοιχεία και χαρακτηριστικά απασχόλησης


Ύστερα έχουν σειρά μερικά από τα κύρια ραβδογράμματα δημογραφικής φύσης:




Εικόνα 5 - Age group



Εικόνα 6 - Industry



Εικόνα 7 - Job Level



Εικόνα 8 - Current Work Model

(Σημείωση: Περαιτέρω φωτογραφίες των αποτελεσμάτων θα βρίσκονται στο Παράρτημα. Ο κώδικας βρίσκεται στο Github, βλ. Παράρτημα II)

Από την περιγραφική ανάλυση των παραχθέντων δημογραφικών διαγραμμάτων προκύπτει ένα ενδιαφέρον προφίλ για τους συμμετέχοντες της έρευνας. Αρχικά το δείγμα παρουσιάζει μια σχετικά ισορροπημένη κατανομή με μια ελαφριά επικράτηση των ανδρών, οι οποίοι αποτελούν το ~58% του συνόλου, έναντι ~41% των γυναικών (βλ. Παράρτημα III). Παράλληλα, καταγράφεται μια έντονη πόλωση στην ομάδα των 26-41 ετών, η οποία αγγίζει το 55% του δείγματος, ενώ ακολουθεί η ηλικιακή ομάδα των 42-57 ετών με ποσοστό ~26%. Οι νεότεροι (18-25) και οι μεγαλύτεροι σε ηλικία εργαζόμενοι (58+) περιορίζονται σε χαμηλότερα ποσοστά (~11% και ~8% αντίστοιχα).

Σχετικά με τα επαγγελματικά χαρακτηριστικά, η πλειοψηφία των ερωτηθέντων δραστηριοποιείται στον κλάδο της Τεχνολογίας και της Πληροφορικής (~39%), γεγονός που αναδεικνύει την έντονη εκπροσώπηση των digital white-collar εργαζομένων στη μελέτη και ερμηνεύει εν μέρει την προαναφερθείσα υπεροχή του ανδρικού φύλου στο δείγμα. Αναφορικά με την ιεραρχική βαθμίδα, το μεγαλύτερο μέρος του δείγματος καταλαμβάνει θέσεις μεσαίου επιπέδου (Mid-Level,




~45%), ενώ οι εισαγωγικές θέσεις (Entry Level) ακολουθούν με 22%. Η κατανομή αυτή της ιεραρχίας ερμηνεύεται πιο ολοκληρωμένα αν συνδυαστεί με τα ευρήματα της συνολικής εργασιακής εμπειρίας (μεταβλητή q8, βλ. *Παράρτημα III*). Εδώ παρατηρείται μια ενδιαφέρουσα πολυδιασπορά. Η επικρατούσα κατηγορία αφορά στελέχη με υψηλή προϋπηρεσία άνω των 20 ετών (~29%), ενώ ακολουθεί η ομάδα με 6-10 έτη εμπειρίας (~23%). Ταυτόχρονα όμως, οι νεότεροι επαγγελματίες με προϋπηρεσία έως 5 έτη (0-2 και 3-5 έτη) συγκεντρώνουν αθροιστικά το ~35% του δείγματος. Η συνύπαρξη αυτή εμπειρών στελεχών και junior εργαζομένων εξηγεί γιατί η πλειοψηφία του δείγματος ισορροπεί τελικά σε Mid-Level θέσεις ευθύνης.


Ένα από τα πιο αξιοσημείωτα ευρήματα της μονομεταβλητής ανάλυσης αφορά το εφαρμοζόμενο μοντέλο εργασίας. Παρά την ισχυρή παρουσία του κλάδου της Πληροφορικής, ο οποίος παραδοσιακά συνδέεται με την εξ αποστάσεως εργασία, η πλειοψηφία των συμμετεχόντων δήλωσε ότι εργάζεται αποκλειστικά δια ζώσης (On-Site, ~58%), με το υβριδικό μοντέλο (Hybrid) να ακολουθεί ως δεύτερη επιλογή με 28%. Η συγκεκριμένη συνθήκη αποτυπώνει πλήρως την υφιστάμενη κατάσταση στην ελληνική αγορά εργασίας, όπου η φυσική παρουσία στο γραφείο παραμένει κυρίαρχη απαίτηση για μεγάλο μέρος των εργοδοτών.

#### 4.2.2 Απόψεις/συμπεριφορές σχετικά με την τάση Job Hopping

Στην συνέχεια θα ακολουθήσει η μονομετάβλητη ανάλυση των μεταβλητών που αφορούν στην τάση του Job Hopping (μεταβλητές q9, q12-q17 και q19). Μέσα από τη συνδυαστική ανάλυση των κύριων διαγραμμάτων και των συμπληρωματικών στοιχείων του Παραρτήματος, επιχειρείται μια χαρτογράφηση των αντιλήψεων και των συνηθειών των Ελλήνων white-collar εργαζομένων.




Εικόνα 9 – Ideal Stay Duration




Εικόνα 10 - Job Hopping Benefit

Τα Διαγράμματα των *Εικονών 9 & 10* αποτυπώνουν τις επικρατούσες απόψεις του δείγματος. Αρχικά, διαπιστώνεται ότι η συντριπτική πλειοψηφία των συμμετεχόντων είναι εξοικειωμένη με την έννοια, καθώς το 73% δηλώνει ότι γνωρίζει τον όρο Job Hopping (μεταβλητή q15, βλ. *Παράρτημα III*). Επιπλέον, η τάση αξιολογείται θετικά, με το ~48% να τη θεωρεί «πολύ έως πάρα πολύ ωφέλιμη» (q16, βαθμολογία 4-5 συλλογικά στην κλίμακα Likert) και το 35% «μέτρια ωφέλιμη» (βαθμολογία 3). Μόλις το 16% του δείγματος την αποτιμά αρνητικά ή ελάχιστα, γεγονός που υποδηλώνει ότι οι εργαζόμενοι στην Ελλάδα αναγνωρίζουν το Job Hopping ως μια αξιόλογη στρατηγική ανέλιξης στο σύγχρονο εργασιακό περιβάλλον.

Ωστόσο, οι πεποιθήσεις αυτές έρχονται σε ενδιαφέρουσα αντιδιαστολή με τις προσδοκίες σταθερότητας, όπως αυτές αποτυπώνονται στη μεταβλητή q12 (ιδανικό διάστημα παραμονής σε έναν εργοδότη). Εδώ, η πλειοψηφία του δείγματος (~55%) θεωρεί ως ιδανικό διάστημα τα 3-5 έτη, ενώ ένα επιπλέον ~28% προκρίνει την παραμονή για διάστημα άνω των 5 ετών. Το εύρημα αυτό υποδεικνύει ότι, παρά την αναγνώριση των πλεονεκτημάτων της συχνής αλλαγής εργασίας, ο μέσος Έλληνας επαγγελματίας εξακολουθεί να αξιολογεί θετικά τη μεσοπρόθεσμη δέσμευση, πιθανώς σταθμίζοντας την ανάγκη για εμβάθυνση στην εργασιακή εμπειρία και τη διατήρηση ενός σταθερού και «συμπαγούς» βιογραφικού σημειώματος.



Εικόνα 11 - Profile update frequency



Εικόνα 12 - Job hopping history

Στη συνέχεια, η ανάλυση εστιάζει στις μεταβλητές συμπεριφοράς (q9, q13, q14, q17 και q19), προκειμένου να εξεταστεί κατά πόσο οι παραπάνω απόψεις μετουσιώνονται σε πράξη. Αναφορικά με την τρέχουσα κατάσταση (μεταβλητή q9, βλ. *Παράρτημα III*), παρατηρείται μια σχετικά ισορροπημένη κατανομή: η επικρατούσα κατηγορία αφορά όσους εργάζονται στον ίδιο εργοδότη για περισσότερα από 5 έτη (~32%), ακολουθούμενη από εκείνους με διάρκεια παραμονής 3-5 ετών (~24%). Το υπόλοιπο ~44% αφορά εργαζόμενους με βραχύτερη θητεία (έως 3 έτη).


Παρά το γεγονός ότι ένα σημαντικό ποσοστό εμφανίζει μακροχρόνια παραμονή, τα ευρήματα της μεταβλητής q13 δείχνουν ότι οι εργαζόμενοι διατηρούν τα αντανακλαστικά τους ενεργά στην αγορά. Αν και η επικρατούσα τιμή εντοπίζεται στην επιλογή «Πολύ σπάνια» (~43%) όσον αφορά την ανανέωση του επαγγελματικού προφίλ (π.χ. LinkedIn), ένα ισχυρό ~41% του συνόλου δηλώνει ότι προβαίνει σε αναβάθμιση του προφίλ του κάθε έξι μήνες ή και συχνότερα (συνδιαστικές απαντήσεις), επιβεβαιώνοντας μια διαρκή ετοιμότητα για τον εντοπισμό νέων ευκαιριών. Η τάση αυτή ενισχύεται και από τη μεταβλητή q14 (βλ. *Παράρτημα III*), όπου το ~42% του δείγματος παραδέχεται ότι σκέφτεται να αλλάξει εργοδότη σε εξαμηνιαία (ή και συχνότερη) βάση, ενώ το ~20% το σκέφτεται σε ετήσια βάση.

Σε επίπεδο πραγματικής εφαρμογής, ωστόσο, καταγράφεται μια απόκλιση. Στη μεταβλητή q17, η συντριπτική πλειοψηφία (~73%) δηλώνει ότι δεν έχει εφαρμόσει ποτέ συνειδητά την πρακτική του Job Hopping. Επιπλέον, στη μεταβλητή q19 (αριθμός αλλαγών εργοδότη την τελευταία πενταετία), το ~45% των ερωτηθέντων δεν έχει αλλάξει εργασιακό περιβάλλον, ενώ το ~20% έχει πραγματοποιήσει μία μόνο αλλαγή. Αντιθέτως, το υπόλοιπο 35% του δείγματος έχει αλλάξει δύο ή περισσότερους εργοδότες κατά την τελευταία πενταετία.

Το ποσοστό αυτό (35%) παρουσιάζει μια εντυπωσιακή σύμπτωση με το ποσοστό των εργαζομένων που αξιολόγησαν προηγούμενως την πρακτική ως ιδιαίτερα ωφέλιμη (36% στην q16). Το γεγονός αυτό υποδηλώνει ότι υπάρχει ένας σκληρός πυρήνας εργαζομένων στο δείγμα που ευθυγραμμίζει πλήρως τις πεποιθήσεις του με τις πράξεις του, εφαρμόζοντας ενεργά το Job Hopping. Για το υπόλοιπο μέρος του δείγματος, η πρόθεση ή η θετική αποτίμηση του φαινομένου φαίνεται πως αναχαιτίζεται στην πράξη, πιθανώς λόγω της ανάγκης για εργασιακή ασφάλεια.

#### 4.2.3 Απόψεις/συμπεριφορές σχετικά με την τάση Quiet Quitting


Ακολουθεί η ανάλυση των τάσεων της πρακτικής Quiet quitting. Θα πραγματοποιηθεί μονομετάβλητη ανάλυση στις μεταβλητές q21 έως 24, εστιάζοντας, όπως και στο *Κεφάλαιο 4.2.2*, τόσο σε απόψεις όσο και σε συμπεριφορές.




Εικόνα 13 - Quiet quitting benefit

Στο παραπάνω γράφημα αποτυπώνεται η αξιολόγηση του δείγματος σχετικά με τη χρησιμότητα του Quiet Quitting ως μέσου προστασίας της ψυχικής υγείας. Το ~40% των συμμετεχόντων να θεωρεί την πρακτική «πολύ έως πάρα πολύ ωφέλιμη» (βαθμολογία 4-5 στην κλίμακα Likert) και το ~29% «μέτρια ωφέλιμη» (βαθμολογία 3). Συνολικά, το ~69% του δείγματος αναγνωρίζει στην τάση αυτή τουλάχιστον μέτριο βαθμό ωφελιμότητας.


Παρ' όλα αυτά, αν συγκριθεί το εύρημα αυτό με την αντίστοιχη αποτίμηση του Job Hopping (όπου το 71% του δείγματος τη θεωρούσε από μέτρια έως πάρα πολύ ωφέλιμη), παρατηρείται ότι οι Έλληνες white-collar εργαζόμενοι εμφανίζουν μια ελαφρώς μεγαλύτερη επιφυλακτικότητα απέναντι στη σιωπηρή παραίτηση. Το γεγονός αυτό υποδηλώνει ότι, αν και αναγνωρίζεται η αξία της για τη διατήρηση των προσωπικών ορίων, η πιο δυναμική και ενεργητική στρατηγική της αλλαγής εργοδότη (Job Hopping) προκρίνεται ως ελκυστικότερη ή πιο αποτελεσματική επιλογή στην παρούσα φάση της αγοράς.



Εικόνα 14 - Retention due to cost



Εικόνα 15 - Quiet quitting history



Εικόνα 16 - Minimum effort frequency

Περνώντας στις μεταβλητές που καταγράφουν την πραγματική συμπεριφορά, γίνεται σαφές ότι η πλειοψηφία του δείγματος επιλέγει συνειδητά να μην εφαρμόσει τη συγκεκριμένη πρακτική. Ειδικότερα, το ~63% των ερωτηθέντων δηλώνει κατηγορηματικά ότι δεν έχει εφαρμόσει ποτέ το Quiet Quitting (μεταβλητή q23). Η στάση αυτή επιβεβαιώνεται ανάγλυφα και από τη μεταβλητή q21, η οποία εξετάζει τη συχνότητα καταβολής της ελάχιστης δυνατής προσπάθειας (εργασιακή αποστασιοποίηση). Το ~28% δηλώνει ότι δεν προβαίνει ποτέ σε μια τέτοια ενέργεια, ενώ ένα επιπλέον ~32% δηλώνει ότι το πράττει «σπάνια έως πολύ σπάνια». Συνεπώς, ένα ισχυρό πλειοψηφικό ρεύμα της τάξης του ~60% διατηρεί υψηλά τα επίπεδα της επαγγελματικής του δέσμευσης. Απεναντίας, σε συνθήκες συστηματικής σιωπηρής παραίτησης («συχνά έως πολύ συχνά») κινείται μόλις το ~21% του δείγματος, ενώ το ~19% εμφανίζει μέτρια συχνότητα.


Μια ιδιαίτερα ενδιαφέρουσα τροπή στην ανάλυση εισάγει η μεταβλητή q22, η οποία λειτουργεί ως συνδετικός κρίκος. Το ~54% του δείγματος παραδέχεται ότι σκέφτηκε σοβαρά να αλλάξει εργοδότη κατά το τελευταίο τρίμηνο, αλλά τελικά απέιχε από μια τέτοια ενέργεια καθώς έκρινε ότι η άμεση αποχώρηση δεν θα ήταν οικονομικά ή επαγγελματικά συμφέρουσα. Στη διεθνή βιβλιογραφία, αυτή η συνθήκη περιγράφεται ως μια κατάσταση «αναγκαστικού εγκλωβισμού» ή υψηλής εργασιακής κατάρτησης, όπου οι εργαζόμενοι παραμένουν σε έναν οργανισμό όχι λόγω συναισθηματικής

δέσμευσης, αλλά επειδή το κόστος της αποχώρησης (θυσία κεκτημένων, οικονομική αβεβαιότητα) κρίνεται απαγορευτικό (Hom, Allen, & Griffith, 2019).


Ενώ θεωρητικά αυτός ο εγκλωβισμός αποτελεί τον κυριότερο κίνητρο που ωθεί τους εργαζόμενους στη μείωση της απόδοσής τους και στη σιωπηρή παραίτηση, στην περίπτωση του ελληνικού δείγματος παρατηρείται ένα παράδοξο. Παρά το γεγονός ότι η τάση για αποχώρηση αναχαιτίζεται λόγω συγκυριών (~54%), η πρακτική του Quiet Quitting τελικά δεν υιοθετείται στην πράξη (~63% άρνηση εφαρμογής). Αυτό υποδηλώνει ότι ο μέσος Έλληνας εργαζόμενος, ακόμη και υπό καθεστώς πίεσης ή επαγγελματικής στασιμότητας, αποτρέπει από το να μειώσει την απόδοσή του. Η συμπεριφορά αυτή μπορεί να αποδοθεί τόσο σε εξωτερικούς, πιεστικούς παράγοντες (π.χ. αυξανόμενο κόστος ζωής, οικογενειακές υποχρεώσεις κ.ο.κ.) όσο και σε εσωτερικά χαρακτηριστικά της εγχώριας εργασιακής κουλτούρας, όπου η προσωπική φιλοδοξία και η ανάγκη για συνεχή επαγγελματική εξέλιξη αποτρέπουν την παθητική στάση.

#### 4.2.4 Απόψεις/συμπεριφορές σχετικά με την τάση για ευεξία

Στο τελικό αυτό υποκεφάλαιο της μονομετάβλητης ανάλυσης θα γίνει εστίαση στις ερωτήσεις/μεταβλητές ευεξίας και burnout (q10, q11, q20, q26-q33). Ταυτοχρόνως, θα αναλυθούν μερικά από τα πιο κρίσιμα σχετικά γραφήματα των εν λόγω μεταβλητών. Οι ερωτήσεις αυτές εστιάζουν περισσότερο στις κλασικές πτυχές του HR Analytics, προσφέροντας τα θεμέλια για την σύγκριση και, ύστερα, τη γεφύρωση των νέων τάσεων με την ήδη υπάρχουσα βιβλιογραφία. Ερωτήσεις όπως η q10 (ικανοποίηση από τρέχουσα εργασία), η q11 (οικονομική ικανοποίηση) και η q31 (ενδιαφέρον από εργοδότη) αντιπροσωπεύουν κλασικούς παράγοντες ώθησης και έλξης (βλ. Κεφάλαιο 2.2.1).



Εικόνα 17 - Job Satisfaction



Εικόνα 18 - Financial Satisfaction

Εξετάζοντας αρχικά τις Εικόνες 17 και 18, παρατηρείται μια παρόμοια τάση κατανομής μεταξύ της γενικής εργασιακής ικανοποίησης (q10) και της οικονομικής ικανοποίησης (q11). Η παράλληλη αυτή πορεία υποδηλώνει μια ισχυρή θετική συσχέτιση μεταξύ των δύο εννοιών. Αυτή η σχέση αποτελεί θεμελιώδη παραδοχή στη βιβλιογραφία του Turnover (Hom, Allen, & Griffith, 2019) και θα ελεγχθεί στατιστικά στη διμεταβλητή ανάλυση που θα ακολουθήσει στην πορεία.


Αναλυτικότερα, το ~39% των συμμετεχόντων δηλώνει «πολύ ικανοποιημένο» (βαθμολογία 4 στην κλίμακα Likert) από την τρέχουσα εργασία του, ενώ το ~17% δηλώνει «πάρα πολύ

ικανοποιημένο» (βαθμολογία 5). Αντιθέτως, μόλις ένα συλλογικό ~12% εκφράζει χαμηλή έως μηδαμινή ικανοποίηση (βαθμολογίες 1-2), με το υπόλοιπο ~30% να τοποθετείται ουδέτερα («μέτρια ικανοποίηση»).


Στο πεδίο των οικονομικών απολαβών (q11), το ~35% δηλώνει ικανοποιημένο (βαθμολογία 4) και το ~15% απόλυτα ικανοποιημένο (βαθμολογία 5). Οι χαμηλές βαθμολογίες (1-2) συγκεντρώνουν συλλογικά το ~26% του δείγματος, ενώ η μέτρια ικανοποίηση αγγίζει το ~23%.

Η θετική αυτή τάση ενισχύεται και από τη μεταβλητή q20 (αντίληψη δίκαιης υλικής και ηθικής αμοιβής, βλ. *Παράρτημα III*), όπου καταγράφεται μια τυπική κανονική κατανομή: το 45% του δείγματος τηρεί ουδέτερη στάση (βαθμολογία 3), το ~25% νιώθει ότι αμείβεται δίκαια (βαθμολογία 4), ενώ το ~15% εκφράζει παράπονο (βαθμολογία 2). Τα ευρήματα αυτά σκιαγραφούν ένα περιβάλλον όπου οι Έλληνες white-collar εργαζόμενοι του δείγματος εμφανίζουν ικανοποιητικά επίπεδα βασικής δέσμευσης, γεγονός που θεωρητικά λειτουργεί ανασταλτικά προς την εμφάνιση σοβαρών συμπτωμάτων burnout.

Η υπόθεση αυτή φαίνεται να στηρίζεται και από τα δεδομένα της μεταβλητής q27 (συχνότητα υπερωριών, βλ. *Παράρτημα III*). Η πλειοψηφία του δείγματος εργάζεται εκτός συμβατικού ωραρίου πολύ λίγες φορές (1-15 ημέρες ετησίως, ~47%) ή λίγες φορές (16-30 ημέρες ετησίως, ~22%). Όπως επισημαίνουν οι Hom et al. (Hom, Allen, & Griffith, 2019), ο ελεγχόμενος φόρτος εργασίας προστατεύει τον εργαζόμενο από τους συστηματικούς στρεσογόνους παράγοντες που διαβρώνουν την ικανοποίηση.



Εικόνα 19 - Preferred work model




Εικόνα 20 - Stress level

Ωστόσο, η βαθύτερη ανάλυση των ψυχομετρικών δεικτών αποκαλύπτει μια σημαντική εσωτερική διαφοροποίηση. Στη μεταβλητή q28, το ~35% δηλώνει μέτρια συχνότητα συναισθηματικής εξάντλησης στο τέλος της ημέρας, αλλά ένα ανησυχητικό συλλογικό ~43% τη βιώνει «συχνά έως πολύ συχνά» (βαθμολογίες 4-5). Αντίθετα, στην ερώτηση q29 για το υποκειμενικό εργασιακό στρες, η κατανομή είναι σαφώς πιο ισορροπημένη (κανονική), με το ~44% να δηλώνει μέτριο στρες, το ~31% χαμηλό και μόλις το ~25% υψηλό.

Η απόκλιση αυτή μεταξύ της υψηλής συναισθηματικής εξάντλησης (~43%) και του σχετικά ελεγχόμενου καθημερινού στρες (~25%) είναι ιδιαίτερα ενδιαφέρουσα. Σύμφωνα με τη θεωρία του Burnout (Maslach & Jackson, 1981), η συναισθηματική εξάντληση αποτελεί το πρώτο και κρίσιμότερο στάδιο της εργασιακής φθοράς, η οποία συχνά αναπτύσσεται υπόγεια, ακόμη κι όταν ο εργαζόμενος νιώθει ότι διαχειρίζεται το καθημερινό του στρες. Αυτό υποδηλώνει ότι το δείγμα, παρά την «ανθεκτική» ή προσαρμοστική φύση του, υφίσταται μια μακροπρόθεσμη, σωρευτική κόπωση.

Ένας καθοριστικός παράγοντας που φαίνεται να μετριάξει ή να επηρεάζει αυτά τα επίπεδα πίεσης είναι το μοντέλο εργασίας. Το συλλογικό ~57% του δείγματος δηλώνει ότι το στρες του συνδέεται άμεσα (μέτρια έως απόλυτα) με το μοντέλο εργασίας που εφαρμόζει (μεταβλητή q30, βλ. Παράρτημα III). Το εύρημα αυτό φωτίζεται πλήρως αν συνδυαστεί με τη μεταβλητή q26 (Διάγραμμα 4.Z), όπου η συντριπτική πλειοψηφία (~60%) προκρίνει το Υβριδικό Μοντέλο ως το ιδανικό για την προσωπική του ευεξία. Σε σύγκριση με τη μεταβλητή q25 (όπου καταγράφηκε ότι η πλειοψηφία εργάζεται αυτή τη στιγμή αμιγώς Δια Ζώσης), αναδεικνύεται μια ξεκάθαρη και ανικανοποίητη ανάγκη του δείγματος για μεγαλύτερη ευελιξία και καλύτερη ισορροπία μεταξύ επαγγελματικής και προσωπικής ζωής.



Εικόνα 21 - Employer wellbeing interest

Τέλος, εξαιρετικά κρίσιμα είναι τα ευρήματα της μεταβλητής q31, η οποία εξετάζει τον βαθμό στον οποίο ο εργαζόμενος νιώθει ότι ο εργοδότης του ενδιαφέρεται πραγματικά για την ευεξία του. Το ~50% του δείγματος δηλώνει ότι ο οργανισμός δείχνει «λίγο έως καθόλου» ενδιαφέρον, ενώ το ~25% κάνει λόγο για «μέτριο» ενδιαφέρον. Η διάχυτη αυτή πεποίθηση περί οργανωσιακής αδιαφορίας συνάδει απόλυτα με τα ευρήματα του υποκεφαλαίου 4.2.2, όπου τονίζεται πως η έλλειψη μέριμνας από τη διοίκηση διαρρηγνύει το ψυχολογικό συμβόλαιο, μειώνει την εταιρική δέσμευση και ωθεί τους εργαζόμενους στο να θεωρούν το Job Hopping (~83% θετική αποτίμηση) ως τη μόνη ορθολογική διέξοδο για τη διατήρηση της προσωπικής τους ευεξίας.

Η ανάγκη αυτή για αυτόνομη προστασία της προσωπικής ευημερίας φωτίζεται ανάγλυφα από τα αποτελέσματα της μεταβλητής q32, η οποία εξετάζει τον βαθμό στον οποίο οι εργαζόμενοι ιεραρχούν την εργασία πάνω από την προσωπική τους ζωή (Work Centrality). Εδώ καταγράφεται μια σαφής απομάκρυνση από το παραδοσιακό μοντέλο της απόλυτης ταύτισης με την καριέρα. Συγκεκριμένα, μόλις το ~31% του δείγματος δηλώνει «πολύ» (βαθμολογία 4) και το ~6% «πάρα πολύ»



(βαθμολογία 5) προσηλωμένο στην ιδέα ότι η εργασία προηγείται της προσωπικής ζωής. Η κυρίαρχη τάση εμφανίζεται στην ουδέτερη βαθμίδα («μέτρια», βαθμολογία 3) με ποσοστό ~38%, ενώ ένα σημαντικό ~25% (βαθμολογίες 1-2) τοποθετείται στην αντίθετη πλευρά, υποβαθμίζοντας την κεντρικότητα της εργασίας και δίνοντας σαφή προτεραιότητα στην προσωπική και οικογενειακή ευημερία.

Ως φυσικό καταστάλαγμα όλων των παραπάνω πιέσεων (της συσσωρευμένης συναισθηματικής εξάντλησης, της έλλειψης εργοδοτικού ενδιαφέροντος και της ανάγκης για Work-Life Balance) η μεταβλητή q33 αποτυπώνει την τελική πρόθεση αποχώρησης (Turnover Intention) του δείγματος για τους επόμενους 12 μήνες. Εδώ καταγράφεται μια έντονη και αξιοσημείωτη πόλωση στο σώμα των ερωτηθέντων.

Από τη μία πλευρά, το ~41% του δείγματος δηλώνει από υψηλή έως απόλυτη ετοιμότητα να αλλάξει εργοδότη άμεσα (~17% βαθμολογία 4 και ~24% βαθμολογία 5). Από την άλλη πλευρά, ένα σχεδόν ισοδύναμο ~40% δηλώνει από ελάχιστη έως μηδενική πιθανότητα αποχώρησης (~16% βαθμολογία 2 και ~23% βαθμολογία 1), με το υπόλοιπο ~19% να διατηρεί μια ουδέτερη στάση αναμονής (βαθμολογία 3).

Η κατανομή αυτή φανερώνει ένα σαφώς διχοτομημένο δείγμα. Το ένα τμήμα των εργαζομένων, ωθούμενο από το Burnout, την αντιλαμβανόμενη αδιαφορία των οργανισμών και την άρνηση να θυσιάσει την προσωπική του ζωή στο βωμό της καριέρας, βρίσκεται ήδη με το «ένα πόδι έξω από την πόρτα». Αντίθετα, το άλλο τμήμα φαίνεται να επιλέγει τη σταθερότητα, είτε λόγω ικανοποιητικών συνθηκών είτε υπό το βάρος του «αναγκαστικού εγκλωβισμού» και των οικονομικών θυσιών που αναλύθηκαν στο μοντέλο των Hom et al. (Hom, Allen, & Griffith, 2019).

Η ανακάλυψη αυτών των δύο αντίθετων προφίλ εργαζομένων ολοκληρώνει τον κύκλο της μονομεταβλητής ανάλυσης και αποτελεί το ιδανικό έναυσμα για την διμετάβλητη ανάλυση που θα ακολουθήσει, η οποία θα επιχειρήσει να χαρτογραφήσει με ακρίβεια τις συγκεκριμένες ομάδες.

#### **4.3 Διμετάβλητη ανάλυση δεδομένων – πίνακας συσχετίσεων και ομαδοποιημένα ραβδογράμματα**

Στην τρέχουσα ενότητα πραγματοποιείται εμβάθυνση στα ευρήματα της μονομεταβλητής ανάλυσης, με σκοπό την ανάδειξη και τον στατιστικό έλεγχο των σχέσεων που διέπουν το σύνολο των μεταβλητών. Για τον σκοπό αυτό, επιστρατεύονται στατιστικές τεχνικές όπως ο Πίνακας Συσχετίσεων Spearman για τις Likert μεταβλητές, ο δείκτης Cramer's V για τις κατηγορικές μεταβλητές, καθώς και ομαδοποιημένα διαγράμματα, προκειμένου να αποκαλυφθούν εσωτερικές συνδέσεις που δεν είναι ορατές μέσω της απλής κατανομής συχνοτήτων.


Με βάση τα συμπεράσματα του Υποκεφαλαίου 4.2, διαπιστώθηκε ότι ο μέσος white-collar εργαζόμενος στην Ελλάδα βιώνει ελεγχόμενο καθημερινό στρες, αλλά παρουσιάζει υψηλά ποσοστά συσσωρευμένης συναισθηματικής εξάντλησης. Παράλληλα, καταγράφηκε μια ισχυρή ανικανοποίητη ανάγκη για ευελιξία (υβριδική εργασία), καθώς και μια γενικότερη θετική στάση απέναντι στο Job Hopping, η οποία τροφοδοτείται σε μεγάλο βαθμό από την αντιλαμβανόμενη εργοδοτική αδιαφορία. Από τις παρατηρήσεις αυτές πηγάζουν τρία κεντρικά ερευνητικά ερωτήματα, τα οποία καλείται να απαντήσει η διμεταβλητή ανάλυση:



1. Πόσο έντονα συνδέεται η προτεραιότητα διαφύλαξης της προσωπικής ζωής με το εργασιακό στρες και τη συναισθηματική εξάντληση;
2. Ποιο είναι το προφίλ των εργαζομένων που διάκεινται θετικά απέναντι στο Job Hopping και το Quiet Quitting συγκριτικά με τους πιο «παραδοσιακούς» εργαζομένους;
3. Σε ποιο βαθμό επηρεάζεται η πρόθεση αποχώρησης (Turnover Intention) από τους κλασικούς πυλώνες του HR, όπως η οικονομική και η εργασιακή ικανοποίηση;

#### 4.3.1 Πίνακας συσχετίσεων Spearman για τις Likert μεταβλητές

Για την απάντηση των ερωτημάτων αυτών, οι μεταβλητές κλίμακας Likert κωδικοποιήθηκαν σε αριθμητική μορφή και υπολογίστηκε ο μη παραμετρικός συντελεστής συσχέτισης ranking του Spearman, ο οποίος είναι ο πλέον δόκιμος για δεδομένα τακτικής κλίμακας.



Εικόνα 22 - Πίνακας συσχετίσεων Spearman

Από τον πίνακα της Εικόνας 22 προκύπτει πλήθος αξιοσημείωτων και στατιστικά σημαντικών συσχετίσεων. Αρχικά, η γενική εργασιακή ικανοποίηση (q10) και η οικονομική ικανοποίηση (q11) παρουσιάζουν ισχυρή θετική συσχέτιση ( $r = 0.56$ ), γεγονός που επιβεβαιώνει την κλασική HR

βιβλιογραφία, αποδεικνύοντας ότι η ηθική και η υλική επιβράβευση λειτουργούν συμπληρωματικά στη συνείδηση του εργαζομένου.

Ιδιαίτερο ενδιαφέρον παρουσιάζει η μεταβλητή q32, η οποία αποτυπώνει τον βαθμό στον οποίο ο εργαζόμενος ιεραρχεί την εργασία πάνω από την προσωπική του ζωή. Η αρνητική της συσχέτιση με την αποδοχή του Quiet Quitting (q24,  $r = -0.18$ ) υπογραμμίζει ότι η σιωπηρή παραίτηση αποτελεί μια συνειδητή επιλογή κυρίως για εκείνους που θέτουν σε προτεραιότητα την προσωπική τους ζωή έναντι της καριέρας. Στον αντίποδα, η q32 συνδέεται θετικά με τη συναισθηματική εξάντληση (q28,  $r = 0.15$ ), επιβεβαιώνοντας ότι η υπερβολική στοχοθέτηση γύρω από τα επαγγελματικά λειτουργεί επιβαρυντικά για την ψυχική υγεία του εργαζομένου, αυξάνοντας τον κίνδυνο Burnout.

Αναφορικά με τη συχνότητα συναισθηματικής εξάντλησης (q28), καταγράφεται αναμενόμενα ισχυρή θετική συσχέτιση με τα επίπεδα καθημερινού στρες (q29,  $r = 0.59$ ). Η εξάντληση αυτή συνδέεται επίσης θετικά με την ιεραρχία της εργασίας στην ζωή του εργαζομένου (q32,  $r = 0.15$ ), υποδηλώνοντας ότι η υψηλή επαγγελματική στοχοθέτηση εις βάρος του προσωπικού χρόνου συνυπάρχει με αυξημένη πιθανότητα εμφάνισης Burnout. Αντιθέτως, η συναισθηματική εξάντληση συνδέεται αρνητικά με την εργασιακή ( $r = -0.37$ ) και την οικονομική ικανοποίηση ( $r = -0.26$ ).

Οι πεποιθήσεις για τις νέες εργασιακές τάσεις, δηλαδή το όφελος του Job Hopping (q16) και του Quiet Quitting (q24), εμφανίζουν θετική γραμμική σχέση μεταξύ τους ( $r = 0.37$ ), υποδεικνύοντας ότι ένα μέρος του δείγματος αντιλαμβάνεται και τις δύο πρακτικές ως εξίσου έγκυρους μηχανισμούς άμυνας ή ανέλιξης στην αγορά εργασίας. Και οι δύο μεταβλητές παρουσιάζουν αρνητική συσχέτιση με την εργασιακή και οικονομική ικανοποίηση, γεγονός που μαρτυρά ότι η απογοήτευση από τον τρέχοντα εργοδότη στρέφει τους εργαζόμενους προς την αποδοχή αυτών των τάσεων.

Τέλος, η πρόθεση αποχώρησης εντός των επόμενων 12 μηνών (q33) παρέχει τα πιο ξεκάθαρα ευρήματα, καθώς εμφανίζει αξιοσημείωτη αρνητική συσχέτιση με την οικονομική ικανοποίηση (q11,  $r = -0.52$ ) και τη γενική εργασιακή ικανοποίηση (q10,  $r = -0.47$ ). Οι τιμές αυτές επιβεβαιώνουν πλήρως το μοντέλο των Hom et al. (Hom, Allen, & Griffith, 2019), αναδεικνύοντας την ικανοποίηση ως το ισχυρότερο «αντίδοτο» απέναντι στο Turnover Risk.

Στον αντίποδα, η πρόθεση φυγής συσχετίζεται θετικά με την αποδοχή του Quiet Quitting ( $r = 0.30$ ) και του Job Hopping ( $r = 0.23$ ), καθώς και με τη συναισθηματική εξάντληση ( $r = 0.20$ ). Αξιοσημείωτη, ωστόσο, είναι η σχεδόν μηδενική/ουδέτερη συσχέτιση της πρόθεσης αποχώρησης με τα τρέχοντα επίπεδα καθημερινού στρες (q29,  $r = -0.09$ ), εύρημα που επαληθεύει τις παρατηρήσεις της μονομεταβλητής ανάλυσης: ο Έλληνας white-collar εργαζόμενος του δείγματος εμφανίζει υψηλή ανθεκτικότητα στην καθημερινή πίεση της εργασίας, και η απόφασή του να παραιτηθεί δεν λαμβάνεται υπό το κράτος στιγμιαίου στρες, αλλά είναι αποτέλεσμα μακροχρόνιας οικονομικής/επαγγελματικής απογοήτευσης και συσσωρευμένης συναισθηματικής κόπωσης.

#### 4.3.2 Cramer's V για κατηγορικές συσχετίσεις

Η ανάλυση συσχέτισης των κατηγορικών μεταβλητών του συνόλου απαιτούν διαφορετική προσέγγιση συγκριτικά με τις μεταβλητές Likert. Συνεπώς, επιλέχθηκε η μετρική Cramer's V για την εν λόγω αξιολόγηση, η οποία είναι πλήρως κατάλληλη για τέτοιες εφαρμογές (Cramer, 1946). Ο

δείκτης αυτός αποτελεί ένα συμμετρικό μέτρο συσχέτισης που βασίζεται στη στατιστική δοκιμασία  $X^2$  τετράγωνο (ανεξαρτησίας και αποτιμά την ισχύ της σχέσης μεταξύ δύο ποιοτικών μεταβλητών, λαμβάνοντας τιμές στο διάστημα  $[0, 1]$ , όπου το 0 υποδηλώνει πλήρη έλλειψη συσχέτισης και το 1 τέλεια συσχέτιση (Field, 2013).

Ωστόσο, ο κλασικός τύπος του Cramer's V τείνει να παρουσιάζει συστηματικό σφάλμα υπερεκτίμησης (upward bias) της συσχέτισης, ιδιαίτερα σε περιπτώσεις μικρού μεγέθους δείγματος ή πινάκων συνάφειας (contingency tables) με πολλές κατηγορίες. Για την εξάλειψη αυτού του περιορισμού, στην παρούσα εργασία αναπτύχθηκε και εφαρμόστηκε ένας αλγόριθμος σε περιβάλλον Python, ο οποίος υλοποιεί τη διορθωμένη εκδοχή του δείκτη (Bias-Corrected Cramer's V), όπως αυτή προτάθηκε από τον Bergsma (Bergsma, 2013).

Η μαθηματική αποτύπωση της διόρθωσης βασίζεται στην τροποποίηση της τιμής  $\Phi^2$  (phi-squared) και των βαθμών ελευθερίας των γραμμών ( $r$ ) και των στηλών ( $k$ ) του πίνακα συνάφειας, με βάση το μέγεθος του δείγματος ( $n$ ), σύμφωνα με τις ακόλουθες εξισώσεις:

$$\Phi_{corr}^2 = \max\left(0, \varphi^2 - \frac{(k-1)(r-1)}{n-1}\right)$$

$$r_{corr} = r - \frac{(r-1)^2}{n-1}$$

$$k_{corr} = k - \frac{(k-1)^2}{n-1}$$

Ο διορθωμένος δείκτης Cramer's V υπολογίζεται ως εξής:

$$V = \sqrt{\frac{\Phi_{corr}^2}{\min((k_{corr}-1), (r_{corr}-1))}}$$

Η προγραμματιστική υλοποίηση της διαδικασίας οργανώθηκε σε τρία διακριτά στάδια μέσω της βιβλιοθήκης `scipy.stats`. Αρχικά έγινε απομόνωση των μεταβλητών. Δημιουργήθηκε μια δυναμική λίστα κατηγορικών μεταβλητών (`categorical_columns`), εξαιρώντας τις μεταβλητές κλίμακας Likert, τη μεταβλητή `q19` (λόγω ειδικής φύσης) και τη χρονοσήμανση (`Timestamp`).

Στην συνέχεια εφαρμόστηκε ο υπολογισμός της μετρικής Cramer's V ανα ζεύγη. Σχεδιάστηκε μια επαναληπτική δομή (`nested for-loop`) η οποία υπολογίζει τον πίνακα συνάφειας (`pd.crosstab`) και τον διορθωμένο δείκτη Cramer's V για κάθε δυνατό συνδυασμό μεταβλητών. Για την αποφυγή διπλότυπων καταχωρίσεων (π.χ. έλεγχος της μεταβλητής A με τη B και στη συνέχεια της B με την A) εισήχθη η μεθοδολογική συνθήκη `column1 > column2`.

Τέλος, εφαρμόστηκε φιλτράρισμα και ταξινόμηση. Τα αποτελέσματα ταξινομήθηκαν σε φθίνουσα σειρά. Με βάση τα κριτήρια ερμηνείας του Cohen (Cohen, 1988) για την ισχύ του μεγέθους του αποτελέσματος (effect size), ως κατώφλι για την ανάδειξη των πιο ουσιαστικών και θεωρητικά αξιοσημείωτων συσχετίσεων ορίστηκε η τιμή  $V \geq 0.3$  (μέτρια προς ισχυρή συσχέτιση).

```

import numpy as np
from scipy.stats import chi2_contingency
#getting all the categorical columns
categorical_columns = []
#inserting each relevant column in the list
for column in dataset.columns:
    if column not in likert_cols+['q19_employers_changed_5years', 'Timestamp']:
        categorical_columns.append(column)

def cramers_v(x, y):
    # creating contingency table
    confusion_matrix = pd.crosstab(x, y)

    # X^2 calculation
    chi2 = chi2_contingency(confusion_matrix)[0]
    n = confusion_matrix.sum().sum()
    phi2 = chi2 / n
    r, k = confusion_matrix.shape

    phi2corr = max(0, phi2 - ((k-1)*(r-1))/(n-1))
    rcorr = r - ((r-1)**2)/(n-1)
    kcorr = k - ((k-1)**2)/(n-1)

    # returning Cramer's V
    return np.sqrt(phi2corr / min((kcorr-1), (rcorr-1)))

```

Εικόνα 23 - Cramer's V custom function

```

# creating a dataframe to store Cramer's V combinations and score
categorical_combinations_cramer_v = pd.DataFrame(columns = ['column1', 'column2',
    'cramer_v'])

for column1 in categorical_columns:
    for column2 in categorical_columns:
        # the condition column1>column2 will be used to avoid having two column
        combinations that are the same for column1 and column2.
        # this will avoid having rows like the following example:
        # [[column1, column2, cramer_v],
        # [q18_attrition_intent, q14_thought_change_frequency, 0.5]
        # [q14_thought_change_frequency, q18_attrition_intent, 0.5]]
        if column1 > column2:
            result = cramers_v(dataset[column1], dataset[column2])
            categorical_combinations_cramer_v.loc[len
                (categorical_combinations_cramer_v.index)] = [column1, column2, result]

# sorting by descending order
categorical_combinations_cramer_v = categorical_combinations_cramer_v.sort_values
    (by=['cramer_v'], ascending=False)

# creating a list with the columns with Cramer's V score above 0.3
top_cramer_combinations =
    categorical_combinations_cramer_v[categorical_combinations_cramer_v['cramer_v'] >=
    0.3]
#displaying the top cramer combinations found previously in a table format
display(top_cramer_combinations)

```

Εικόνα 24 - Εφαρμογή Cramer's V συνάρτησης όπως αναφέρθηκε

Έπειτα της εφαρμογής του παραπάνω script συλλέχθηκαν 35 ζευγάρια κατηγορικών μεταβλητών με μέτρια συσχέτιση και πάνω. Ο παρακάτω πίνακας παρουσιάζει τα ταξινομημένα αυτά τα ζεύγη:

| Column 1                     | Column 2                           | Cramer's V Score |
|------------------------------|------------------------------------|------------------|
| q18_attrition_intent         | q14_thought_change_frequency       | 0.599750         |
| q8_total_experience          | q2_age_group                       | 0.564588         |
| q22_retention_due_to_costs   | q14_thought_change_frequency       | 0.563458         |
| q22_retention_due_to_costs   | q18_attrition_intent               | 0.530948         |
| q8_total_experience          | q15_job_hopping_awareness          | 0.478827         |
| q9_tenure_current_employer   | q8_total_experience                | 0.467156         |
| q2_age_group                 | q15_job_hopping_awareness          | 0.447322         |
| q20_fair_reward_perception   | q18_attrition_intent               | 0.425661         |
| q5_industry                  | q15_job_hopping_awareness          | 0.415967         |
| q18_attrition_intent         | q12_ideal_stay_duration            | 0.411321         |
| q5_industry                  | q25_current_work_model             | 0.403669         |
| q8_total_experience          | q12_ideal_stay_duration            | 0.397590         |
| q26_preferred_work_model     | q25_current_work_model             | 0.394792         |
| q8_total_experience          | q22_retention_due_to_costs         | 0.392731         |
| q22_retention_due_to_costs   | q13_profile_update_frequency       | 0.392463         |
| q18_attrition_intent         | q13_profile_update_frequency       | 0.392256         |
| q8_total_experience          | q6_job_level                       | 0.391554         |
| q2_age_group                 | q12_ideal_stay_duration            | 0.384335         |
| q9_tenure_current_employer   | q15_job_hopping_awareness          | 0.382039         |
| q9_tenure_current_employer   | q2_age_group                       | 0.379910         |
| q29_stress_level             | q28_emotional_exhaustion_frequency | 0.375727         |
| q1_gender                    | q15_job_hopping_awareness          | 0.365369         |
| q5_industry                  | q1_gender                          | 0.361457         |
| q7_company_size              | q31_employer_wellbeing_interest    | 0.349257         |
| q9_tenure_current_employer   | q12_ideal_stay_duration            | 0.347640         |
| q6_job_level                 | q2_age_group                       | 0.346075         |
| q2_age_group                 | q26_preferred_work_model           | 0.345742         |
| q7_company_size              | q5_industry                        | 0.335267         |
| q9_tenure_current_employer   | q22_retention_due_to_costs         | 0.331225         |
| q14_thought_change_frequency | q12_ideal_stay_duration            | 0.330153         |
| q22_retention_due_to_costs   | q15_job_hopping_awareness          | 0.324101         |
| q5_industry                  | q2_age_group                       | 0.314101         |
| q8_total_experience          | q5_industry                        | 0.312216         |
| q15_job_hopping_awareness    | q14_thought_change_frequency       | 0.308743         |
| q9_tenure_current_employer   | q6_job_level                       | 0.300388         |

Στην κορυφή του πίνακα καταγράφονται οι ισχυρότερες συσχετίσεις της έρευνας, οι οποίες συνθέτουν τον ψυχολογικό και πρακτικό μηχανισμό του Turnover. Συγκεκριμένα, η γενική πρόθεση αποχώρησης (q18) συνδέεται στενά με τη συχνότητα με την οποία ο εργαζόμενος σκέφτεται να αλλάξει δουλειά (q14,  $V = 0.60$ ).

Το πλέον ενδιαφέρον εύρημα, ωστόσο, αφορά τη μεταβλητή του «αναγκαστικού εγκλωβισμού» λόγω οικονομικού ή επαγγελματικού κόστους (q22). Η q22 παρουσιάζει εξαιρετικά υψηλή συνάφεια τόσο με τη συχνότητα σκέψης αλλαγής (q14,  $V = 0.56$ ) όσο και με την ίδια την

πρόθεση αποχώρησης (q18,  $V = 0.53$ ). Η τριάδα αυτή των συσχετίσεων επιβεβαιώνει εμπειρικά ότι η γνωστική διεργασία της παραίτησης (turnover cognition) περνά απαρέγκλιτα μέσα από το φίλτρο της οικονομικής σκοπιμότητας, όπως ακριβώς προβλέπεται στο θεωρητικό μοντέλο των Hom et al. (Hom, Allen, & Griffith, 2019).

Επιπλέον, η πρόθεση αποχώρησης (q18) συνδέεται με τη συχνότητα επικαιροποίησης του επαγγελματικού προφίλ/βιογραφικού (q13,  $V = 0.39$ ) και την αντίληψη περί δίκαιης αμοιβής (q20,  $V = 0.43$ ). Το τελευταίο αυτό στοιχείο υπογραμμίζει ότι η αίσθηση αδικίας στις απολαβές αποτελεί έναν από τους ισχυρότερους κατηγορικούς μοχλούς ώθησης (push factors) προς την έξοδο.

Ο δεύτερος σημαντικός πόλος του πίνακα περιστρέφεται γύρω από τη μεταβλητή της εξοικείωσης με τον όρο Job Hopping (q15). Η γνώση και η αποδοχή της συγκεκριμένης πρακτικής δεν εμφανίζονται ομοιογενώς στο δείγμα, αλλά παρουσιάζουν σαφή εξάρτηση από δημογραφικά και δομικά χαρακτηριστικά.

Ειδικότερα, η q15 συσχετίζεται έντονα με τη συνολική εργασιακή εμπειρία (q8,  $V = 0.48$ ), την ηλικιακή ομάδα (q2,  $V = 0.45$ ), τον κλάδο απασχόλησης (q5,  $V = 0.42$ ), καθώς και την τρέχουσα προϋπηρεσία στον ίδιο εργοδότη (q9,  $V = 0.38$ ). Οι συσχετίσεις αυτές φανερώνουν ότι η κουλτούρα του Job Hopping είναι κατεξοχήν χαρακτηριστικό συγκεκριμένων ηλικιακών ομάδων (κυρίως των νεότερων γενεών white-collar εργαζομένων) και συγκεκριμένων κλάδων (π.χ. Τεχνολογία/IT, όπου η κινητικότητα είναι δομικό στοιχείο της αγοράς).

Η υπόθεση αυτή ενισχύεται από τη συσχέτιση της q15 με το ιδανικό διάστημα παραμονής σε έναν εργοδότη (q12,  $V = 0.41$ ), δείχνοντας ότι η θεωρητική εξοικείωση με τον όρο διαμορφώνει άμεσα και τις πρακτικές προσδοκίες των εργαζομένων για τη διάρκεια των επαγγελματικών τους κύκλων.

Ο τρίτος άξονας αναδεικνύει τη σημασία των οργανωσιακών δομών. Η μεταβλητή του κλάδου (q5) αποδεικνύεται κομβική, καθώς καθορίζει σε μεγάλο βαθμό το εφαρμοζόμενο μοντέλο εργασίας (q25,  $V = 0.40$ ), τη συνολική εμπειρία ( $V = 0.31$ ) και το μέγεθος της εταιρείας (q7,  $V = 0.34$ ).

Παράλληλα, το τρέχον μοντέλο εργασίας (q25) συνδέεται αναμενόμενα με το προτιμώμενο μοντέλο εργασίας (q26,  $V = 0.39$ ), αποτυπώνοντας το χάσμα μεταξύ πραγματικότητας και επιθυμίας των εργαζομένων.

Τέλος, αξίζει να σημειωθεί η συσχέτιση μεταξύ του μεγέθους της εταιρείας (q7) και του βαθμού στον οποίο ο εργοδότης ενδιαφέρεται για την ευεξία του προσωπικού (q31,  $V = 0.35$ ). Το εύρημα αυτό υποδηλώνει ότι η εταιρική κουλτούρα μέριμνας διαφοροποιείται σημαντικά ανάλογα με το μέγεθος του οργανισμού, με τις μικρότερες ή τις πολύ μεγάλες (πολυεθνικές) εταιρείες να αναπτύσσουν διαφορετικούς μηχανισμούς προσέγγισης της εργασιακής ευεξίας.

#### **4.3.3 Ομαδοποιημένα ραβδογράμματα (Grouped Bar Charts)**

Από τα προηγούμενα δύο υποκεφάλαια προέκυψαν σημαντικά ευρήματα, τα οποία συνεισφέρουν στην ολοκληρωμένη απάντηση των αρχικών τριών ερευνητικών ερωτημάτων. Αρχικά, εντοπίστηκε στατιστικά σημαντική συσχέτιση μεταξύ των επιπέδων καθημερινού stress, της

κεντρικότητας της εργασίας και της συναισθηματικής εξάντλησης. Επομένως, κρίνεται σημαντική η χαρτογράφηση των χαρακτηριστικών που διαχωρίζουν κάθε ευεξιοκεντρική προσέγγιση.

Εξίσου σημαντική είναι η διερεύνηση των χαρακτηριστικών των συμμετεχόντων με θετική στάση στα φαινόμενα του Job Hopping και του Quiet Quitting. Από τη διμεταβλητή ανάλυση διασφαλίστηκε ήδη πως η γνώση και η στάση απέναντι στην τάση του Job Hopping εμφανίζει ισχυρή συνάφεια με συγκεκριμένες ηλικιακές ομάδες, κλάδους και τη συνολική προϋπηρεσία του εργαζόμενου στον ίδιο εργοδότη. Συνεπώς, θα αναπτυχθούν ομαδοποιημένα ραβδογράμματα για τη συγκεκριμένη χαρτογράφηση, καθώς και για την εξερεύνηση των χαρακτηριστικών των Quiet Quitters, οι οποίοι εμφανίζουν μικρότερη ομοιογένεια στις προηγούμενες διερευνήσεις.

Επιπροσθέτως, αναδείχθηκε μια ξεκάθαρη συσχέτιση μεταξύ των κλασικών πυλώνων HR, όπως η οικονομική και εργασιακή ικανοποίηση, και των συναισθημάτων «εργασιακού εγκλωβισμού». Η περαιτέρω εμβάθυνση για την ακριβή χαρτογράφηση των χαρακτηριστικών που συνδέονται με αυτές τις πτυχές κρίνεται απαραίτητη για την εξαγωγή μιας ολοκληρωμένης εικόνας.

Οι παραπάνω ερευνητικοί σκοποί θα εξυπηρετηθούν μέσω μιας συνάρτησης Python, η οποία σχεδιάστηκε για την οπτικοποίηση των δεδομένων και την παροχή των ακριβών ποσοστιαίων αναλογιών που διαχωρίζουν κάθε κατηγορία ανά ομάδα μεταβλητών:

```
def grouped_bar_chart_creation(dataset, categorical_index, likert_target):
    ds_frequency_table = pd.crosstab(
        index=dataset[categorical_index],
        columns=dataset[likert_target]
    )
    #normalizing the rows
    ds_frequency_table = ds_frequency_table.div(ds_frequency_table.sum(axis=1),
        axis=0)
    ds_frequency_table.plot(
        kind='barh',
        stacked=True,
        figsize=(10,8),
        edgecolor='black',
    )


    #naming title and labels
    plt.title(f'Distribution of {likert_target} by {categorical_index}',
        fontsize=12, pad=15)
    plt.xlabel('Proportion (%)', fontsize=10)
    plt.ylabel(categorical_index, fontsize=10)

    #moving the likert target groups outside the main plot
    plt.legend(title=likert_target, bbox_to_anchor=(1.05, 1), loc='upper left')
    plt.show()


    ds_frequency_table_with_totals = pd.crosstab(
        index=dataset[categorical_index],
        columns=dataset[likert_target],
        margins=True,
        margins_name='Total Counts'
    )
    ds_frequency_table_with_totals_normalized = pd.crosstab(
        index=dataset[categorical_index],
        columns=dataset[likert_target],
        normalize=True,
        margins=True,
        margins_name='Total Counts'
    )
    print(ds_frequency_table_with_totals)
    print(ds_frequency_table_with_totals_normalized)
    print('\n')
```

Εικόνα 25 - Κώδικας ομαδοποιημένων ραβδογραμμάτων

Με στόχο τη βέλτιστη οπτική αποτύπωση των αποτελεσμάτων, επιλέχθηκε η χρήση οριζόντιων, σωρευτικών ομαδοποιημένων ραβδογραμμάτων (stacked bar charts, με τη μεταβλητή stacked=True), ώστε να αναδεικνύεται ξεκάθαρα η ποσοστιαία αναλογία κάθε κατηγορίας ανά μεταβλητή.




Εικόνα 26 - Ερώτηση 32 με ερώτηση 25



Εικόνα 27 - Ερώτηση 5 με ερώτηση 25





Εικόνα 28 - Ερώτηση 28 με ερώτηση 25


Τα παραπάνω ραβδογράμματα φανερώουν τα ιδιαίτερα χαρακτηριστικά που συνδέουν το εφαρμοζόμενο μοντέλο εργασίας με τις υπόλοιπες πτυχές της εργασιακής καθημερινότητας των συμμετεχόντων. Πρώτον, αναφορικά με τη σχέση Κλάδου και Μοντέλου Εργασίας, επιβεβαιώνεται ότι η συντριπτική πλειοψηφία των εργαζομένων του δείγματος που απασχολούνται σε καθεστώς τηλεργασίας ή υβριδικής εργασίας συγκεντρώνονται στον κλάδο της Τεχνολογίας & Πληροφορικής. Συγκεκριμένα, επί συνόλου 44 εργαζομένων στον εν λόγω κλάδο, το 52.3% (23 άτομα) εργάζεται υβριδικά και το 25% (11 άτομα) με πλήρη τηλεργασία, ενώ μόλις το 22.7% (10 άτομα) εργάζεται διά ζώσης. Αντίθετα, οι εργαζόμενοι όλων των υπόλοιπων κλάδων (Δημόσιος Τομέας, Διοικητική Υποστήριξη, Πωλήσεις, Οικονομικά/Τράπεζες) απασχολούνται σχεδόν καθολικά σε καθεστώς φυσικής παρουσίας (On-Site). Το εύρημα αυτό επαληθεύει τα συμπεράσματα του Υποκεφαλαίου 4.2.1 σχετικά με τη δομική σύνδεση του κλάδου Τεχνολογίας με ευέλικτες μορφές απασχόλησης, καθώς και την κυριαρχία του διά ζώσης μοντέλου στην ευρύτερη ελληνική αγορά εργασίας.

Δεύτερον, παρατηρώντας τα αποτελέσματα της διασταύρωσης του μοντέλου εργασίας με την κεντρικότητα της εργασίας (q32), διαπιστώνεται ότι οι εργαζόμενοι στο υβριδικό μοντέλο εμφανίζουν τη χαμηλότερη τάση υπερ-επένδυσης στην καριέρα τους, με το 32.2% (10 στους 31) να βαθμολογεί την κεντρικότητα της εργασίας κάτω από το μετρίως (κλίμακα 1-2). Στον αντίποδα, όσοι εργάζονται αποκλειστικά διά ζώσης τείνουν να ιεραρχούν υψηλότερα την επαγγελματική τους ιδιότητα, με το 38.4% (25 στους 65) να δίνει βαθμολογίες 4 και 5 (υψηλή έως απόλυτη προτεραιότητα).


Η πλέον αξιοσημείωτη παρατήρηση, ωστόσο, αφορά τους εργαζόμενους σε καθεστώς πλήρους τηλεργασίας (Remote). Παρά την παρεχόμενη χωρική ευελιξία, το 46.6% (7 στους 15) εξ αυτών ιεραρχεί την εργασία υψηλά έως πολύ υψηλά (βαθμολογίες 4-5) έναντι της προσωπικής ζωής. Το εύρημα αυτό, σε θεωρητικό επίπεδο, αντανακλά τη δυσκολία αποσύνδεσης (blurring boundaries) που συχνά προκαλεί η τηλεργασία. Ταυτόχρονα, σε πρακτικό επίπεδο, ενδέχεται να σκιαγραφεί ένα

εξειδικευμένο τμήμα του δείγματος που εργάζεται εξ αποστάσεως για εταιρείες του εξωτερικού. Οι εν λόγω εργαζόμενοι, καθοδηγούμενοι από υψηλή επαγγελματική στοχοθέτηση και την επιδίωξη καλύτερων απολαβών, επιλέγουν συνειδητά και αναγκαία το συγκεκριμένο μοντέλο απασχόλησης.

Τρίτον, το μοντέλο εργασίας που αποδεικνύεται ότι συνδέεται με τη χαμηλότερη συχνότητα συναισθηματικής εξάντλησης (q28) είναι η πλήρης τηλεργασία, όπου το 80% των συμμετεχόντων (12 στους 15) δηλώνει από μέτρια έως πολύ χαμηλή συχνότητα εξάντλησης (μόλις το 20% δηλώνει «πολλές/πάρα πολλές φορές τον χρόνο»). Στο υβριδικό μοντέλο το ποσοστό έντονης εξάντλησης ανεβαίνει στο 41.9% (13 στους 31). Η δυσμενέστερη εικόνα καταγράφεται στο διά ζώσης μοντέλο, όπου σχεδόν οι μισοί εργαζόμενοι (49.2%, 32 στους 65) βιώνουν συναισθηματική εξάντληση με υψηλή ή πάρα πολύ υψηλή συχνότητα. Το εύρημα αυτό τεκμηριώνει με σαφήνεια το έντονο ψυχολογικό φορτίο και την ανικανοποίητη ανάγκη για ευελιξία που χαρακτηρίζει τους εργαζόμενους με υποχρεωτική φυσική παρουσία.



Εικόνα 29 - Ερώτηση 24 με ερώτηση 2



Εικόνα 30 – Ερώτηση 16 με ερώτηση 2

Έντονη διαφοροποίηση καταγράφεται στις αντιλήψεις των νεότερων συμμετεχόντων σε σύγκριση με τις μεγαλύτερες ηλικιακές ομάδες αναφορικά με τις δύο κεντρικές εργασιακές τάσεις που εξετάζονται στην παρούσα μελέτη. Όπως αποτυπώνεται στις *Εικόνες 29* και *30*, οι εργαζόμενοι της ηλικιακής ομάδας 18-25 ετών επιδεικνύουν κατεξοχήν θετική στάση απέναντι και στις δύο πρακτικές.


Ωστόσο, όσον αφορά την ωφελιμότητα του Quiet Quitting, παρατηρείται ένας ελαφρύς διχασμός εντός της συγκεκριμένης ομάδας. Ενώ ελάχιστοι τη θεωρούν χαμηλής ωφελιμότητας (μόλις 1 στους 12 βαθμολογεί με 2), οι γνώμες πολώνονται μεταξύ της ουδέτερης/μέτριας στάσης (50%, 6 στα 12 άτομα) και της απόλυτης αποδοχής της πρακτικής ως πάρα πολύ ωφέλιμης (33.3%, 4 στα 12 άτομα). Αντίθετα, η στρατηγική του Job Hopping τυγχάνει πιο καθολικής και ξεκάθαρης αποδοχής από την ηλικιακή ομάδα 18-25, με το 66.7% (8 στα 12 άτομα) να τη θεωρεί από πολύ έως πάρα πολύ ωφέλιμη (βαθμολογίες 4-5) και κανέναν (0%) να μην εκφράζει αρνητική άποψη.

Η εικόνα αυτή μεταβάλλεται σταδιακά κατά τη μετάβαση σε μεγαλύτερες ηλικιακές ομάδες. Συγκεκριμένα, στην πολυπληθέστερη ομάδα των 26-41 ετών, παρατηρείται μια ελαφρά αύξηση της εμφάνισης αρνητικών τοποθετήσεων (βαθμολογίες 1-2) και για τις δύο πρακτικές (~14.7% για το Job Hopping και ~27.8% για το Quiet Quitting). Παρά ταύτα, η επικρατούσα τάση στην ηλικιακή ομάδα 26-41 παραμένει ισχυρά θετική.

Η βασική διαφορά είναι ότι σε αυτή την ηλικιακή φάση οι εργαζόμενοι μοιάζουν να ξεκαθαρίζουν πιο συνειδητά την αξία του Quiet Quitting, με το 36% (22 στα 61 άτομα) να συγκεντρώνεται στη βαθμίδα 4 («πολύ ωφέλιμο»), ξεπερνώντας τη μετριοπαθή στάση και αναγνωρίζοντας την τακτική αυτή ως ένα δομικό εργαλείο διατήρησης της προσωπικής τους ισορροπίας.

Η τάση αυτή ανατρέπεται στις ύστερες ηλικιακές ομάδες (42 ετών και άνω), οι οποίες εμφανίζουν σαφή αντίσταση απέναντι στο Quiet Quitting συγκριτικά με το Job Hopping. Ενδεικτικά, στην ομάδα 42-57 ετών, το Quiet Quitting απορρίπτεται από το 41.3% των ερωτηθέντων (βαθμολογίες 1-2), ενώ στην ομάδα 58+ το ποσοστό απόρριψης αγγίζει το 44.4%, με κανέναν συμμετέχοντα (0%) να μην αναγνωρίζει υψηλό όφελος στην πρακτική.

Στον αντίποδα, οι μεγαλύτεροι σε ηλικία επαγγελματίες εμφανίζονται πιο ανεκτικοί με το Job Hopping, αν και το αντιμετωπίζουν πλέον με πιο ρεαλιστικούς όρους, με την πλειοψηφία της ομάδας 42-57 ετών (55.2%, 16 στα 29 άτομα) να κατασταλάζει στην ουδέτερη βαθμίδα (3), θεωρώντας το μια τακτική μέτριας ωφελιμότητας για την καριέρα.




Εικόνα 31 – Ερώτηση 31 με ερώτηση 23

Εμβαθύνοντας στο πραγματικό ιστορικό των συμμετεχόντων (Εικόνα 31), διαπιστώνεται ότι το 29.7% του συνολικού δείγματος (33 στα 111 άτομα) έχει εφαρμόσει ήδη την πρακτική του Quiet Quitting στην επαγγελματική του πορεία. Στη συντριπτική τους πλειοψηφία, οι εργαζόμενοι αυτοί συνδέουν την απόφασή τους με την αντιλαμβανόμενη εργοδοτική αδιαφορία. Συγκεκριμένα, το 63.6% όσων έχουν κάνει Quiet Quitting (21 στα 33 άτομα) δηλώνει ότι ο εργοδότης του «δεν ενδιαφέρεται» ή δείχνει «λίγο ενδιαφέρον» για την ευεξία του, ενώ μόλις 2 άτομα προέρχονται από περιβάλλον με «πολύ ενδιαφέρον». Το εύρημα αυτό επιβεβαιώνει εμπειρικά ότι η σιωπηρή παραίτηση αποτελεί μια καθαρά αμυντική αντίδραση απέναντι στην οργανωσιακή αδιαφορία.


Ιδιαίτερο ερευνητικό ενδιαφέρον παρουσιάζουν, ωστόσο, και οι απαντήσεις των 70 συμμετεχόντων που δεν έχουν εφαρμόσει ακόμα τη συγκεκριμένη πρακτική. Οι εργαζόμενοι αυτοί εμφανίζουν μια αξιοσημείωτα παρόμοια κατανομή με τους Quiet Quitters, καθώς το 47.1% εξ αυτών

(33 στα 70 άτομα) θεωρεί επίσης πως ο εργοδότης του δείχνει ελάχιστο έως μηδενικό ενδιαφέρον για την ευημερία του.

Αυτό το μεγάλο τμήμα του δείγματος αποτελεί μια εξαιρετικά ευάλωτη ομάδα (at-risk population), η οποία εμφανίζεται ιδιαίτερα επιρρεπής σε μελλοντική μακροχρόνια αποστασιοποίηση ή, εναλλακτικά, σε οριστική αλλαγή εργασιακού περιβάλλοντος (Job Hopping). Στην οργανωσιακή ψυχολογία, η χαμηλή αντιλαμβανόμενη υποστήριξη λειτουργεί ως ο βασικότερος προγνωστικός δείκτης (predictor) που συνδέει τη συναισθηματική αποσύνδεση με την τελική πρόθεση αποχώρησης, καθώς η μία μεταβλητή τροφοδοτεί νομοτελειακά την άλλη.



Εικόνα 32 - Ερώτηση 10 και ερώτηση 33




Εικόνα 33 - Ερώτηση 11 με ερώτηση 33

Επιπροσθέτως, τα ευρήματα της *Εικόνας 32* επιβεβαιώνουν την ισχυρή αρνητική συνάφεια μεταξύ της πιθανότητας αλλαγής εργοδότη εντός των επόμενων 12 μηνών (q33) και της γενικής εργασιακής ικανοποίησης (q10). Η διασταύρωση των δύο μεταβλητών επικυρώνει εμπειρικά τις θεωρητικές προσεγγίσεις των Hom et al. (Hom, Allen, & Griffith, 2019) σχετικά με τους μηχανισμούς οικειοθελούς αποχώρησης (voluntary turnover), καθώς η υψηλή ικανοποίηση από το αντικείμενο και το περιβάλλον εργασίας λειτουργεί ως ισχυρός ανασταλτικός παράγοντας για τη φυγική διάθεση των εργαζομένων.

Συγκεκριμένα, από το τμήμα του δείγματος που δηλώνει μηδενική πρόθεση αποχώρησης (βαθμολογία 1 στην q33), το εντυπωσιακό 73.1% (19 στα 26 άτομα) αναφέρει υψηλή έως πάρα πολύ υψηλή εργασιακή ικανοποίηση (βαθμολογίες 4-5), ενώ κανένας εργαζόμενος (0%) από αυτή την ομάδα δεν δηλώνει δυσαρεστημένος. Στον αντίποδα, μεταξύ εκείνων που δηλώνουν απόλυτα έτοιμοι να αποχωρήσουν άμεσα (βαθμολογία 5 στην q33), η εργασιακή δυσαρέσκεια είναι εμφανής, με το 37% (10 στα 27 άτομα) να βαθμολογεί την ικανοποίησή του με 1 ή 2.

Ανάλογη, αν και ελαφρώς διαφοροποιημένη, είναι η εικόνα αναφορικά με τις οικονομικές απολαβές (*Εικόνα 33*), επιβεβαιώνοντας τα συμπεράσματα των Υποκεφαλαίων 4.2.4 και 4.3.1. Η οικονομική ικανοποίηση (q11) αναδεικνύεται σε εξίσου καθοριστικό κριτήριο διακράτησης. Από τους εργαζόμενους με μηδενική πρόθεση φυγής, το 84.6% (22 στα 26 άτομα) δηλώνει ικανοποιημένο με τις απολαβές του (βαθμολογίες 4-5).

Ωστόσο, η οικονομική πίεση λειτουργεί ως ισχυρότερος «μοχλός ώθησης» (push factor) προς την έξοδο σε σχέση με την απλή εργασιακή δυσαρέσκεια: επί του συνόλου των 27 ατόμων που σκοπεύουν να αποχωρήσουν άμεσα (βαθμολογία 5), η πλειοψηφία τους —συγκεκριμένα το 55.6% (15 άτομα)— δηλώνει χαμηλή έως πολύ χαμηλή οικονομική ικανοποίηση (βαθμολογίες 1-2). Το εύρημα αυτό υπογραμμίζει ότι στην ελληνική αγορά εργασίας white-collar, η μισθολογική ανεπάρκεια αποτελεί τον πρωταρχικό λόγο για την ενεργοποίηση της πρόθεσης αποχώρησης.



Εικόνα 34 - Ερώτηση 14 με ερώτηση 22

Εξίσου αποκαλυπτικά είναι τα ευρήματα που αφορούν τα αισθήματα εργασιακού εγκλωβισμού. Η περαιτέρω εμβάθυνση στην εν λόγω κατάσταση (Εικόνα 34) αναδεικνύει το βαρύ ψυχολογικό τίμημα που βιώνουν οι εργαζόμενοι οι οποίοι δεσμεύονται στον οργανισμό αποκλειστικά λόγω αδυναμίας ανάληψης του οικονομικού κόστους μιας μετάβασης. Αρχικά, διαπιστώνεται ότι πάνω από το μισό δείγμα (54.1%, 60 στα 111 άτομα) τελεί υπό καθεστώς οικονομικού εγκλωβισμού (q22 = «Ναι»).

Όπως αναμενόταν βάσει της θεωρίας, οι «εγκλωβισμένοι» αυτοί εργαζόμενοι εμφανίζουν ακραία συχνότητα σκέψης αλλαγής περιβάλλοντος. Το 35% εξ αυτών (21 στα 60 άτομα) σκέφτεται να αλλάξει εργοδότη σε καθημερινή ή εβδομαδιαία βάση («κάθε εβδομάδα» ή «κάθε μήνα»), ενώ αν συνυπολογιστούν και οι ενδιάμεσες βαθμίδες (κάθε 3 ή 6 μήνες), το ποσοστό των ανθρώπων που αναζητούν νοητικά τη φυγή αγγίζει το 65% (39 στα 60 άτομα). Μόλις ένα 15% εξ αυτών δηλώνει ότι δεν το σκέφτεται.

Απεναντίας, στην ομάδα των εργαζομένων που δεν βιώνουν αυτόν τον οικονομικό καταναγκασμό (q22 = «Όχι»), η εικόνα αντιστρέφεται πλήρως. Η συντριπτική πλειοψηφία αυτών, σε ποσοστό 66.7% (34 στα 51 άτομα), δηλώνει ότι δεν σκέφτεται καθόλου να αλλάξει εργοδότη. Όσοι ελάχιστοι από αυτή την ελεύθερη ομάδα σκέφτονται εναλλακτικές, το κάνουν κυρίως σε αραιά διαστήματα, με το 21.6% (11 άτομα) να το σκέφτεται «κάθε χρόνο», γεγονός που υποδηλώνει μια υγιή στάση αναμονής και περιοδικής αξιολόγησης της αγοράς για λόγους επαγγελματικής εξέλιξης και καριέρας, και όχι μια κατάσταση ψυχικής εξάντλησης ή πίεσης.

#### **4.4 Ομαδοποίηση εργαζομένων με πρακτικές Μηχανικής Μάθησης – Clustering**

Η κλιμάκωση της διμετάβλητης ανάλυσης ακολουθείται από τη συσταδοποίηση των δεδομένων (Clustering), με σκοπό τον σαφή διαχωρισμό των υποκείμενων ομάδων στο σύνολο δεδομένων. Τα προηγούμενα βήματα παρείχαν μια σφαιρική εικόνα των επικρατουσών τάσεων, καθώς και των αιτιών που συμβάλλουν στη διαμόρφωσή τους. Με βάση αυτά τα ευρήματα και τη συσταδοποίηση που ακολουθεί, επιχειρείται η σαφής χαρτογράφηση των χαρακτηριστικών που διαφοροποιούν κάθε ομάδα συμμετεχόντων.

Στον τομέα της Μηχανικής Μάθησης, η συσταδοποίηση ανήκει στην κατηγορία της Μη Επιβλεπόμενης Μάθησης (Unsupervised Learning), καθώς οι υποκείμενες ομάδες του δείγματος είναι άγνωστες πριν από την εφαρμογή της συγκεκριμένης μεθόδου. Αντίθετα, στην Επιβλεπόμενη Μάθηση (Supervised Learning), ο στόχος είναι η εκπαίδευση μοντέλων που αξιοποιούν μια εξαρτημένη μεταβλητή και τις διαθέσιμες ανεξάρτητες μεταβλητές, προκειμένου να πραγματοποιούν προβλέψεις.

Το παρόν δείγμα περιλαμβάνει τόσο κατηγορικές όσο και αριθμητικές μεταβλητές. Συνεπώς, η χρήση του αλγορίθμου K-Prototypes κρίθηκε ως η καταλληλότερη επιλογή. Ο συγκεκριμένος αλγόριθμος λειτουργεί συνδυάζοντας δύο αλγορίθμους συσταδοποίησης, τον K-Means και τον K-Modes, οι οποίοι εκτελούν συσταδοποίηση στις αριθμητικές και στις κατηγορικές μεταβλητές, αντίστοιχα.

Πριν από την εφαρμογή του παραπάνω αλγορίθμου, κρίθηκε απαραίτητη η κανονικοποίηση των μεταβλητών τύπου Likert με τη χρήση του αντικειμένου StandardScaler από τη βιβλιοθήκη scikit-learn. Η διαδικασία αυτή εξασφαλίζει ότι οι αριθμητικές μεταβλητές βρίσκονται στην ίδια κλίμακα,

αποτρέποντας την υπερεκπροσώπηση μεταβλητών με μεγαλύτερο εύρος τιμών. Με τον τρόπο αυτό διευκολύνεται η λειτουργία του K-Prototypes, ο οποίος, όπως και ο αλγόριθμος K-Means, χρησιμοποιεί την Ευκλείδεια απόσταση για τη συσταδοποίηση των αριθμητικών μεταβλητών.

#### 4.4.1 Εύρεση βέλτιστου αριθμού συστάδων K μέσω Elbow Method & Silhouette Score

Ο αλγόριθμος K-Prototypes απαιτεί τον προκαθορισμό του αριθμού των συστάδων (clusters) που θα δημιουργηθούν. Προκειμένου να αποφευχθεί η επιλογή του αριθμού αυτού μέσω τυχαίων δοκιμών, αξιοποιήθηκαν δύο καθιερωμένες τεχνικές για τον προσδιορισμό του βέλτιστου πλήθους συστάδων: η μέθοδος Elbow και η μετρική Silhouette Score.

Οι δύο αυτές τεχνικές επιδιώκουν τον ίδιο στόχο, ωστόσο βασίζονται σε διαφορετικά κριτήρια αξιολόγησης. Σύμφωνα με τον Géron (Géron, 2019), η μέθοδος Elbow χρησιμοποιεί ως βασικό κριτήριο την αδράνεια (Inertia), η οποία ορίζεται ως το άθροισμα των τετραγώνων των αποστάσεων κάθε δείγματος από το πλησιέστερο κέντρο της συστάδας του (centroid), δηλαδή το Mean Squared Error της συσταδοποίησης. Κατά την οπτικοποίηση της αδράνειας για διαδοχικές τιμές του (K), παρατηρείται ότι η αδράνεια μειώνεται όσο αυξάνεται ο αριθμός των συστάδων, αλλά με ολοένα μικρότερο ρυθμό. Το σημείο στο οποίο η καμπύλη παρουσιάζει μια χαρακτηριστική «κάμψη» (elbow) θεωρείται πιθανή ένδειξη του βέλτιστου αριθμού συστάδων. Παρόλα αυτά, ο Géron επισημαίνει ότι η συγκεκριμένη μέθοδος είναι συχνά υποκειμενική (Géron, 2019). Για τον λόγο αυτό προτείνει τη συμπληρωματική χρήση της μετρικής Silhouette Score.

Όπως και η μέθοδος Elbow, η μετρική Silhouette Score υπολογίζεται για ένα εύρος τιμών του K. Ωστόσο, η επιλογή του βέλτιστου αριθμού συστάδων βασίζεται στη μέγιστη τιμή του δείκτη, καθώς όσο υψηλότερο είναι το Silhouette Score τόσο καλύτερος θεωρείται ο διαχωρισμός και η συνοχή των συστάδων. Για τον λόγο αυτό, η συνδυαστική χρήση των δύο τεχνικών κρίθηκε απαραίτητη, ώστε η επιλογή του τελικού αριθμού συστάδων να βασίζεται σε περισσότερα από ένα κριτήρια.

Στα επόμενα βήματα υλοποιήθηκαν δύο custom συναρτήσεις Python, μία για κάθε τεχνική. Η εφαρμογή τους απαιτούσε τον καθορισμό των δεικτών (indices) που αντιστοιχούν στις κατηγορικές μεταβλητές του συνόλου δεδομένων, καθώς ο αλγόριθμος K-Prototypes απαιτεί τη ρητή δήλωσή τους. Για τον σκοπό αυτό πραγματοποιήθηκε η χαρτογράφηση τόσο των θέσεων (indices) όσο και των ονομάτων των κατηγορικών μεταβλητών σε δύο ξεχωριστές λίστες της Python.

Μετά την ολοκλήρωση της παραπάνω διαδικασίας, υλοποιήθηκαν οι δύο συναρτήσεις. Παρακάτω παρουσιάζεται ο πηγαίος κώδικας της συνάρτησης που υλοποιεί τη μέθοδο Elbow.



```
def elbow_method(data, c_col_indices):
    inertia = []
    K_range = range(1, 11) # test k from 1 to 11

    for k in K_range:
        kprototypes = KPrototypes(n_clusters=k, init='Huang', random_state=42,
                                   n_init=10)
        kprototypes.fit(data.values, categorical=c_col_indices)
        inertia.append(kprototypes.cost_)
    plt.figure(figsize=(8, 5))
    plt.plot(K_range, inertia, marker='o')
    plt.title("Elbow Method for Optimal K")
    plt.xlabel("Number of clusters (K)")
    plt.ylabel("Inertia (Within-Cluster Sum of Squares)")
    plt.grid(True)
    plt.show()
```

Εικόνα 35 - Elbow Method Function

Στη συνέχεια παρουσιάζεται η προσαρμοσμένη συνάρτηση υπολογισμού και οπτικοποίησης του Silhouette Score, με αξιοποίηση των συναρτήσεων `silhouette_score()` της βιβλιοθήκης `scikit-learn` και `gower_matrix()` της βιβλιοθήκης `gower`.

```
from sklearn.metrics import silhouette_score
import gower

def sil_score(dataset, cat_col_names, cat_col_indices):
    values = dataset.values

    #gower distance matrix calculation
    gower_matrix = gower.gower_matrix(dataset, cat_features=[col in cat_col_names
                                                             for col in dataset.columns])

    K_range = range(2, 11) # just like with elbow method, testing k from 1 to 11
    silhouettes = []

    for k in K_range:
        kproto = KPrototypes(n_clusters=k, init='Huang', verbose=0, random_state=42)
        cluster_labels = kproto.fit_predict(values, categorical=cat_col_indices)

        score = silhouette_score(gower_matrix, cluster_labels, metric='precomputed')
        silhouettes.append(score)


        # print(self) # tracking code outputs just in case
        # print(f"For K = {k}, Silhouette Score = {score:.4f}") #for debugging

    plt.figure(figsize=(8, 5))
    plt.plot(K_range, silhouettes, marker='o', color='purple', linestyle='--')
    plt.xlabel('Clusters (K)')
    plt.ylabel('Silhouette Score (Gower)')
    plt.title('Silhouette score for K-Prototypes')
    plt.grid(True)
    plt.show()
```

Εικόνα 36 - Silhouette Score calculation and visualization

Η εφαρμογή της συγκεκριμένης μεθόδου απαιτεί επιπλέον βήματα, καθώς το σύνολο δεδομένων αποτελείται από μεικτού τύπου μεταβλητές. Για τον λόγο αυτό χρησιμοποιείται ο πίνακας αποστάσεων Gower, ο οποίος επιτρέπει τον υπολογισμό αποστάσεων μεταξύ παρατηρήσεων που περιλαμβάνουν τόσο αριθμητικές όσο και κατηγορικές μεταβλητές. Με βάση τον πίνακα αυτό καθίσταται δυνατός ο υπολογισμός του Silhouette Score για κάθε εξεταζόμενη τιμή του K. Η εφαρμογή των δύο μεθόδων παρήγαγε τα ακόλουθα γραφήματα:

```
elbow_method(final_ds, categorical_column_indices)
sil_score(final_ds, cat_col_names, categorical_column_indices)
✓ [51] 13s 573ms
```



Εικόνα 37 - Elbow Method & Silhouette score results

Από τη συνδυαστική αξιολόγηση των δύο γραφημάτων προέκυψε ότι ο βέλτιστος αριθμός συστάδων είναι  $K = 2$ . Ως εκ τούτου, ο αλγόριθμος K-Prototypes εφαρμόστηκε τελικά με δύο συστάδες.

#### 4.4.2 Εφαρμογή αλγορίθμου K-Prototypes και ανάλυση αποτελεσμάτων

Με το πλέον βέλτιστο αριθμό συστάδων να έχει οριστικοποιηθεί θα εφαρμοστεί η τελική συσταδοποίηση στο σύνολο δεδομένων. Κατόπιν της ολοκληρωμένης εκπαίδευσης του αλγορίθμου στα δεδομένα, με την ίδια μεθοδολογία που εφαρμόστηκε από τις προηγούμενες δύο συναρτήσεις, θα δημιουργηθεί μια καινούρια στήλη στο τελικό σύνολο δεδομένων που θα περιέχει την κάθε συστάδα ξεχωριστά.

```
#final K-Prototypes test, with 5 clusters based on prior Elbow Method results

kproto = KPrototypes(n_clusters = 2, init='Huang', random_state=42, n_init=10)
cluster_labels = kproto.fit_predict(final_ds.values,
    categorical=categorical_column_indices)

final_ds['cluster_labels'] = cluster_labels
final_ds['cluster_labels'] = final_ds['cluster_labels']+1
✓ [47] 510ms
```

Εικόνα 38 - Τελική συσταδοποίηση

Έχοντας, λοιπόν, διαχωρίσει κάθε γραμμή του συνόλου σε δύο διαφορετικά groups θα ακολουθήσει η αναλυτική αξιολόγηση κάθε συστάδας. Αυτό επιτεύχθηκε με την ομαδοποίηση των δεδομένων ανά συστάδα, συνδυαστικά με την εύρεση των επικρατουσών τιμών κάθε μεταβλητής. Με αυτό το βήμα αποσκοπείται ο ξεκάθαρος διαχωρισμός των χαρακτηριστικών κάθε συστάδας. Εξαιρώντας, λοιπόν, τις κανονικοποιημένες μεταβλητές Likert από το τελικό σύνολο, εφαρμόστηκε ο παρακάτω κώδικας:

```
#emptying the categorical_columns list to have the recent changes
categorical_columns = []
for col in final_ds.columns:
    if col not in scaled_likert_column_names:
        categorical_columns.append(col)

#using mode as a metric (the most frequent value)
for i in range(2):
    #skipping i = 0, since clusters are 1-5
    print('\n'+'*50')
    print(f"Most frequent characteristics for Cluster {i+1}")
    print('='*50, '\n')
    for cat_col in categorical_columns:
        mode_val = final_ds[final_ds['cluster_labels'] == i+1][cat_col].mode()[0]
        print(f"{cat_col}: {mode_val}")
```

Εικόνα 39 - Τελικές συστάδες

Τα τελικά αποτελέσματα οργανώθηκαν στον ακόλουθο πίνακα για λόγους σαφήνειας:

| Μεταβλητή                              | Cluster 1                  | Cluster 2                        |
|----------------------------------------|----------------------------|----------------------------------|
| q1_gender                              | Άνδρας                     | Άνδρας                           |
| q2_age_group                           | 26-41                      | 26-41                            |
| q3_education_level                     | Πτυχίο AEI-TEI             | Μεταπτυχιακό Δίπλωμα             |
| q4_white-collar_status                 | Δουλεύω σε έναν εργοδότη   | Δουλεύω σε έναν εργοδότη         |
| q5_industry                            | Τεχνολογία & Πληροφορική   | Τεχνολογία & Πληροφορική         |
| q6_job_level                           | Mid-level                  | Mid-level                        |
| q7_company_size                        | Μικρομεσαία (11-250 άτομα) | Μεγάλη - Πολυεθνική (250+ άτομα) |
| q8_total_experience                    | 6-10                       | 20+                              |
| q9_tenure_current_employer             | 3-5 έτη                    | Πάνω από 5 έτη                   |
| q10_job_satisfaction                   | 3                          | 4                                |
| q11_financial_satisfaction             | 2                          | 4                                |
| q12_ideal_stay_duration                | 3-5 έτη                    | 3-5 έτη                          |
| q13_profile_update_frequency           | Κάθε 6 μήνες               | Πολύ σπάνια                      |
| q14_thought_change_frequency           | Κάθε μήνα                  | Δεν το σκέφτομαι                 |
| q15_job_hopping_awareness              | Ναι                        | Ναι                              |
| q16_job_hopping_benefit                | 4                          | 3                                |
| q17_job_hopping_history                | Όχι                        | Όχι                              |
| q18_attrition_intent                   | Ναι                        | Όχι                              |
| q19_employers_changed_5years           | 0                          | 0                                |
| q20_fair_reward_perception             | Μέτρια                     | Μέτρια                           |
| q21_minimum_effort_frequency           | Συχνά                      | Δεν το κάνω                      |
| q22_retention_due_to_costs             | Ναι                        | Όχι                              |
| q23_quiet_quitting_history             | Όχι                        | Όχι                              |
| q24_quiet_quitting_benefit             | 4                          | 3                                |
| q25_current_work_model                 | Δια ζώσης (On-Site)        | Δια ζώσης (On-Site)              |
| q26_preferred_work_model               | Υβριδικό (Hybrid)          | Υβριδικό (Hybrid)                |
| q27_overtime_frequency                 | Πολύ λίγο (1-15 μέρες)     | Πολύ λίγο (1-15 μέρες)           |
| enc_q28_emotional_exhaustion_frequency | 3                          | 3                                |
| enc_q29_stress_level                   | 3                          | 3                                |
| q30_stress_work_model_connection       | Μέτρια σύνδεση             | Άμεση σύνδεση                    |
| q31_employer_wellbeing_interest        | Λίγο ενδιαφέρον            | Μέτριο ενδιαφέρον                |
| q32_work_life_priority                 | 3                          | 3                                |
| q33_change_probability_12months        | 5                          | 1                                |

Από παραπάνω παρατηρείται ο ξεκάθαρος διαχωρισμός μεταξύ των ατόμων που σκοπεύουν να αλλάξουν εργοδότη (q33 – 5) και των «πιστών» εργαζομένων (q33 – 1).

Πριν αναλυθούν οι δομικές αποκλίσεις των δύο ομάδων, παρουσιάζει ενδιαφέρον το γεγονός ότι οι δύο συστάδες μοιράζονται μια σειρά από πανομοιότυπα, επικρατούντα δημογραφικά και

επαγγελματικά χαρακτηριστικά. Συγκεκριμένα, η επικρατούσα τιμή (mode) και στις δύο συστάδες αφορά τα ακόλουθα χαρακτηριστικά:

1. Φύλο & Ηλικία: Άνδρες, ηλικίας 26-41 ετών (γενιά των Millennials).
2. Κλάδος: Τεχνολογία & Πληροφορική.
3. Εργασιακό Μοντέλο: Τρέχουσα διά ζώσης απασχόληση (q25) με έντονη, ωστόσο, την κοινή προτίμηση για μετάβαση σε υβριδικό μοντέλο εργασίας (q26).
4. Ιστορικό Συμπεριφοράς: Απουσία προηγούμενου ιστορικού Job Hopping (q17 = Όχι) ή εφαρμογής Quiet Quitting (q23 = Όχι).
5. Ψυχομετρικοί Δείκτες: Μέτρια επίπεδα συναισθηματικής εξάντλησης (q28 = 3.0) και εργασιακού στρες (q29 = 3.0).

Μια ιδιαίτερα αξιοσημείωτη διάσταση της ανάλυσης προκύπτει από τη συσχέτιση του μεγέθους της επιχείρησης (q7) με το αντιλαμβανόμενο ενδιαφέρον του εργοδότη για την ευεξία του προσωπικού (q31). Συγκεκριμένα, οι «Εγκλωβισμένοι Φυγάδες» (Συστάδα 1) απασχολούνται κατά κύριο λόγο σε μικρομεσαίες επιχειρήσεις (MME) και βιώνουν χαμηλό εργοδοτικό ενδιαφέρον, ενώ οι «Σταθεροί/Ικανοποιημένοι» (Συστάδα 2) εργάζονται σε μεγάλες ή πολυεθνικές εταιρείες, αναφέροντας μέτρια επίπεδα φροντίδας.

Το εύρημα αυτό έρχεται σε αντίθεση με την παραδοσιακή βιβλιογραφική παραδοχή που θέλει τις πολυεθνικές επιχειρήσεις να λειτουργούν με πιο «απρόσωπο» και γραφειοκρατικό τρόπο. Αντίθετα, υποδηλώνει ότι στην ελληνική πραγματικότητα, οι μεγαλύτεροι οργανισμοί διαθέτουν πιο οργανωμένα τμήματα Διαχείρισης Ανθρώπινων Πόρων (HRM) και δομημένα προγράμματα εταιρικής ευεξίας. Στον αντίποδα, οι Μικρομεσαίες φαίνεται να υστερούν σε κουλτούρα υποστήριξης (perceived organizational support), εμφανίζοντας μια εικόνα διοικητικής απάθειας που λειτουργεί ως καταλύτης για την εργασιακή αποσύνδεση.

Η βαθύτερη διαφοροποίηση των δύο ομάδων εντοπίζεται στη μεταβλητή του οικονομικού εγκλωβισμού (q22). Η Συστάδα 1 αποτελεί την εμπειρική ενσάρκωση του μοντέλου των Hom et al. (Hom, Allen, & Griffith, 2019), για τους «εγκλωβισμένους» εργαζόμενους. Παρά το γεγονός ότι δηλώνουν μέτρια εργασιακή (3.0) και χαμηλή οικονομική (2.0) ικανοποίηση, οι εργαζόμενοι αυτοί παραμένουν στον οργανισμό αποκλειστικά λόγω της αδυναμίας τους να αντιμετωπίσουν το οικονομικό κόστος μιας μετάβασης. Αυτός ο αναγκαστικός εγκλωβισμός δημιουργεί μια κατάσταση διαρκούς νοητικής φυγής. Συγκεκριμένα σκέφτονται την αλλαγή εργοδότη κάθε μήνα (q14), δηλώνουν ρητά πρόθεση αποχώρησης (q18 = Ναι) και αξιολογούν την πιθανότητα πραγματικής φυγής εντός του επόμενου έτους στο μέγιστο επίπεδο (q33 = 5.0).

Η εσωτερική πίεση που βιώνουν οι «Εγκλωβισμένοι Φυγάδες» μεταφράζεται σε άμεση αλλαγή της εργασιακής τους συμπεριφοράς. Θεωρώντας τόσο το Job Hopping όσο και το Quiet Quitting ως ιδιαίτερα ωφέλιμες πρακτικές (4.0), υιοθετούν μια αμυντική στάση στην καθημερινότητά τους, καταβάλλοντας συχνά την ελάχιστη δυνατή προσπάθεια για τη διατήρηση της θέσης τους (q21). Η συμπεριφορά αυτή επιβεβαιώνει ότι το Quiet Quitting δεν αποτελεί μια τυχαία τάση, αλλά έναν συνειδητό μηχανισμό αντισταθμιστικής προσαρμογής (coping mechanism) απέναντι στην υποτιμημένη εργασία και την εργοδοτική αδιαφορία.

Στον αντίποδα, η Συστάδα 2 («Σταθεροί/Ικανοποιημένοι») εκπροσωπεί τα χαρακτηριστικά διακράτησης (retention). Διαθέτοντας υψηλή εργασιακή και οικονομική ικανοποίηση (4.0) και έχοντας μεγαλύτερη επαγγελματική ωριμότητα (20+ έτη εμπειρίας), οι εργαζόμενοι αυτοί δεν βιώνουν οικονομικό εξαναγκασμό, διατηρούν ουδέτερη στάση απέναντι στις πρακτικές αποστασιοποίησης, δεν υιοθετούν τη συμπεριφορά της ελάχιστης προσπάθειας και δηλώνουν μηδενική πρόθεση αποχώρησης ( $q33 = 1.0$ ).

Τα παραπάνω ευρήματα ολοκληρώνουν την μελέτη της πρωτογενούς έρευνας που διεξάχθηκε, παρέχοντας την πλήρη εικόνα για το δείγμα των 120 Ελλήνων συμμετεχόντων. Συνδιαστικά με αυτά του Κεφαλαίου 5 που θα ακολουθήσει, θα συντελέσουν στις τελικές προτάσεις οργανωσιακής στρατηγικής διακράτησης και έλξης προσωπικού στο τελικό *Κεφάλαιο 6*.

## 5. Ανάλυση δευτερογενών δεδομένων & Μοντελοποίηση (EDA & ML)

Μετά την ολοκλήρωση της ανάλυσης και συσταδοποίησης των πρωτογενών δεδομένων, το πέμπτο κεφάλαιο της παρούσας μελέτης εστιάζει στο δεύτερο ερευνητικό σκέλος: την επεξεργασία, ανάλυση και μοντελοποίηση του αναγνωρισμένου δευτερογενούς συνόλου δεδομένων "IBM HR Analytics" (το εν λόγω dataset βρίσκεται στο link: <https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset/data>).

Η συγκεκριμένη διαδικασία λειτουργεί ως ένα proof-of-concept (απόδειξη concept), αναδεικνύοντας τη μεθοδολογία και τα βήματα που μπορεί να ακολουθήσει ένας οργανισμός για την πρόβλεψη της οικειοθελούς αποχώρησης προσωπικού εντός εταιρείας. Παρά τον περιορισμό που προκύπτει από τη συνθετική φύση των δεδομένων της IBM, το dataset προσφέρει μια ολοκληρωμένη βάση για την ανάπτυξη προγνωστικών μοντέλων υψηλής ακρίβειας. Τα ευρήματα που θα προκύψουν από αυτό το κεφάλαιο θα αποτελέσουν το υπόβαθρο για μια συγκριτική αξιολόγηση στο τελικό στάδιο της εργασίας. Στόχος είναι η γεφύρωση των αποτελεσμάτων των δύο σκελών, προκειμένου να αντιπαραβληθούν οι θεωρητικές δομές της "υποθετικής" αυτής εταιρείας με τις πραγματικές, σύγχρονες τάσεις που καταγράφηκαν στην ελληνική αγορά εργασίας, αναδεικνύοντας στρατηγικές περιοχές για τη βελτίωση του Work-Life Balance και τη συγκράτηση του ταλέντου. Ο κώδικας, όπως και στο πρώτο σκέλος της διπλωματικής, θα βρίσκεται αναρτημένος στο αποθετήριο Github, που θα βρίσκεται στο *Παράρτημα II*. Ο σύνδεσμος του θα βρίσκεται στο παράρτημα μαζί με εικόνες της εκτέλεσης του. Ωστόσο, μερικά από τα πιο κρίσιμα αποτελέσματα του κώδικα θα χρησιμοποιηθούν εντός του κεφαλαίου.

### 5.1 Προεπεξεργασία δεδομένων

Η βάση για τη διασφάλιση της αξιοπιστίας και της γενικευτικής ικανότητας των προγνωστικών μοντέλων έγκειται στην κατάλληλη προεπεξεργασία του συνόλου δεδομένων. Το δευτερογενές συνθετικό σύνολο δεδομένων "IBM HR Analytics" αποτελείται συνολικά από 35 μεταβλητές (στήλες). Κατά την αρχική διερεύνηση του dataset, 26 μεταβλητές αναγνωρίστηκαν ως αριθμητικές - κυρίως τύπου δεδομένων int64 - και 9 ως κατηγορικές (object/string).

```

1 #fundamental libraries for this analysis
2 import pandas as pd
3 import numpy as np
4
5 #loading the dataset
6 ibm_ds = pd.read_csv('C:/Users/chris/Desktop/Masters Degree/THESIS AND
  PROPOSAL/datasets/IBM-HR-Employee-Attrition.csv', delimiter=',')
7 #showing info of the dataset
8 print(ibm_ds.info())
9 print(ibm_ds.head())
✓ [1] 47ms

```

```

<class 'pandas.DataFrame'>
RangeIndex: 1470 entries, 0 to 1469
Data columns (total 35 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Age                                   1470 non-null   int64
1   Attrition                            1470 non-null   str
2   BusinessTravel                       1470 non-null   str
3   DailyRate                            1470 non-null   int64
4   Department                           1470 non-null   str
5   DistanceFromHome                     1470 non-null   int64
6   Education                             1470 non-null   int64
7   EducationField                       1470 non-null   str
8   EmployeeCount                        1470 non-null   int64
9   EmployeeNumber                       1470 non-null   int64
10  EnvironmentSatisfaction               1470 non-null   int64
11  Gender                               1470 non-null   str
12  HourlyRate                           1470 non-null   int64
13  JobInvolvement                       1470 non-null   int64

```

Εικόνα 40 - Μετατροπή CSV σε Pandas DataFrame και παρουσίαση περιεχομένων του

Πραγματοποιήθηκε έλεγχος για τον εντοπισμό τυχόν διπλοεγγραφών και ελλειπουσών τιμών. Από τον έλεγχο διαπιστώθηκε ότι το συγκεκριμένο σύνολο δεδομένων είναι πλήρες και στερείται κενών τιμών, γεγονός που καθιστά περιττή την εφαρμογή τεχνικών imputation. Σε αντίθετη περίπτωση, όπως επισημαίνεται από τον Geron (Géron, 2019), η διαχείριση των ελλειπουσών τιμών θα απαιτούσε είτε τη διαγραφή των αντίστοιχων παρατηρήσεων είτε τον καταλογισμό τους με τη χρήση στατιστικών δεικτών κεντρικής τάσης (όπως ο μέσος όρος ή η διάμεσος), ή ακόμη και την πλήρη απάλειψη μιας μεταβλητής στην περίπτωση που το ποσοστό ελλιπών δεδομένων υπερέβαινε ένα κρίσιμο πλήθος.

Προκειμένου να βελτιστοποιηθεί η υπολογιστική απόδοση και να αποφευχθεί η εισαγωγή «θορύβου» κατά τη φάση εκπαίδευσης των αλγορίθμων, αποφασίστηκε η αφαίρεση τεσσάρων μεταβλητών από το αρχικό σύνολο δεδομένων. Η πρώτη μεταβλητή ονόματι EmployeeNumber αποτελεί το μοναδικό αναγνωριστικό (ID) κάθε εργαζομένου. Καθώς δεν φέρει καμία στατιστική ή επιχειρησιακή πληροφορία, αποκλείστηκε από τη μοντελοποίηση. Οι επόμενες τρείς, EmployeeCount, StandardHours και Over18, χαρακτηρίζονται ως χαρακτηριστικά μηδενικής

διακύμανσης (zero-variance features), καθώς περιέχουν μία και μοναδική τιμή για το σύνολο των παρατηρήσεων (η τιμή 1, η τιμή 80 και η τιμή 'Υ' αντίστοιχα). Η έλλειψη μεταβλητότητας τις καθιστά μη πληροφοριακές για οποιονδήποτε αλγόριθμο Μηχανικής Μάθησης.

Ιδιαίτερη έμφαση δόθηκε στον ορθό διαχωρισμό μεταξύ ποσοτικών και ποιοτικών δεδομένων. Μεταβλητές όπως οι JobLevel, StockOptionLevel, Education, EnvironmentSatisfaction, JobInvolvement, JobSatisfaction, PerformanceRating, RelationshipSatisfaction και WorkLifeBalance, παρόλο που αρχικά εμφανίζονται με αριθμητικές τιμές στο dataset, αποτελούν στην πραγματικότητα τακτικές (ordinal) κατηγορικές μεταβλητές που βασίζονται σε ψυχομετρικές κλίμακες (π.χ. κλίμακες Likert 1-4 ή 1-5). Για τον λόγο αυτό, οι εν λόγω μεταβλητές απομονώθηκαν προκειμένου να αντιμετωπιστούν με τις κατάλληλες τεχνικές κωδικοποίησης.

Για τις εναπομείνουσες γνήσιες ποσοτικές μεταβλητές (π.χ. MonthlyIncome, Age, TotalWorkingYears), ο τύπος δεδομένων μετατράπηκε από int64 σε float64. Η μετατροπή αυτή κρίθηκε απαραίτητη για τη διασφάλιση της υπολογιστικής ομοιογένειας και τη βέλτιστη συμβατότητα με τις διαδικασίες κανονικοποίησης (feature scaling) που ακολουθούν. Αντίστοιχα, όλες οι κατηγορικές μεταβλητές τυποποιήθηκαν σε μορφή συμβολοσειράς (string), θέτοντας τις βάσεις για το επόμενο στάδιο της Ερευνητικής Ανάλυσης Δεδομένων (EDA).

## 5.2 Ερευνητική ανάλυση δεδομένων – EDA

### 5.2.1 Περιγραφική Στατιστική και Μονομετάβλητη ανάλυση κατανομών

Έπειτα από την ολοκλήρωση της προεπεξεργασίας των δεδομένων έρχεται το στάδιο της ερευνητικής ανάλυσης του συνόλου δεδομένων. Σε αυτό το στάδιο θα πραγματοποιηθεί Exploratory Data Analysis (EDA), συνδιαστικά με εύρεση/διαχείριση ακραίων τιμών και εύρεση μαθηματικών συσχετίσεων μεταξύ των μεταβλητών (στηλών). Η διαδικασία αυτή βασίζεται στη θεμελιώδη φιλοσοφία του John W. Tukey (Tukey, 1977), ο οποίος εισήγαγε τον όρο EDA προκειμένου να περιγράψει την προσέγγιση του αναλυτή ως «ντετέκτιβ» που αναζητά κρυμμένα μοτίβα, ασυνήθιστες συμπεριφορές και στατιστικές δομές στα δεδομένα, προτού εφαρμοστεί οποιοδήποτε προγνωστικό μοντέλο. Το πρώτο βήμα στη διεκπεραίωση του εν λόγω σταδίου ξεκινά με τον υπολογισμό βασικών στατιστικών μετρικών κάθε αριθμητικής στήλης (π.χ. μέσο όρο, διάμεσο, τυπική απόκλιση, μέγιστη/ελάχιστη τιμή). Συνδιαστικά με την οπτικοποίηση των δεδομένων κάθε σχετικής αριθμητικής στήλης, με τη βοήθεια της python βιβλιοθήκης matplotlib.pyplot, θα γίνει ο αρχικός έλεγχος για την κατανόηση του συνόλου.



```

import matplotlib.pyplot as plt

#putting all the numeric columns shown by the previous block in a list, to later on
show relevant info about them
numerical_columns = ['Age',
                     'DailyRate',
                     'HourlyRate',
                     'MonthlyRate',
                     'DistanceFromHome',
                     'MonthlyIncome',
                     'PercentSalaryHike',
                     'NumCompaniesWorked',
                     'TrainingTimesLastYear',
                     'YearsAtCompany',
                     'YearsInCurrentRole',
                     'YearsSinceLastPromotion',
                     'YearsWithCurrManager',
                     'TotalWorkingYears'
                    ]

#looping per numerical column
for column in numerical_columns:
    #all numeric columns will be treated as numbers with the code below
    ibm_ds[column] = np.float64(ibm_ds[column])

    #showing useful information per column (Mean/Median, SD, Min/Max)
    print("Category of",column)
    print("Mean :",ibm_ds[column].mean())
    print("Median :",ibm_ds[column].median())
    print("Standard Deviation :",ibm_ds[column].std())
    print("Minimum value :",ibm_ds[column].min())
    print("Maximum value :",ibm_ds[column].max())
    print("")


    #creating the plots accordingly, choosing 7 bins for visibility
    plt.figure(figsize=(8,5))
    plt.hist(ibm_ds[column], bins=7, color="skyblue", edgecolor="black")
    plt.title("Distribution of "+column+" within the dataset")
    plt.xlabel(column)
    plt.ylabel("Frequency")
    plt.grid(True, linestyle="--", alpha=0.6)
    plt.show()

```

Εικόνα 41 - Πηγαίος κώδικας παρουσίασης αριθμητικών μεταβλητών


Ακολουθούν μερικά ιστογράμματα που βοηθούν στην κατανόηση των αριθμητικών χαρακτηριστικών του συνόλου:

Category of Age  
 Mean : 36.923809523809524  
 Median : 36.0  
 Standard Deviation : 9.135373489136732  
 Minimum value : 18.0  
 Maximum value : 60.0




Εικόνα 42 - Κατανομή μεταβλητής Age

Category of DistanceFromHome  
 Mean : 9.19251700680272  
 Median : 7.0  
 Standard Deviation : 8.106864435666074  
 Minimum value : 1.0  
 Maximum value : 29.0




Εικόνα 43 - Κατανομή μεταβλητής DistanceFromHome

Category of MonthlyIncome  
 Mean : 6502.931292517007  
 Median : 4919.0  
 Standard Deviation : 4707.956783097994  
 Minimum value : 1009.0  
 Maximum value : 19999.0




Εικόνα 44 - Κατανομή μεταβλητής MonthlyIncome

Category of YearsAtCompany  
 Mean : 7.0081632653061225  
 Median : 5.0  
 Standard Deviation : 6.126525152403569  
 Minimum value : 0.0  
 Maximum value : 40.0




Εικόνα 45 - Κατανομή μεταβλητής YearsAtCompany

Category of YearsInCurrentRole  
 Mean : 4.229251786680272  
 Median : 3.0  
 Standard Deviation : 3.623137834678628  
 Minimum value : 0.0  
 Maximum value : 18.0



Εικόνα 46 - Κατανομή μεταβλητής YearsInCurrentRole


Category of YearsSinceLastPromotion  
 Mean : 2.1877551828408164  
 Median : 1.0  
 Standard Deviation : 3.222438279137967  
 Minimum value : 0.0  
 Maximum value : 15.0




Εικόνα 47 - Κατανομή μεταβλητής YearsSinceLastPromotion

(Σημείωση: Τα αντίστοιχα διαγράμματα για το σύνολο των υπόλοιπων μεταβλητών παρατίθενται στο Παράρτημα ΙΙΙ, ενώ ο πλήρης πηγαίος κώδικας της οπτικοποίησης έχει αναρτηθεί στο σχετικό αποθετήριο GitHub, βλ. Παράρτημα ΙΙ)


Από τη μελέτη των παραπάνω διαγραμμάτων και των περιγραφικών δεικτών, προκύπτουν σημαντικά συμπεράσματα για τη δημογραφική και οργανωσιακή σύνθεση του δείγματος της IBM. Ξεκινώντας με το ηλικιακό προφίλ του συνόλου, παρατηρείται ότι αποτελείται κυρίως από εργαζόμενους παραγωγικής ηλικίας μεταξύ 25 και 40 ετών, με την κατανομή να προσεγγίζει την κανονική. Οι μηνιαίες απολαβές εμφανίζουν επίσης θετική ασυμμετρία, με το μεγαλύτερο ποσοστό των εργαζομένων να συγκεντρώνεται στο εύρος των 2.000 έως 6.000 δολαρίων, ενώ παρατηρείται μια μακρά «ουρά» υψηλόμισθων στελεχών. Η πλειοψηφία του προσωπικού βρίσκεται στον οργανισμό για ένα διάστημα μεταξύ 1 και 10 ετών. Παράλληλα, ο μέσος χρόνος που μεσολαβεί από την τελευταία προαγωγή προσεγγίζει τα δύο έτη, γεγονός που υποδηλώνει μια σχετικά σταθερή ροή εσωτερικής εξέλιξης, αν και η κατανομή εμφανίζει μεμονωμένες περιπτώσεις μεγάλης στασιμότητας. Η ίδια διαδικασία εκτελέστηκε για τις κατηγορικές μεταβλητές του συνόλου. Παρακάτω ακολουθούν επιπρόσθετα ραβδογράμματα συχνότητων για κάποιες από αυτές τις μεταβλητές:




Εικόνα 48 – Πλήθος δειγμάτων ανά Department




Εικόνα 49 - Πλήθος δειγμάτων ανά JobLevel




Εικόνα 50 - Πλήθος δειγμάτων ανά JobRole



Εικόνα 51 - Πλήθος δειγμάτων ανά PerformanceRating



Εικόνα 52 - Πλήθος δειγμάτων ανά WorkLifeBalance



Εικόνα 53 - Πλήθος δειγμάτων ανά Attrition (target value)

(Σημείωση: Περαιτέρω φωτογραφίες των αποτελεσμάτων θα βρίσκονται στο Παράρτημα. Ο κώδικας βρίσκεται στο Github, βλ. Παράρτημα II )

Βάσει των διαγραμμάτων των κατηγορικών τιμών συμπεραίνεται, παράλληλα με τα προηγούμενα ευρήματα, πως ο πλυθησμός του συνόλου αποτελείται κυρίως από προσωπικό στο τμήμα έρευνας και πωλήσεων, με το μεγαλύτερο πλήθος ατόμων να συγκεντρώνεται στις κατώτατες ιεραρχικά θέσεις κάθε τμήματος. Οι περισσότεροι εργαζόμενοι έχουν ικανοποιητικές αξιολογήσεις (3 και 4 στα 5), συνδιαστικά με αξιόλογη ικανοποίηση από την δουλειά και το περιβάλλον της. Τέλος, η εξαρτημένη μεταβλητή Attrition, που παρουσιάζει τους εργαζομένους που έφυγαν από την εταιρεία, δείχνει πως η πλειοψηφία των εργαζομένων είναι πιστή στην εταιρεία με ένα μικρό ποσοστό εξαιρέσεων, δείχνοντας πως το τρέχον σύνολο δεδομένων είναι μη ισορροπημένο.

### 5.2.2 Ανάλυση και Διαχείριση Ακραίων Τιμών

Στη συνέχεια θα βρεθούν οι ακραίες τιμές του dataset των ποσοτικών μεταβλητών του. Η ανίχνευση τους συμβάλλει στη θωράκιση της ποιότητας των δεδομένων και διευκολύνει τις μεταγενέστερες υπολογιστικές εφαρμογές.

Η μεθοδολογία βασίζεται στη στατιστική προσέγγιση των «Φρακτών του Tukey» (Tukey's Fences, (Tukey, 1977)). Σύμφωνα με τον Tukey, ως ακραίες τιμές ορίζονται όσες παρατηρήσεις βρίσκονται εκτός των εξωτερικών φρακτών (outer fences), οι οποίοι προσδιορίζονται μαθηματικά από τους ακόλουθους τύπους:

$$\text{Lower Bound: } Q1 - 3 * IQR$$

$$\text{Upper Bound : } Q3 + 3 * IQR$$

Όπου  $Q1$  είναι το πρώτο τεταρτημόριο (25ο εκατοστημόριο),  $Q3$  το τρίτο τεταρτημόριο (75ο εκατοστημόριο) και  $IQR$  το ενδοτεταρτημοριακό εύρος ( $Q3 - Q1$ ). Η επιλογή του αυστηρού συντελεστή 3 (αντί του τυπικού 1.5) έγινε εσκεπώς, προκειμένου να απομονωθούν αποκλειστικά οι έκδηλα ακραίες τιμές (extreme outliers) και να αξιολογηθεί αν χρειάζεται να αποφευχθεί ο επηρεασμός του δείγματος από ήπιες φυσιολογικές διακυμάνσεις. Η ανίχνευση επεκτάθηκε σε «πλαισιωμένη ανάλυση ακραίων τιμών» (Contextual Outlier Analysis). Μέσω ενός αυτοματοποιημένου αλγορίθμου (διπλή for loop) στο περιβάλλον ανάπτυξης της Python, εξετάστηκαν συνδυαστικά όλες οι πιθανές αλληλεπιδράσεις μεταξύ των βασικών ποσοτικών μεταβλητών και των κατηγορικών μεταβλητών που ορίζουν το οργανωσιακό πλαίσιο του εργαζομένου.

```

#search for outliers and extreme values

numericals_outlier_check = [
    'MonthlyIncome',
    'TotalWorkingYears',
    'DistanceFromHome',
    'NumCompaniesWorked',
    'YearsAtCompany',
    'YearsInCurrentRole',
    'YearsSinceLastPromotion'
]

# Λίστα με τις κατηγορηματικές μεταβλητές πλαισίωσης (Categorical Context Features)
categoricals_outlier_check = [
    'Department',
    'JobRole',
    'JobLevel'
]

def find_outliers (ds, numerical_column_name, groupby_col):
    q1 = ds[numerical_column_name].quantile(0.25)
    q3 = ds[numerical_column_name].quantile(0.75)
    IQR = q3 - q1
    lower = q1 - 3 * IQR
    upper = q3 + 3 * IQR
    print(f"{lower}\n{upper}")
    outliers = ds[(ds[numerical_column_name] < lower) | (ds[numerical_column_name] >
        upper)]
    print (f"Lower quantile: {q1}\nUpper quantile: {q3}")
    #creating the scatterplot that shows each values, having a line on the upper
    limit.
    plt.scatter(outliers[groupby_col] ,outliers[numerical_column_name],
        color='blue', marker='o')
    plt.ylabel(numerical_column_name)
    plt.xlabel(groupby_col)
    if len(outliers[groupby_col].unique()) > 3: plt.xticks(rotation=65)
    # plt.title('Prices per square meter Outliers per city')
    plt.axhline(y=upper, color='r', linestyle='--', label='Upper Bound Extremes')
    plt.show()

for nc in numericals_outlier_check:
    for cc in categoricals_outlier_check:
        find_outliers(ibm_ds, nc, cc)

```

Εικόνα 54 - Πηγαίος κώδικας ελέγχου ακραίων τιμών


Ποσοτικές μεταβλητές ελέγχου:

'MonthlyIncome', 'TotalWorkingYears', 'DistanceFromHome', 'NumCompaniesWorked', 'YearsAtCompany', 'YearsInCurrentRole', 'YearsSinceLastPromotion'


Κατηγορικές μεταβλητές ελέγχου:

'Department', 'JobRole', 'JobLevel'


Κατά την εκτέλεση του script, διαπιστώθηκε η πλήρης απουσία extreme outliers για τους συνδυασμούς των μεταβλητών *MonthlyIncome*, *TotalWorkingYears*, *DistanceFromHome* και *NumCompaniesWorked* σε σχέση με οποιοδήποτε κατηγορικό πλαίσιο (*Department*, *JobLevel*, *JobRole*). Αντίθετα, εντοπίστηκαν στατιστικά σημαντικές ακραίες τιμές στις μεταβλητές που σχετίζονται άμεσα με τον χρόνο παραμονής και την εξέλιξη των εργαζομένων στον οργανισμό. Τα κυριότερα ευρήματα οπτικοποιήθηκαν μέσω διαγραμμάτων διασποράς (scatter plots), στα οποία αποτυπώνεται με ευκρίνεια η γραμμή του προαναφερθέντου ανώτατου καθολικού ορίου (*Upper Bound*):




Εικόνα 55 - Outliers YearsAtCompany ανα Department



Εικόνα 56 - Outliers YearsAtCompany ανα JobRole



Εικόνα 57 - - Outliers YearsSinceLastPromotion ανα JobRole



Εικόνα 58 - - Outliers YearsSinceLastPromotion ανα Department

Από την αξιολόγηση των παραπάνω διαγραμμάτων προκύπτει ότι οι εν λόγω ακραίες τιμές αντιπροσωπεύουν μια πολύ συγκεκριμένη και υπαρκτή ομάδα εργαζομένων. Πρόκειται για ανώτερα, ιστορικά στελέχη της εταιρείας, τα οποία καταγράφουν πάνω από 27 έτη συνεχούς προϋπηρεσίας στον οργανισμό. Παράλληλα, εμφανίζουν μεγάλο αριθμό ετών χωρίς προαγωγή, γεγονός που ερμηνεύεται επιχειρησιακά από το ότι βρίσκονται ήδη στην κορυφή της ιεραρχικής πυραμίδας, όπου δεν υφίσταται περαιτέρω δυνατότητα παραδοσιακής βαθμολογικής ανέλιξης.

Καθώς οι παρατηρήσεις αυτές αποτελούν απολύτως έγκυρα επιχειρησιακά δεδομένα και όχι σφάλματα μέτρησης ή καταχώρησης, αποφασίστηκε η διατήρησή τους στο dataset. Επιπλέον, οι tree-based αλγόριθμοι που θα χρησιμοποιηθούν στη συνέχεια (Random Forest, XGBoost, LightGBM) παρουσιάζουν εγγενή ανθεκτικότητα στην παρουσία ακραίων τιμών, καθώς οι διαχωρισμοί στους κόμβους των δέντρων βασίζονται σε διατάξεις τιμών και δεν επηρεάζονται από το μέγεθος των ακραίων τιμών με τον τρόπο που επηρεάζονται τα γραμμικά μοντέλα.

### 5.2.3 Διμεταβλητή ανάλυση στην εξαρτημένη μεταβλητή Attrition

Εξίσου σημαντικό σκέλος μιας στατιστικής ανάλυσης προ της εφαρμογής αλγορίθμων Μηχανικής Μάθησης αποτελεί η διερεύνηση τυχόν συσχετίσεων των χαρακτηριστικών με την εξαρτημένη μεταβλητή-στόχο (Attrition). Το βασικό μέσο για την επίτευξη αυτού του στόχου είναι η διμεταβλητή ανάλυση (Bivariate Analysis). Η μονομεταβλητή ανάλυση περιορίζεται στο να περιγράψει πώς κατανέμεται μια μεμονωμένη μεταβλητή (π.χ. ο μέσος μηνιαίος μισθός), ενώ η διμεταβλητή ανάλυση μας επιτρέπει να εξετάσουμε εάν η μεταβολή μιας μεταβλητής σχετίζεται στατιστικά με τη μεταβολή μιας άλλης (Mann, 2013). Στο πλαίσιο των κατηγορικών δεδομένων, η προσέγγιση αυτή εστιάζει στη χρήση πινάκων συνάφειας (contingency tables) και ραβδογραμμάτων με σκοπό την αποκάλυψη υποκείμενων μοτίβων εξάρτησης (Mann, 2013).



Στην παρούσα ενότητα, η διμεταβλητή ανάλυση χρησιμοποιείται προκειμένου να εξεταστεί η επίδραση των ανεξάρτητων ποσοτικών και ποιοτικών μεταβλητών πάνω στην εξαρτημένη μεταβλητή Attrition. Η διαδικασία αυτή χρησιμεύει ως ένα ενδιάμεσο στάδιο φιλτραρίσματος και επιλογής χαρακτηριστικών (feature selection filtering), καθώς επιτρέπει τον έγκαιρο εντοπισμό των μεταβλητών που παρουσιάζουν τη μεγαλύτερη διακριτική ικανότητα (discriminative power). Ως εκ τούτου, οι μεταβλητές αυτές αναμένεται να εισφέρουν τη μεγαλύτερη πληροφοριακή χρησιμότητα (feature importance) κατά την επακόλουθη εκπαίδευση των προγνωστικών μοντέλων (Johnson, 1988).

Λόγω της έντονης ανισορροπίας των κλάσεων που διαπιστώθηκε στο προηγούμενο στάδιο, η διμεταβλητή απεικόνιση πραγματοποιήθηκε με τη χρήση stacked & filled count plots.

```
import seaborn as sb

#bar charts for bivariate analysis
def bivariateBarCharts(dataset, index_columns, target_column):
    for index_col in dataset[index_columns]:


        if index_col != target_column:
            # figure creation with 2 plots next to each other (1 row with 2 cols per
            # index column)
            fig, axes = plt.subplots(1, 2, figsize=(16, 6))
            sb.histplot(
                data=dataset,
                x=dataset[index_col],
                hue=dataset[target_column],
                multiple="stack",
                shrink=0.8,
                ax=axes[0] # left alignment
            )
            axes[0].set_title(f"Absolute Counts by {index_col}", fontsize=12,
                             fontweight='bold')
            axes[0].set_ylabel("Number of Employees")
            axes[0].tick_params(axis='x', rotation=45)

            sb.histplot(
                data=dataset,
                x=dataset[index_col],
                hue=dataset[target_column],
                multiple="fill",
                shrink=0.8,
                ax=axes[1] # right alignment
            )
            axes[1].set_title(f"Proportions by {index_col}", fontsize=12,
                              fontweight='bold')
            axes[1].set_ylabel("Proportion (%)")
            axes[1].tick_params(axis='x', rotation=45)
            plt.tight_layout()
            plt.show()


bivariateBarCharts(ibm_ds, categorical_columns+numerical_columns, 'Attrition')
```

Εικόνα 59 - Κώδικας διμεταβλητής ανάλυσης


Η προσέγγιση αυτή επιτρέπει τον παράλληλο έλεγχο τόσο των απόλυτων μεγεθών όσο και των σχετικών αναλογιών του Attrition εντός κάθε υπό-ομάδας, διασφαλίζοντας ότι οι τάσεις αποχώρησης σε ολιγοπληθείς κατηγορίες προσωπικού δεν θα επισκιαστούν από τον συνολικό όγκο των δεδομένων. Ακολουθούν κάποια από τα ραυδογράμματα που παράχθηκαν:




Εικόνα 60 - Διμετάβλητη ανάλυση Attrition / Age




Εικόνα 61 - Διμετάβλητη ανάλυση Attrition / JobLevel



Εικόνα 62 - Διμετάβλητη ανάλυση Attrition / OverTime



Εικόνα 63 - Διμετάβλητη ανάλυση Attrition / TotalWorkingYears



Εικόνα 64 - Διμετάβλητη ανάλυση Attrition / YearsAtCompany

(Σημείωση: Τα αντίστοιχα διαγράμματα για το σύνολο των υπόλοιπων μεταβλητών παρατίθενται στο Παράρτημα III, ενώ ο πλήρης πηγαίος κώδικας της οπτικοποίησης έχει αναρτηθεί στο σχετικό αποθετήριο GitHub, βλ. Παράρτημα II)

Από τη συνδυαστική μελέτη των παραχθέντων διαγραμμάτων και των σχετικών αναλογιών, εξάγονται ιδιαίτερα χρήσιμα συμπεράσματα για τους παράγοντες που επηρεάζουν την κινητικότητα του προσωπικού. Αρχικά, εργαζόμενοι που παρουσιάζουν χαμηλές τιμές στις μεταβλητές Age, JobLevel, MonthlyIncome, YearsAtCompany, YearsInCurrentRole και TotalWorkingYears εμφανίζουν στατιστικά σημαντικά μεγαλύτερη πιθανότητα οικειοθελούς αποχώρησης. Το εύρημα αυτό υποδηλώνει ότι το φαινόμενο του Attrition πλήττει κυρίως το νεότερο ηλικιακά και ιεραρχικά προσωπικό, το οποίο δεν έχει προλάβει να αναπτύξει ισχυρούς δεσμούς με τον οργανισμό.


Οι εργαζόμενοι που απαιτείται να ταξιδεύουν συχνά για επαγγελματικούς λόγους (*BusinessTravel = Travel\_Frequently*), καθώς και εκείνοι που εργάζονται συστηματικά υπερωρίες (*OverTime = Yes*), καταγράφουν εξαιρετικά αυξημένα ποσοστά αποχώρησης, γεγονός που αναδεικνύει την πίεση και την επαγγελματική εξουθένωση ως κρίσιμους παράγοντες κινδύνου.

Αντιθέτως, το προσωπικό που απασχολείται στο τμήμα Έρευνας και Ανάπτυξης (*Research & Development*) εμφανίζει αυξημένη εργασιακή σταθερότητα. Αντίθετα, συγκεκριμένοι ρόλοι εντός της εταιρείας, όπως οι Τεχνικοί Εργαστηρίου (*Laboratory Technicians*), οι Εκπρόσωποι Πωλήσεων (*Sales Representatives*) και το προσωπικό Ανθρωπίνων Πόρων (*Human Resources*), παρουσιάζουν δυσανάλογα υψηλά ποσοστά attrition.

Τέλος, από την ανάλυση των προσωπικών χαρακτηριστικών προκύπτει ότι οι άνδρες εργαζόμενοι παρουσιάζουν ελαφρώς μεγαλύτερη τάση αποχώρησης συγκριτικά με τις γυναίκες. Επιπλέον, οι άγαμοι εργαζόμενοι εμφανίζουν αυξημένη κινητικότητα σε σχέση με τους έγγαμους ή διαζευγμένους συναδέλφους τους, πιθανώς λόγω μειωμένων οικογενειακών υποχρεώσεων που διευκολύνουν την αλλαγή εργασιακού περιβάλλοντος.

## 5.2.4 Ανάλυση Γραμμικών Συσχετίσεων (Correlation Matrix / Heatmap)

Στο τελευταίο στάδιο της Ερευνητικής Ανάλυσης Δεδομένων (EDA) περιλαμβάνεται η μελέτη των γραμμικών συσχετίσεων μεταξύ των αριθμητικών μεταβλητών του συνόλου δεδομένων. Για τον σκοπό αυτό, υπολογίστηκε ο συντελεστής γραμμικής συσχέτισης του Pearson για κάθε ζεύγος μεταβλητών και τα αποτελέσματα οπτικοποιήθηκαν μέσω ενός χάρτη θερμότητας (Correlation Heatmap), στον οποίο η μεταβλητή-στόχος Attrition έχει μετατραπεί σε δυαδική μορφή (Boolean: 1 για Yes, 0 για No) μέσω One-Hot Encoding:



Εικόνα 65 - Πίνακας συσχετίσεων

Από την αξιολόγηση του χάρτη θερμότητας που παράχθηκε προκύπτουν τρεις διακριτές ζώνες ισχυρών στατιστικών συσχετίσεων. Αρχικά καταγράφεται μια σχεδόν τέλεια γραμμική συσχέτιση μεταξύ του μηνιαίου εισοδήματος (MonthlyIncome) και του ιεραρχικού επιπέδου (JobLevel) με συντελεστή  $r = 0.95$ . Παράλληλα, η μεταβλητή των συνολικών ετών προϋπηρεσίας (TotalWorkingYears) εμφανίζει ισχυρή θετική συσχέτιση τόσο με το JobLevel ( $r = 0.78$ ) όσο και με το MonthlyIncome ( $r = 0.77$ ). Οι συσχετίσεις αυτές αποτυπώνουν μια παραδοσιακή εταιρική δομή, όπου η οικονομική και βαθμολογική εξέλιξη είναι άμεσα συνυφασμένη με τη συνολική εργασιακή εμπειρία.

Εντοπίζεται, επιπλέον, μια ομάδα υψηλών συσχετίσεων μεταξύ των μεταβλητών που μετρούν τον χρόνο παραμονής του εργαζομένου στον οργανισμό. Συγκεκριμένα, τα έτη στην εταιρεία (YearsAtCompany) συσχετίζονται έντονα με τα έτη στον τρέχοντα ρόλο (YearsInCurrentRole,  $r = 0.76$ ), τα έτη με τον ίδιο προϊστάμενο (YearsWithCurrManager,  $r = 0.77$ , καθώς και με τα έτη από την

τελευταία προαγωγή (YearsSinceLastPromotion,  $r = 0.62$ ). Επιπροσθέτως, η μεταβλητή του ποσοστού αύξησης του μισθού (PercentSalaryHike) παρουσιάζει ισχυρή θετική συσχέτιση ( $r = 0.77$ ) αποκλειστικά με την αξιολόγηση απόδοσης (PerformanceRating), επιβεβαιώνοντας ότι η πολιτική αυξήσεων της επιχείρησης είναι προσανατολισμένη στην απόδοση.

Η ύπαρξη συντελεστών συσχέτισης που αγγίζουν ή υπερβαίνουν το 0.75 (όπως στην περίπτωση των μεταβλητών MonthlyIncome και JobLevel με  $r = 0.95$ ) αποτελεί σαφή ένδειξη του φαινομένου της πολυσυγγραμμικότητας (multicollinearity). Σύμφωνα με τους Johnson και Wichern (2019), η συνύπαρξη μεταβλητών με υψηλή γραμμική εξάρτηση σε κλασικά στατιστικά μοντέλα (όπως η Γραμμική ή η Λογιστική Παλινδρόμηση) προκαλεί σημαντική αστάθεια στην εκτίμηση των συντελεστών, διογκώνει τις διακυμάνσεις τους και δυσχεραίνει την ερμηνεία της συνεισφοράς κάθε χαρακτηριστικού (Johnson, 1988).

Ωστόσο, η επιλογή της παρούσας διατριβής θα βασιστεί περισσότερο σε tree-based ensemble αλγορίθμους (*Random Forest*, *XGBoost*, *LightGBM*), που προσφέρουν εγγενή προστασία έναντι αυτού του προβλήματος (Bruce, Bruce, & Gedeck, 2020). Τέτοιοι αλγόριθμοι αυτοί διαχειρίζονται αποτελεσματικά τις συσχετισμένες μεταβλητές κατά τη διαδικασία επιλογής των διαχωρισμών στους κόμβους (node splits), καθώς επιλέγουν το χαρακτηριστικό με τη μεγαλύτερη πληροφοριακή χρησιμότητα σε κάθε βήμα, χωρίς η προγνωστική τους ισχύς να φθίνει από την παρουσία πλεονάζουσών γραμμικών σχέσεων (Bruce, Bruce, & Gedeck, 2020).

Τέλος, εξετάζοντας την τελευταία σειρά του πίνακα, η οποία αποτυπώνει τη γραμμική συσχέτιση των χαρακτηριστικών με το *Attrition\_Yes*, παρατηρείται ότι όλοι οι συντελεστές είναι εξαιρετικά χαμηλοί, με τους ισχυρότερους (αρνητικούς) να εντοπίζονται στα JobLevel ( $r = -0.17$ ), MonthlyIncome ( $r = -0.16$ ), TotalWorkingYears ( $r = -0.17$ ) και Age ( $r = -0.16$ ).

Το γεγονός ότι καμία μεμονωμένη μεταβλητή δεν εμφανίζει ισχυρή γραμμική συσχέτιση με την αποχώρηση των εργαζομένων αποτελεί μια κρίσιμη διαπίστωση: το φαινόμενο του Attrition είναι πολυπαραγοντικό και χαρακτηρίζεται από μη γραμμικές αλληλεπιδράσεις. Η διαπίστωση αυτή δικαιολογεί πλήρως και τεκμηριώνει την ανάγκη επιστράτευσης προηγμένων μοντέλων Μηχανικής Μάθησης, τα οποία είναι σε θέση να χαρτογραφήσουν τις πολύπλοκες και μη γραμμικές σχέσεις που οι παραδοσιακές στατιστικές μεθοδολογίες αδυνατούν να εντοπίσουν.

## 5.3 Feature Engineering

Μετά την ολοκλήρωση της Ερευνητικής Ανάλυσης Δεδομένων (EDA), το επόμενο καθοριστικό στάδιο προ της εκπαίδευσης των μοντέλων είναι η Μηχανική Χαρακτηριστικών (Feature Engineering). Στο στάδιο αυτό, τα δεδομένα μετασχηματίζονται με τέτοιο τρόπο ώστε να μεγιστοποιηθεί η πληροφοριακή τους αξία και να καταστούν συμβατά με τις μαθηματικές απαιτήσεις των αλγορίθμων Μηχανικής Μάθησης.

### 5.3.1 Κωδικοποίηση Κατηγορικών Μεταβλητών (One-Hot Encoding)

Οι περισσότεροι αλγόριθμοι Μηχανικής Μάθησης απαιτούν αποκλειστικά αριθμητικούς πίνακες εισόδου για την εκτέλεση των μαθηματικών τους πράξεων. Για τον λόγο αυτό, οι κατηγορικές μεταβλητές του συνόλου δεδομένων πρέπει να μετασχηματιστούν. Η βασική μέθοδος που επιλέχθηκε

για τις ονομαστικές (nominal) μεταβλητές είναι η κωδικοποίηση One-Hot (One-Hot Encoding), η οποία, σύμφωνα με τους Kuhn και Johnson (2019), αποτελεί μια απαραίτητη «γέφυρα» για τη μετατροπή ποιοτικών δεδομένων σε μορφή κατάλληλη για μοντελοποίηση (Kuhn & Kjell, 2019).

Η μέθοδος One-Hot Encoding μετατρέπει κάθε κατηγορική μεταβλητή που διαθέτει  $k$  διακριτές κατηγορίες σε  $k$  νέες δυαδικές μεταβλητές (Boolean/Dummy variables) με τιμές 0 (False) ή 1 (True), διατηρώντας παράλληλα τον αρχικό αριθμό των παρατηρήσεων (γραμμών). Για παράδειγμα, η μεταβλητή του φύλου (Gender), η οποία αποτελείται αρχικά από τις τιμές Male και Female, μετασχηματίζεται σε δύο νέες στήλες. Η πρώτη (Gender\_Male) λαμβάνει την τιμή 1 αν ο εργαζόμενος είναι άνδρας και 0 αν είναι γυναίκα. Η δεύτερη (Gender\_Female) λαμβάνει την τιμή 1 αν η εργαζόμενη είναι γυναίκα και 0 αν είναι άνδρας.

Παρά την αποτελεσματικότητά της, η εφαρμογή του One-Hot Encoding εγκυμονεί σοβαρούς κινδύνους όταν το σύνολο δεδομένων περιλαμβάνει μεταβλητές με υψηλή πληθυντικότητα (high-cardinality features), όπως η μεταβλητή JobRole (9 διακριτές κατηγορίες) ή η EducationField (6 διακριτές κατηγορίες). Ο μετασχηματισμός των συνολικά 16 κατηγορικών στηλών οδηγεί σε εκθετική αύξηση των διαστάσεων του πίνακα εισόδου. Το φαινόμενο αυτό ορίζεται στη διεθνή βιβλιογραφία ως η «Κατάρρα της Διαστατικότητας» (Curse of Dimensionality) και, όπως υπογραμμίζουν οι Kuhn και Johnson (2019), μπορεί να υποβαθμίσει σημαντικά την προγνωστική ισχύ των μοντέλων, εκθέτοντάς τα στον κίνδυνο της overfitting λόγω της δημιουργίας ενός υπερβολικά αραιού πίνακα δεδομένων (sparse matrix) (Kuhn & Kjell, 2019).

Ειδικότερα, οι Kuhn και Johnson (2019) επισημαίνουν ότι η εισαγωγή πολυάριθμων dummy μεταβλητών επηρεάζει αρνητικά την αρχιτεκτονική και την απόδοση των δενδρικών ensemble αλγορίθμων (όπως ο Random Forest). Όταν ένα δέντρο απόφασης καλείται να εξετάσει μια One-Hot κωδικοποιημένη μεταβλητή (π.χ. JobRole\_SalesRepresentative), ο διαχωρισμός (split) που πραγματοποιεί απομονώνει αναγκαστικά τη μία συγκεκριμένη κατηγορία από όλες τις υπόλοιπες μαζί (Kuhn & Kjell, 2019). Εάν η κρίσιμη πληροφορία που επιχειρεί να εξαγάγει ο αλγόριθμος βρίσκεται κρυμμένη σε μια συνδυαστική δομή μεταξύ των υπόλοιπων ρόλων, το δέντρο αναγκάζεται να αυξήσει δραματικά το βάθος του (tree depth) και να εκτελέσει πολλαπλά, διαδοχικά και υπολογιστικά δαπανηρά splits για να ανασυνθέσει τη χαμένη δομή της αρχικής μεταβλητής. Κάτι τέτοιο μειώνει τη γενικευτική ικανότητα του μοντέλου και αυξάνει τον θόρυβο κατά την εκπαίδευση.

Για την αντιμετώπιση του ανωτέρω προβλήματος, οι Kuhn και Johnson (2019) προτείνουν εναλλακτικές στρατηγικές, όπως το Target Encoding ή την προληπτική ομαδοποίηση των κατηγοριών με εξαιρετικά χαμηλή συχνότητα εμφάνισης σε μια κοινή κατηγορία-ομπρέλα (π.χ. "Other") (Kuhn & Kjell, 2019). Στην παρούσα διατριβή, ακολουθώντας τις συστάσεις της βιβλιογραφίας, εφαρμόστηκε μια συνδυαστική προσέγγιση: πριν από την τελική κωδικοποίηση, πραγματοποιήθηκε έλεγχος συχνότητας εμφάνισης των κατηγοριών. Κατηγορίες με μηδενική ή ελάχιστη στατιστική συχνότητα ενσωματώθηκαν, όπου αυτό ήταν επιχειρησιακά εφικτό, προκειμένου να περιοριστεί ο τελικός αριθμός των dummy μεταβλητών που θα προέκυπταν από το One-Hot Encoding. Με αυτόν τον τρόπο, διασφαλίζεται η βέλτιστη υπολογιστική ισορροπία και η διατήρηση της δομικής πληροφορίας για τα δενδρικά μοντέλα που θα αναπτυχθούν στη συνέχεια.

### 5.3.2 Κανονικοποίηση αριθμητικών χαρακτηριστικών (Feature Scaling)

Οι ποσοτικές μεταβλητές του συνόλου δεδομένων παρουσιάζουν σημαντικές αποκλίσεις ως προς τα εύρη τιμών τους. Παραδείγματος χάριν, η μεταβλητή του μηνιαίου εισοδήματος (MonthlyIncome) εκτείνεται σε μια κλίμακα χιλιάδων δολαρίων, ενώ η μεταβλητή των ετών από την τελευταία προαγωγή (YearsSinceLastPromotion) περιορίζεται σε πολύ μικρότερους μονοψήφιους ή διψήφιους αριθμούς. Για την εξάλειψη της μεροληψίας που προκαλείται από αυτές τις διαφορές μεγέθους, εφαρμόστηκε η μέθοδος της Τυποποίησης (Z-score Standardization) μέσω του αναλυτή *StandardScaler* της βιβλιοθήκης *Scikit-Learn* (Team S. L., Scikit-learn *StandardScaler* documentation, 2026). Η μαθηματική φόρμουλα που εφαρμόζεται για τη μετατροπή κάθε τιμής  $x$  ενός χαρακτηριστικού είναι η εξής:

$$z = \frac{x - \mu}{\sigma}$$

Όπου ' $\mu$ ' αντιπροσωπεύει τον μέσο όρο του χαρακτηριστικού και ' $\sigma$ ' την τυπική του απόκλιση. Με τον μετασχηματισμό αυτό, όλες οι αριθμητικές μεταβλητές αποκτούν μέσο όρο ίσο με 0 και τυπική απόκλιση ίση με 1, ακολουθώντας τη δομή της Τυπικής Κανονικής Κατανομής. Στο πλαίσιο της παρούσας μελέτης, η επιλογή του *StandardScaler* έναντι εναλλακτικών μεθόδων (όπως η *Normalization* στο εύρος [0,1]) έγινε εσκόπως και εξυπηρετεί δύο κρίσιμες σκοπιμότητες. Όπως τεκμηριώθηκε στην ενότητα 5.2.2, οι ακραίες τιμές του dataset αντιπροσωπεύουν πραγματικά και πολύτιμα επιχειρησιακά δεδομένα (ανώτερα στελέχη). Η Τυποποίηση δεν συμπίεζει αυθαιρετικά τα όρια της κατανομής, επιτρέποντας τη διατήρηση της στατιστικής συμπεριφοράς των outliers, η οποία είναι απαραίτητη για την εκπαίδευση των μοντέλων. Επιπροσθέτως, δεδομένης της ανάγκης αντιμετώπισης της ανισορροπίας των κλάσεων (class imbalance), η εφαρμογή του αλγορίθμου παραγωγής συνθετικών δεδομένων SMOTE (Synthetic Minority Over-sampling Technique) βασίζεται στον υπολογισμό Ευκλείδειων αποστάσεων μέσω του αλγορίθμου k-nearest neighbors (KNN) (Team I. I., 2026). Η προληπτική τυποποίηση των δεδομένων κρίνεται μεθοδολογικά σωστή, καθώς διασφαλίζει ότι μεταβλητές με μεγάλο εύρος τιμών δεν θα κυριαρχήσουν στον υπολογισμό των αποστάσεων έναντι των υπόλοιπων χαρακτηριστικών.

## 5.4 Ανάπτυξη προγνωστικών μοντέλων

### 5.4.1 Feature engineering προ εκπαίδευσης

Έπειτα της ολοκλήρωσης της διαδικασίας του Feature Engineering, ακολουθεί το στάδιο της αρχιτεκτονικής σχεδίασης, της εκπαίδευσης και της αξιολόγησης των προγνωστικών μοντέλων. Αρχικά, απομονώνονται όλες οι κατηγορικές μεταβλητές σε μία δομή λίστας στην Python. Για τον μετασχηματισμό τους χρησιμοποιείται ο αναλυτής *OneHotEncoder* της βιβλιοθήκης *Scikit-Learn*, θέτοντας την παράμετρο `min_frequency=0.05`. Η επιλογή αυτή, όπως τεκμηριώθηκε στο *Υποκεφάλαιο* 5.3.2, εξασφαλίζει ότι κατηγορίες με συχνότητα εμφάνισης μικρότερη του 5% θα συγχωνευθούν αυτόματα, αποτρέποντας την εκθετική διόγκωση των διαστάσεων του πίνακα (Curse of Dimensionality).

Στη συνέχεια, το σύνολο δεδομένων διαχωρίζεται στις ανεξάρτητες μεταβλητές  $x$  και στην εξαρτημένη μεταβλητή-στόχο  $y$ , η οποία εκφράζει την οικειοθελή αποχώρηση (Attrition) σε δυαδική μορφή (0 και 1). Πριν από οποιαδήποτε επεξεργασία κλιμάκωσης, τα δεδομένα διαχωρίζονται σε υποσύνολα εκπαίδευσης (Train Set) και δοκιμής (Test Set) σε αναλογία 80/20 αντίστοιχα,



διασφαλίζοντας ότι το 20% των δεδομένων θα παραμείνει εντελώς άγνωστο προς τα μοντέλα για την τελική και αντικειμενική τους αξιολόγηση.

Προς αποφυγή του φαινομένου της διαρροής δεδομένων (data leakage), όπου πληροφορίες από το test set επηρεάζουν έμμεσα τη διαδικασία εκπαίδευσης (Kuhn & Kjell, 2019), η προσαρμογή των μετασχηματιστών πραγματοποιείται με αυστηρό πρωτόκολλο. Ο StandardScaler πραγματοποιεί υπολογισμό μέσης τιμής και τυπικής απόκλισης (.fit()) αποκλειστικά επί του  $x_{train}$ . Στη συνέχεια, εφαρμόζει τον μετασχηματισμό (.transform()) τόσο στο  $x_{train}$  όσο και στο  $x_{test}$ . Τα πλέον έτοιμα, κωδικοποιημένα και τυποποιημένα υποσύνολα αριθμητικών και κατηγορικών στηλών συνενώνονται, αντικαθιστώντας τα αρχικά  $x_{train}$  και  $x_{test}$ .

#### 5.4.2 Διαδικασία εκπαίδευσης/δοκιμής μοντέλων και μετρικές αξιολόγησης

Η δοκιμή και η συγκριτική αξιολόγηση των προγνωστικών αλγορίθμων πραγματοποιείται μέσω μιας custom συνάρτησης Python. Η συνάρτηση αυτή δέχεται ως εισόδους τα υποσύνολα  $x_{test}$  και  $y_{test}$ , το εκάστοτε εκπαιδευμένο μοντέλο και την ονομασία του. Κατά την εκτέλεσή της, παράγει προβλέψεις για το  $x_{test}$ , οι οποίες συγκρίνονται με τις πραγματικές τιμές του  $y_{test}$  μέσω ενός πίνακα σύγχυσης (Confusion Matrix). Για λόγους σαφήνειας, τα περιεχόμενα του πίνακα σύγχυσης θα εξηγηθούν για το σενάριο που εξετάζεται:

- TP: Οι εργαζόμενοι που αποχώρησαν και προβλέφθηκε σωστά ότι θα αποχωρήσουν.
- FP: Οι εργαζόμενοι που παράμειναν και προβλέφθηκε λάθος ότι θα αποχωρήσουν.
- FN: Οι εργαζόμενοι που αποχώρησαν και προβλέφθηκε λάθος ότι παράμειναν.
- TN: Οι εργαζόμενοι που παράμειναν και προβλέφθηκε σωστά ότι παράμειναν.

Λόγω της έντονης ανισορροπίας των κλάσεων του dataset (class imbalance), η αξιολόγηση των μοντέλων δεν μπορεί να βασιστεί σε μία μεμονωμένη μετρική. Για τον λόγο αυτό, επιστρατεύεται μια δέσμη ακαδημαϊκά εγκεκριμένων μετρικών απόδοσης (Bruce, Bruce, & Gedeck, 2020):

- Δείκτης Ακρίβειας (Accuracy): 
$$\frac{TP+TN}{TP+TN+FP+FN}$$

Η ακρίβεια (Accuracy) ορίζεται ως ο λόγος των σωστών προβλέψεων (Θετικών και Αρνητικών) προς το συνολικό πλήθος των παρατηρήσεων. Όπου  $TP$  τα Αληθώς Θετικά (True Positives),  $TN$  τα Αληθώς Αρνητικά (True Negatives),  $FP$  τα Ψευδώς Θετικά (False Positives) και  $FN$  τα Ψευδώς Αρνητικά (False Negatives). Αν και αποτελεί την πιο διαισθητική μετρική, στην παρούσα διατριβή αντιμετωπίζεται με επιφυλακτικότητα. Σε ανισόρροπα σύνολα δεδομένων, ένα μοντέλο μπορεί να επιτύχει υψηλό Accuracy (π.χ. 85%) απλώς προβλέποντας πάντα την κυρίαρχη κλάση (ότι κανείς δεν θα αποχωρήσει), αποτυγχάνοντας παταγωδώς στον εντοπισμό του attrition.

- Δείκτης Precision: 
$$\frac{TP}{TP+FP}$$

Ο εν λόγω δείκτης μετρά την ακρίβεια των θετικών προβλέψεων του μοντέλου. Η μετρική αυτή είναι κρίσιμη για τη διοίκηση, καθώς ένα χαμηλό Precision σημαίνει πολλά Ψευδώς Θετικά δείγματα ( $FP$ ), οδηγώντας την εταιρεία σε σπατάλη πόρων και λήψη προληπτικών μέτρων για υπαλλήλους που δεν είχαν σκοπό να παραιτηθούν.


- Δείκτης Ευαισθησίας ή Ανάκλησης (Recall / Sensitivity):  $\frac{TP}{TP+FN}$

Η Ανάκληση (Recall) μετρά την ικανότητα του μοντέλου να εντοπίζει τις πραγματικές περιπτώσεις της κλάσης-στόχου. Στο HR Analytics, το Recall θεωρείται συχνά πιο κρίσιμο από το Precision, καθώς το κόστος του να μην εντοπιστεί ένας υπάλληλος που πρόκειται να αποχωρήσει (Ψευδώς Αρνητικό - FN) συνεπάγεται την οριστική απώλεια του και το κόστος αντικατάστασής του.


- Δείκτης F1 (F1-Score):  $2 \times \frac{Precision \times Recall}{Precision+Recall}$

Ο δείκτης F1-Score αποτελεί τον αρμονικό μέσο όρο μεταξύ της Πιστότητας (Precision) και της Ανάκλησης (Recall). Παρέχει μια ισορροπημένη και αξιόπιστη αποτύπωση της προγνωστικής ισχύος του μοντέλου, ιδιαίτερα σε imbalanced datasets, καθώς λαμβάνει υψηλή τιμή μόνο όταν τόσο το Precision όσο και το Recall είναι εξίσου ικανοποιητικά.

- Καμπύλη ROC και το Σκορ AUC (Receiver Operating Characteristic - Area Under the Curve)  
Η καμπύλη ROC αποτελεί μια γραφική απεικόνιση της απόδοσης του μοντέλου ταξινόμησης σε όλα τα πιθανά κατώφλια απόφασης (decision thresholds), αποτυπώνοντας την Ευαισθησία (True Positive Rate) έναντι της αναλογίας των Ψευδώς Θετικών. Το σκορ AUC (Area Under the Curve) μετρά το συνολικό εμβαδόν κάτω από την καμπύλη ROC και κυμαίνεται από 0.5 (τυχαία επιλογή) έως 1.0 (τέλειος ταξινομητής). Σύμφωνα με τους Japkowicz και Shah, το ROC AUC προσφέρει μια καθολική μετρική αξιολόγησης της ικανότητας του μοντέλου να διαχωρίζει τις δύο κλάσεις (διακριτική ικανότητα), ανεξάρτητα από την κατανομή των κλάσεων στο dataset (Japkowicz & Shah, 2011).



Εικόνα 66 - Παράδειγμα ROC AUC με Λογιστική Παλινδρόμηση



Εικόνα 67 - Παράδειγμα ROC AUC με XGBoost

```

from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
from sklearn.metrics import roc_auc_score, RocCurveDisplay
# convinient function to test a model

#a list to save the AUC results of every classification algorithm
classification_results = []

#creating ROC Curve function and dictionary to keep track of the results
def show_roc_curve(x_tst, y_tst, y_prob, model_recieved, model_title):
    auc_score = roc_auc_score(y_tst, y_prob)
    print(f"ROC AUC Score: {auc_score:.4f}")

    #preparation for visualization of roc curve
    fig, ax = plt.subplots(figsize=(8,6))
    RocCurveDisplay.from_estimator(
        estimator=model_recieved,
        X=x_tst,
        y=y_tst,
        ax=ax,
        name=model_title,
        color='darkorange',
        linewidth=2
    )
    ax.plot([0, 1], [0, 1], color="navy", linestyle="--", label="Random Guess (AUC = 0.50)")
    ax.set_title("Receiver Operating Characteristic (ROC) Curve", fontsize=14,
        fontweight='bold')
    ax.set_xlabel("False Positive Rate (1 - Specificity)", fontsize=12)
    ax.set_ylabel("True Positive Rate (Sensitivity / Recall)", fontsize=12)
    ax.legend(loc="lower right", fontsize=11)
    ax.grid(True, linestyle=":", alpha=0.6)

    plt.show()

    #save results to the classification_results list to compare later
    classification_results.append({"model": model_title, "auc": auc_score})

```

Εικόνα 68 - ROC AUC Custom-made συνάρτηση

```

def test_model(model_used, x_tst, y_tst, title = 'Model Tested'):
    #predictions, containing either True or false
    y_prob = model_used.predict(x_tst)

    print(title)
    print('Accuracy:', accuracy_score(y_tst, y_prob))
    print("Classification Report \n",classification_report
        (y_tst, y_prob))
    print("Confusion Matrix: \n",confusion_matrix(y_tst, y_prob))
    print("="*60)

    #probability from test set
    y_pred_proba = model_used.predict_proba(x_tst)[: , 1] #taking only second column,
        containing the predicted probability

    show_roc_curve(x_tst, y_tst, y_pred_proba, model_used, title)

    # Sensitivity (recall of True cases - churn = Yes), Specificity (recall of False
        cases - churn = No) ,Precision, type I error (false positives) and type II
        error (false negatives) are shown in the classification report

```

Εικόνα 69 - Custom-made model testing συνάρτηση

### 5.4.3 Μοντέλα που εκπαιδεύτηκαν

Για την επίλυση του προβλήματος της δυαδικής ταξινόμησης της εργασιακής αποχώρησης (Attrition), εφαρμόστηκε μια πολυπαραμετρική προσέγγιση που περιλαμβάνει πέντε από τους πλέον αναγνωρισμένους και ισχυρούς αλγορίθμους της Μηχανικής Μάθησης. Η επιλογή αυτή έγινε προκειμένου να συγκριθούν διαφορετικές μαθηματικές προσεγγίσεις (γραμμικά μοντέλα, μοντέλα μη παραμετρικά, διαχωριστικά υπερεπίπεδα και δενδρικές δομές) ως προς τη γενικευτική τους ικανότητα.

Το πρώτο μοντέλο που επιλέχθηκε, το οποίο θα χρησιμοποιηθεί και ως βάση σύγκρισης με πιο σύνθετα είναι η Λογιστική Παλινδρόμηση. Αποτελεί το βασικό μοντέλο αναφοράς (baseline model) της παρούσας διατριβής. Ανήκει στην οικογένεια των Γενικευμένων Γραμμικών Μοντέλων (GLM) και χρησιμοποιείται για την εκτίμηση της πιθανότητας εμφάνισης ενός δυαδικού αποτελέσματος. Αντί να προβλέπει απευθείας την κλάση, ο αλγόριθμος υπολογίζει έναν γραμμικό συνδυασμό των ανεξάρτητων μεταβλητών ( $z$ ), ο οποίος στη συνέχεια εισάγεται στη Σιγμοειδή Συνάρτηση (Sigmoid Function) (Bruce, Bruce, & Gedeck, 2020).

$$S(z) = \frac{1}{1 + e^{-z}}$$

Η σιγμοειδής συνάρτηση λειτουργεί ως μαθηματικός συμπίεστής, περιορίζοντας το αποτέλεσμα αυστηρά στο διάστημα  $[0, 1]$ . Λόγω της ευαισθησίας της στις κλίμακες των δεδομένων, η απόδοσή της εξαρτάται άμεσα από την τυποποίηση μέσω του StandardScaler που προηγήθηκε.

```
#applying one hot encoding with minimum frequency to help with redundant dimensions
ohe = OneHotEncoder(min_frequency=0.05, handle_unknown='infrequent_if_exist',
                    sparse_output=False)

x = ibm_ds.drop(['Attrition'], axis=1)
#turning Attrition column to Boolean type
encoding_attrition = pd.get_dummies(ibm_ds, columns=['Attrition'], drop_first=True)
y = encoding_attrition['Attrition_Yes']

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2,
                                                    random_state=42)

#scaler initialization
scaler = StandardScaler()

#applying one-hot encoding using x_categorical_columns list
x_train_enc = ohe.fit_transform(x_train[x_categorical_columns])
x_test_enc = ohe.transform(x_test[x_categorical_columns])

#scaling the numerical columns for easier processing
x_train_scaled = scaler.fit_transform(x_train[numerical_columns +
                                             turn_to_numeric_list])
x_test_scaled = scaler.transform(x_test[numerical_columns + turn_to_numeric_list])

x_train = np.hstack((x_train_enc, x_train_scaled))
x_test = np.hstack((x_test_enc, x_test_scaled))

lr_model = LogisticRegression(random_state=42)
lr_model.fit(x_train, y_train)
```

Εικόνα 70 - Παράδειγμα OHE, StandardScaler & Model Training/Testing

Το δεύτερο μοντέλο που επιλέχθηκε, που λειτουργεί ως εισαγωγή στα μοντέλα τύπου Δέντρων είναι το Random Forest. Αποτελεί έναν αντιπροσωπευτικό αλγόριθμο ομαδικής μάθησης (ensemble learning) που βασίζεται στη μεθοδολογία της Παράλληλης Σύνθεσης με Αντικατάσταση (Bagging / Bootstrap Aggregating). Ο αλγόριθμος εκπαιδεύει έναν μεγάλο αριθμό ανεξάρτητων Δέντρων Απόφασης (Decision Trees) σε διαφορετικά τυχαία υποσύνολα των δεδομένων και των χαρακτηριστικών (Kuhn & Kjell, 2019). Η τελική πρόβλεψη προκύπτει μέσω πλειοψηφικής ψηφοφορίας (majority voting) των επιμέρους δέντρων. Το κύριο πλεονέκτημα του Random Forest είναι η εξαιρετική του ανθεκτικότητα στην υπερεκπαίδευση και η ικανότητά του να διαχειρίζεται εγγενώς τις μη γραμμικές σχέσεις και τις πολυσυγγραμμικές μεταβλητές που εντοπίστηκαν στον πίνακα συσχετίσεων.

Σε αντίθεση με την παράλληλη αρχιτεκτονική του Random Forest, οι αλγόριθμοι ενίσχυσης κλίσης (Gradient Boosting) λειτουργούν σειριακά. Κάθε νέο δέντρο απόφασης εκπαιδεύεται με σκοπό να διορθώσει τα σφάλματα (residuals) των προηγούμενων δέντρων, ελαχιστοποιώντας μια προκαθορισμένη συνάρτηση απώλειας (loss function) μέσω της μεθόδου της απότομης καθόδου (gradient descent). Για τους σκοπούς της τρέχουσας έρευνας χρησιμοποιήθηκαν δύο σύγχρονα μοντέλα Gradient Boosting. Το πρώτο από αυτά μοντέλο που θα αναλυθεί είναι το XGBoost. Σύμφωνα με τον δημιουργό του (Chen & Guestrin, 2016), το XGBoost αποτελεί ένα κλιμακούμενο και εξαιρετικά αποδοτικό σύστημα δένδρικής ενίσχυσης. Η καινοτομία του έγκειται στην ενσωμάτωση μιας τροποποιημένης συνάρτησης κόστους που περιλαμβάνει όρους ομαλοποίησης (L1 και L2 regularization), οι οποίοι ελέγχουν την πολυπλοκότητα των δέντρων και προσφέρουν ισχυρή προστασία έναντι της υπερεκπαίδευσης (overfitting). Επιπλέον, διαχειρίζεται εγγενώς και με βέλτιστο υπολογιστικά τρόπο τα ελλιπή δεδομένα.

Το επόμενο Gradient Boosting μοντέλο, το LightGBM, αναπτύχθηκε από την ερευνητική ομάδα της Microsoft (Ke, Meng, Finley, & Wang, 2017) με σκοπό να ξεπεράσει τους υπολογιστικούς περιορισμούς του κλασικού Gradient Boosting σε μεγάλα σύνολα δεδομένων. Σε αντίθεση με την παραδοσιακή ανάπτυξη των δέντρων κατά επίπεδα (level-wise growth), το LightGBM εισάγει μια στρατηγική ανάπτυξης κατά φύλλα (leaf-wise growth), επιλέγοντας να διασπάσει τον κόμβο με τη μέγιστη απώλεια. Η προσέγγιση αυτή, σε συνδυασμό με την τεχνική Gradient-based One-Side Sampling (GOSS), επιτρέπει ταχύτερη σύγκλιση, μειωμένη κατανάλωση μνήμης και υψηλότερη προγνωστική ακρίβεια.

Κλείνοντας με τα μοντέλα προς εκπαίδευση θα ακολουθήσει ο αλγόριθμος SVM, ο οποίος λειτουργεί αναζητώντας το βέλτιστο υπερεπίπεδο διαχωρισμού (optimal separating hyperplane) το οποίο μεγιστοποιεί το περιθώριο (margin) μεταξύ των δειγμάτων των δύο κλάσεων στον πολυδιάστατο χώρο των χαρακτηριστικών. Τα δείγματα που ορίζουν τα όρια αυτού του περιθωρίου ονομάζονται support vectors (James, Witten, Hastie, & Tibshirani, 2021). Στην παρούσα μελέτη, ο ταξινομητής SVC ρυθμίστηκε με την ιδιότητα probability=True. Η συγκεκριμένη παραμετροποίηση κρίνεται απαραίτητη, καθώς οι βασικές Μηχανές Διανυσμάτων Υποστήριξης εξάγουν αποστάσεις από το υπερεπίπεδο διαχωρισμού και όχι εγγενείς πιθανότητες. Μέσω της ρύθμισης αυτής ενεργοποιείται η μέθοδος εσωτερικής βαθμονόμησης του Platt (Platt scaling), η οποία εφαρμόζει μια εκ των υστέρων λογιστική παλινδρόμηση πάνω στα scores του SVM, μετατρέποντάς τα σε βαθμονομημένες πιθανότητες (James, Witten, Hastie, & Tibshirani, 2021). Με τον τρόπο αυτό καθίσταται εφικτός ο υπολογισμός της μετρικής ROC AUC κατά το στάδιο της αξιολόγησης.

#### 5.4.4 Τεχνική Παραγωγής Συνθετικών Δεδομένων SMOTE

Όπως προαναφέρθηκε, το σύνολο δεδομένων παρουσιάζει ανισορροπία στην εξαρτημένη μεταβλητή. Για τον λόγο αυτόν χρησιμοποιήθηκε ο αλγόριθμος SMOTE (Synthetic Minority Over-sampling Technique), με στόχο την εξισορρόπηση της μεταβλητής Attrition. Αντί για απλή επαναλήψη των υπαρχόντων δειγμάτων (random oversampling), η οποία προκαλεί overfitting, ο SMOTE λειτουργεί στον πολυδιάστατο χώρο των χαρακτηριστικών. Συγκεκριμένα, εντοπίζει τα k-κοντινότερα δείγματα (k-nearest neighbors) για κάθε παρατήρηση της μειονοτικής κλάσης (Attrition\_Yes). Έπειτα, σχεδιάζει νοητές γραμμές που ενώνουν αυτά τα δείγματα. Τέλος, δημιουργεί νέα, εντελώς συνθετικά αλλά στατιστικά παρόμοια δείγματα κατά μήκος αυτών των γραμμών (Japkowicz & Shah, 2011).


Η διαδικασία αυτή εφαρμόστηκε αποκλειστικά στο υποσύνολο  $x_{train}$ , αυξάνοντας το πλήθος των παρατηρήσεων της μειονοτικής κλάσης ώστε να εξισωθεί με την πλειοψηφική, ενώ το  $x_{test}$  παρέμεινε ανέπαφο για να διασφαλιστεί η αντικειμενικότητα των δοκιμών. Πάνω στα νέα εξισορροπημένα δεδομένα επανεκπαιδεύτηκαν τα μοντέλα Logistic Regression, Random Forest και SVM, δημιουργώντας ένα δεύτερο σύνολο προγνωστικών αποτελεσμάτων προς σύγκριση. Η χρήση αυτής της πρακτικής παραλήφθηκε για τους Gradient Boosting αλγορίθμους, καθώς είναι σχεδιασμένοι για να διαχειρίζονται ανισόρροπα δεδομένα.

### 5.5 Αξιολόγηση μοντέλων

#### 5.5.1 Ανάλυση επιδόσεων βασικών μοντέλων

Στην συνέχεια θα πραγματοποιηθεί σύγκριση και αξιολόγηση των εκπαιδευμένων μοντέλων. Τα αποτελέσματα του παρακάτω πίνακα για τις μετρικές Precision, Recall και F1-Score αφορούν αποκλειστικά στα *True* αποτελέσματα, δηλαδή τις περιπτώσεις οικειοθελούς αποχώρησης προσωπικού, που ενδιαφέρουν περισσότερο αυτήν την μελέτη.

| Μοντέλο             | Accuracy | Precision | Recall | F1-Score | AUC Score |
|---------------------|----------|-----------|--------|----------|-----------|
| Logistic Regression | 88.78%   | 59.00%    | 49.00% | 54.00%   | 0.8271    |
| Random Forest       | 88.10%   | 100.00%   | 10.26% | 19.00%   | 0.7679    |
| XGBoost             | 89.46%   | 83.33%    | 25.64% | 39.00%   | 0.7608    |
| LightGBM            | 85.37%   | 42.86%    | 30.77% | 36.00%   | 0.7832    |
| SVM                 | 88.78%   | 100.00%   | 15.38% | 27.00%   | 0.8538    |
| L.R. SMOTE          | 76.19%   | 31.33%    | 66.67% | 43.00%   | 0.7865    |
| Rand. For. SMOTE    | 87.41%   | 58.33%    | 17.95% | 27.00%   | 0.7392    |
| SVM SMOTE           | 88.78%   | 60.00%    | 46.15% | 52.00%   | 0.8067    |



Εικόνα 71 - AUC scores κάθε εκπαιδευμένου μοντέλου

Αρχικά, η φάση των δοκιμών ανέδειξε έντονα το πρόβλημα της στατιστικής ανισορροπίας του δείγματος. Μοντέλα όπως το Random Forest και το SVM πέτυχαν απόλυτο Precision (100.00%), πράγμα που σημαίνει ότι όλες φορές προέβλεψαν αποχώρηση ήταν 100% ορθές (μηδενικά False Positives). Ωστόσο, η αυστηρότητα αυτή οδήγησε σε εξαιρετικά χαμηλά ποσοστά Recall (10.26% και 15.38% αντίστοιχα). Τα μοντέλα αυτά απέτυχαν να εντοπίσουν τη συντριπτική πλειονότητα των εργαζομένων που σκόπευαν να αποχωρήσουν (35 και 33 False Negatives αντίστοιχα), καθιστώντας τα επιχειρησιακά ανεπαρκή παρά το υψηλό ολικό Accuracy (~88%).

Το XGBoost, κάνοντας χρήση της παραμέτρου `scale_pos_weight`, κατάφερε να εξισορροπήσει καλύτερα τις δύο μετρικές, επιτυγχάνοντας το υψηλότερο Accuracy (89.46%) με ικανοποιητικό Precision (83.33%) και Recall στο 25.64%. Αντίθετα, το LightGBM εμφάνισε χαμηλότερη γενικευτική ικανότητα, με το F1-Score να περιορίζεται στο 36.00%.

Η έκπληξη των βασικών δοκιμών προήλθε από τη Λογιστική Παλινδρόμηση (Logistic Regression) και το SVM ως προς τη διακριτική τους ικανότητα. Το SVM κατέγραψε το κορυφαίο ROC AUC score (0.8538) και η Λογιστική Παλινδρόμηση ακολούθησε με 0.8271. Το γεγονός αυτό

επιβεβαιώνει ότι οι δύο αυτοί αλγόριθμοι, επωφελούμενοι από την προληπτική τυποποίηση των δεδομένων (StandardScaler), κατάφεραν να βαθμονομήσουν ορθά τις πιθανότητες εμφάνισης του attrition, παρόλο που το default κατώφλι απόφασης (0.5) περιόριζε το Recall τους.

### 5.5.2 Επιπτώσεις της τεχνικής SMOTE και Συγκριτική αξιολόγηση

Η εφαρμογή του αλγορίθμου SMOTE μετέβαλε ριζικά τη συμπεριφορά των μοντέλων, μετατοπίζοντας το σημείο ισορροπίας μεταξύ Precision και Recall. Η εισαγωγή συνθετικών δειγμάτων ανάγκασε την Λογιστική Παλινδρόμηση να γίνει πολύ πιο «ευαίσθητη». Το Recall εκτοξεύθηκε στο 66.67% (το υψηλότερο σε όλες τις δοκιμές), εντοπίζοντας ορθά 26 από τις 39 αποχωρήσεις. Η μετατοπίση αυτή όμως επέφερε σημαντικό κόστος στην μετρική Precision, η οποία υποχώρησε στο 31.33% λόγω της αύξησης των False Positives (57), ρίχνοντας το ολικό Accuracy στο 76.19%.

Ο αλγόριθμος Random Forest παρουσίασε μικρή βελτίωση στο Recall (από 10.26% σε 17.95%), αλλά η φύση του Bagging φάνηκε να αντιστέκεται στην τεχνητή γραμμική παρεμβολή που δημιουργεί ο SMOTE στον χώρο των χαρακτηριστικών, επιβεβαιώνοντας τη βιβλιογραφία που θέλει τα δέντρα απόφασης να επηρεάζονται λιγότερο από αλλαγές στα δεδομένα.

Τέλος, ο SVM αναδείχθηκε ως ο πιο σταθερός αλγόριθμος υπό τη συνθήκη του resampling. Κατάφερε να διατηρήσει το ολικό Accuracy στο υψηλό 88.78%, ενώ παράλληλα τριπλασίασε το Recall του (από 15.38% σε 46.15%), διατηρώντας το Precision στο πολύ ικανοποιητικό 60.00%. Η ισορροπία αυτή οδήγησε στο υψηλότερο F1-Score (52.00%) μεταξύ των SMOTE υλοποιήσεων, σε συνδυασμό με ένα πολύ ισχυρό ROC AUC (0.8067).

### 5.5.3 Επιχειρησιακά συμπεράσματα επιλογής μοντέλου και ερμηνευσιμότητα

Από πλευράς HR Management, η επιλογή του καταλληλότερου μοντέλου εξαρτάται από τη στρατηγική της εταιρείας. Εάν ο οργανισμός επιθυμεί μια επιθετική πολιτική διακράτησης, όπου το κύριο μέλημα είναι να μην χαθεί κανένα στέλεχος (υψηλό Recall), η Λογιστική Παλινδρόμηση με SMOTE αποτελεί την καλύτερη λύση, παρά το ρίσκο να εφαρμοστούν προληπτικά μέτρα σε υπαλλήλους που δεν θα αποχωρούσαν. Εάν ο οργανισμός επιδιώκει μια ισορροπημένη και οικονομικά αποδοτική προσέγγιση, αποφεύγοντας άσκοπες δαπάνες σε ψευδείς προβλέψεις, το SVM με SMOTE ή η βασική Λογιστική Παλινδρόμηση προσφέρουν τον βέλτιστο συνδυασμό (F1-Score / AUC), εξασφαλίζοντας σταθερή προγνωστική ισχύ και υψηλή αξιοπιστία.

Με τις αυξανόμενες ανάγκες για ερμηνεύσιμη TN, είναι απαραίτητη η παραχώρηση ξεκάθαρων κριτηρίων κάθε πρόβλεψης των προαναφερθέντων αλγορίθμων για ορθές διοικητικές αποφάσεις. Τα γραμμικά μοντέλα, όπως η Λογιστική Παλινδρόμηση, κατόπιν εκπαίδευσης, διαθέτουν συντελεστές που υποδεικνύουν τη μαθηματική επίδραση κάθε μεταβλητής στο τελικό αποτέλεσμα. Αντιθέτως, το μοντέλο SVM που εκπαιδεύτηκε τρέχει σε μη-γραμμικό πυρήνα (RBF kernel), συνεπώς δεν κατέχει τέτοια δυνατότητα. Η επιλογή ενός γραμμικού kernel κατά την δήλωση του θα επέτρεπε, ωστόσο, την διεξαγωγή τέτοιων πορισμάτων. Ακολουθούν οι πέντε σημαντικότεροι συντελεστές της Λογιστικής παλινδρόμησης με άμεση σύνδεση με αυξημένο Attrition:



|    | Feature                          | Coefficient |
|----|----------------------------------|-------------|
| 27 | OverTime_Yes                     | 1.104427    |
| 1  | BusinessTravel_Travel_Frequently | 0.879051    |
| 63 | JobLevel_infrequent_sklearn      | 0.853050    |
| 73 | YearsAtCompany                   | 0.794780    |
| 15 | JobRole_Laboratory Technician    | 0.722750    |

Εικόνα 72 - Πέντε μεγαλύτερες ενδείξεις Attrition στην Λογιστική Παλινδρόμηση

```
#getting the coefficients for the trained Logistic Regression model
coefficients_lr = lr_model.coef_[0]

log_reg_df = pd.DataFrame({
    'Feature': all_columns,
    'Coefficient': coefficients_lr
}).sort_values(by='Coefficient', ascending=False)
#printing the top 5 features that increase Attrition
print(log_reg_df.head())
```

Εικόνα 73 - Πηγαίος Κώδικας για τα παραπάνω αποτελέσματα

Από την ανάλυση των συντελεστών συμπεραίνεται ότι η μεταβλητή της εργασίας πέραν του συμβατικού ωραρίου (*OverTime\_Yes*) ασκεί τη μεγαλύτερη επίδραση στην απόφαση του μοντέλου, αποτελώντας τον ισχυρότερο προγνωστικό παράγοντα αποχώρησης. Παράλληλα, οι μεταβλητές που αφορούν τα συχνά επαγγελματικά ταξίδια (*BusinessTravel\_Travel\_Frequently*) και τον συνολικό χρόνο παραμονής στην εταιρεία (*YearsAtCompany*) παρουσίασαν εξαιρετικά μεγάλη βαρύτητα. Τα ευρήματα αυτά ερμηνεύονται επιχειρησιακά καθώς οι συγκεκριμένες συνθήκες λειτουργούν ως έντονοι στρεσογόνοι παράγοντες για τον μέσο εργαζόμενο, οδηγώντας σταδιακά σε επαγγελματική εξάντληση (*burnout*).

Επιπρόσθετα, το μοντέλο απομόνωσε και ανέδειξε τον επαγγελματικό ρόλο του Τεχνικού Εργαστηρίου (*JobRole\_Laboratory Technician*) ως ισχυρή ένδειξη Attrition. Το γεγονός αυτό υποδηλώνει ότι είτε η ίδια η φύση των καθηκόντων της συγκεκριμένης θέσης, είτε οι συνθήκες διοίκησης στα εργαστήρια, χρήζουν περαιτέρω διερεύνησης, επίβλεψης και υποστήριξης από την ανώτερη διοίκηση του οργανισμού.

#### 5.5.4 Περαιτέρω βελτιστοποίηση μοντέλων για μελλοντική ακρίβεια

Το τρέχον σκέλος της μελέτης θα κλείσει με την παρουσίαση τεχνικών βελτιστοποίησης υπερπαραμέτρων για τα προαναφερθέντα προγνωστικά μοντέλα. Με σκοπό τη μεγιστοποίηση της γενικευτικής ικανότητας των αλγορίθμων και την εξάλειψη φαινομένων υπερεκπαίδευσης (*overfitting*), πραγματοποιήθηκε βελτιστοποίηση των υπερπαραμέτρων τους. Αντί της παραδοσιακής και υπολογιστικά δαπανηρής μεθόδου αναζήτησης σε πλέγμα (*Grid Search*), επιλέχθηκε η σύγχρονη προσέγγιση της Μπεϋζιανής Βελτιστοποίησης (*Bayesian Optimization*) μέσω του αλγορίθμου *BayesSearchCV*.

Χρησιμοποιώντας ένα πιθανοτικό μοντέλο (Gaussian Process Regression) ως υποκατάστατο (surrogate model), ο αλγόριθμος αξιολογεί τις προηγούμενες δοκιμές για να επιλέξει έξυπνα τον επόμενο συνδυασμό παραμέτρων προς εξέταση, εστιάζοντας σε περιοχές του χώρου αναζήτησης που παρουσιάζουν τη μεγαλύτερη πιθανότητα βελτίωσης. Για την αξιολόγηση των συνδυασμών εφαρμόστηκε Στρωματοποιημένη Διασταυρούμενη Επικύρωση 5 επιπέδων (5-fold Stratified Cross-Validation), διασφαλίζοντας τη σταθερή αναλογία της ανισόρροπης εξαρτημένης μεταβλητής (Attrition) σε κάθε split. Ως αντικειμενική συνάρτηση προς μεγιστοποίηση (scoring metric) ορίστηκε η μετρική AUC score. Παρακάτω ακολουθούν τα αποτελέσματα της εκτέλεσης του εν λόγω αλγορίθμου:

#### Final Model results after Bayesian Search (BENCHMARK)

| Model               | Best CV ROC-AUC | Test ROC-AUC |
|---------------------|-----------------|--------------|
| Logistic Regression | 0.8639          | 0.8302       |
| Random Forest       | 0.8341          | 0.7617       |
| SVM                 | 0.8628          | 0.8424       |
| XGBoost             | 0.8150          | 0.7814       |
| LightGBM            | 0.8190          | 0.7756       |

Εικόνα 74 - Πίνακας αποτελεσμάτων Bayesian Search

Best Hyperparameters per model:

Model: Logistic Regression

OrderedDict({'C': 0.3083505801105222, 'penalty': 'l2'})

Model: Random Forest

OrderedDict({'max\_depth': 13, 'min\_samples\_split': 3, 'n\_estimators': 259})

Model: SVM

OrderedDict({'C': 0.01, 'gamma': 0.00605953987716112, 'kernel': 'rbf'})

Model: XGBoost

OrderedDict({'learning\_rate': 0.05093117443518205, 'max\_depth': 9, 'n\_estimators': 224, 'scale\_pos\_weight': 5.188282185302634})

Model: LightGBM

OrderedDict({'learning\_rate': 0.02831717718879084, 'max\_depth': 4, 'n\_estimators': 217, 'num\_leaves': 61})

Εικόνα 75 - Βέλτιστες υπερπαραμέτροι για κάθε μοντέλο

Από παραπάνω συμπεραίνεται η μή γραμμική κυριαρχία του SVM. Ο αλγόριθμος αυτός αναδείχθηκε ως το βέλτιστο προγνωστικό μοντέλο της μελέτης, επιτυγχάνοντας Test ROC-AUC 0.8424. Η Μπεϋζιανή αναζήτηση απέρριψε τη γραμμική διαχωρισιμότητα και επέβαλε τη χρήση του Radial Basis Function πυρήνα (kernel='rbf') με υψηλή τιμή κανονικοποίησης (C': 0.01). Το γεγονός αυτό υποδηλώνει ότι τα όρια απόφασης που διαχωρίζουν τους εργαζόμενους που προτίθενται να αποχωρήσουν από εκείνους που θα παραμείνουν είναι εξαιρετικά περίπλοκα και μη γραμμικά στον χώρο των χαρακτηριστικών.

Ο αλγόριθμος XGBoost εμφάνισε τη σημαντικότερη βελτίωση, αυξάνοντας το Test ROC-AUC από το αρχικό 0.7608 στο 0.7814. Η εύρεση της βέλτιστης τιμής για την παράμετρο `scale_pos_weight` (~5.19) επέτρεψε στο μοντέλο να αντισταθμίσει την ανισορροπία των κλάσεων με μαθηματική ακρίβεια, αποφεύγοντας τους ψευδείς συναγερμούς. Αντίστοιχα, το LightGBM σταθεροποιήθηκε στο 0.7756, με τον αλγόριθμο να επιλέγει χαμηλό ρυθμό μάθησης (`learning_rate`: 0.0283) και ρηχά δέντρα (`max_depth`: 4), περιορίζοντας δραστικά το *overfitting* που εμφανιζε στις αρχικές δοκιμές.

Συμπερασματικά, η διαδικασία του *hyperparameter tuning* μέσω Μπεϋζιανής Βελτιστοποίησης οριστικοποίησε τα μοντέλα στην τελική τους μορφή, παρέχοντας στη Διοίκηση Ανθρωπίνου Δυναμικού μια εργαλειοθήκη αλγορίθμων με εγγυημένη μαθηματική ευστάθεια και υψηλή προγνωστική ικανότητα.

## 6. Συμπεράσματα & Προτάσεις

Με την ολοκλήρωση των δύο διακριτών σταδίων της παρούσας μελέτης, ακολουθεί το τελικό στάδιο της συνδυαστικής αξιολόγησης των ευρημάτων. Η σφαιρική εικόνα που προέκυψε, τόσο για την ελληνική αγορά εργασίας (μέσα από την πρωτογενή έρευνα) όσο και για την εξεταζόμενη εταιρεία (βάσει των ενδοεταιρικών δεδομένων της IBM), αποτελεί τον θεμέλιο λίθο για μια εκτενή συγκριτική ανάλυση. Τα κρίσιμα ευρήματα των Κεφαλαίων 4 και 5 αποτυπώνονται συνοπτικά στη συνέχεια, με σκοπό τη διατύπωση στρατηγικών προτάσεων διακράτησης και προσέλκυσης ταλέντων, αναδεικνύοντας τα βήματα που οδηγούν στη λήψη αποφάσεων βάσει δεδομένων (*data-driven decision making*). Χάρει στα ευρήματα των παρακάτω τριών Υποκεφαλαίων απαντούνται, επίσης, τα ερευνητικά ερωτήματα που τέθηκαν στο *Υποκεφάλαιο 1.3*.

### 6.1 Σύνοψη ευρημάτων πρώτου σκέλους – Ερωτηματολογίου

Τα ευρήματα του Κεφαλαίου 4 χαρτογραφούν τις τάσεις και τις ιδιαιτερότητες της ελληνικής αγοράς εργασίας, όπως αυτές αποτυπώθηκαν στο δείγμα των 120 συμμετεχόντων.

Η γενική εικόνα, σύμφωνα με τα αποτελέσματα των Υποκεφαλαίων 4.2 και 4.3, αναδεικνύει ένα έντονα συναισθηματικά εξαντλημένο εργατικό δυναμικό, το οποίο βιώνει συνθήκες εργασιακού εγκλωβισμού και αποτιμά θετικά τις σύγχρονες αμυντικές πρακτικές της αγοράς εργασίας, όπως το *Job-Hopping* και το *Quiet Quitting*. Το μεγαλύτερο μέρος του δείγματος ιεραρχεί μέτρια την εργασία στην ζωή του και εξέφρασε μια έντονη, μη καλυπτόμενη ανάγκη για ευελιξία, η οποία μεταφράζεται σε καθολική προτίμηση για το υβριδικό μοντέλο εργασίας έναντι της αποκλειστικής φυσικής παρουσίας.

Παράλληλα, επιβεβαιώνεται η κλασική θεωρία διακράτησης του HR (Hom, Allen, & Griffith, 2019) σχετικά με τον καθοριστικό ρόλο των οικονομικών απολαβών, της εργασιακής ικανοποίησης και του έμπρακτου ενδιαφέροντος του εργοδότη για την ευεξία του προσωπικού. Οι συσχετίσεις που εντοπίστηκαν στα Υποκεφάλαια 4.3.1 και 4.3.2 υπογραμμίζουν την ανάγκη μετάβασης σε μια ανθρωποκεντρική οργανωσιακή κουλτούρα.

Επιπλέον, η ανάλυση συστάδων (βλ. *Υποκεφάλαιο 4.4.2*) διαχώρισε με σαφήνεια τους εργαζόμενους σε δύο κατηγορίες. Η Συστάδα «Σταθεροί/Ικανοποιημένοι», με εργαζόμενους υψηλής

εργασιακής ωριμότητας, ικανοποιητικές απολαβές και πίστη στον οργανισμό, και η Συστάδα «Εγκλωβισμένοι Φυγάδες», όπου οι νεότεροι και ανερχόμενοι επαγγελματίες παρουσιάζουν τις ισχυρότερες τάσεις φυγής, καθώς δηλώνουν δυσαρεστημένοι από τις οικονομικές απολαβές και την έλλειψη υποστήριξης, αναζητώντας ενεργά μια επαγγελματική διέξοδο.

## 6.2 Σύνοψη ευρημάτων δεύτερου σκέλους – Ενδοεταιρικών δεδομένων

Τα ευρήματα του Κεφαλαίου 5 εστίασαν στην ανάπτυξη και αξιολόγηση προγνωστικών μοντέλων μηχανικής μάθησης για την πρόβλεψη της οικειοθελούς αποχώρησης (attrition) εντός του εταιρικού περιβάλλοντος. Αποδείχθηκε ότι η συστηματική προεπεξεργασία των δεδομένων και η εκπαίδευση μοντέλων Επιβλεπόμενης Μάθησης (Supervised Learning) αποτελούν ιδιαίτερα αποτελεσματικά εργαλεία για την έγκαιρη αναγνώριση των εργαζομένων που βρίσκονται σε κίνδυνο φυγής.

Παρά τη μη γραμμική φύση που χαρακτηρίζει την πρόθεση αποχώρησης, ο αλγόριθμος Support Vector Machines (SVM) παρουσίασε την υψηλότερη προγνωστική ακρίβεια (predictive performance). Ωστόσο, το απλούτερο και υπολογιστικά ελαφρύτερο μοντέλο της Λογιστικής Παλινδρόμησης (Logistic Regression) αναδείχθηκε ως μια εξαιρετικά αξιόπιστη εναλλακτική λόγω της υψηλής ερμηνευσιμότητάς του. Οι μεταβλητές με τη μεγαλύτερη βαρύτητα στην πρόβλεψη της φυγής περιλαμβάνουν:

1. Την πραγματοποίηση υπερωριών (overtime).
2. Τη συχνότητα των επαγγελματικών ταξιδιών (business travel).
3. Το ιεραρχικό επίπεδο (job level).
4. Τα έτη παραμονής στον τρέχοντα ρόλο (years in current role).
5. Την εργασία εντός του εργαστηριακού τομέα (laboratory technician).

Οι τέσσερις πρώτες μεταβλητές εναρμονίζονται πλήρως με τη διεθνή θεωρία διακράτησης του HR (Hom, Allen, & Griffith, 2019), (Dias, Cruz, Luis, Jardim da Palma, & Pereira, 2025). Αντίθετα, η πέμπτη μεταβλητή αποκαλύπτει μια εξειδικευμένη εσωτερική δυσλειτουργία στο τμήμα έρευνας και ανάπτυξης της εταιρείας, η οποία χρήζει άμεσης διοικητικής παρέμβασης.

## 6.3 Συλλογική αξιολόγηση και στρατηγικές προτάσεις έλξης και διακράτησης

Συγκρίνοντας τα χαρακτηριστικά των δύο σκελών διακρίνεται ένα πλήθος ομοιοτήτων μεταξύ τους. Πρώτον, στο ελληνικό δείγμα το ~43% των ερωτηθέντων δηλώνει ότι βιώνει συναισθηματική εξάντληση στο τέλος της ημέρας «συχνά έως πολύ συχνά». Στο δεύτερο σκέλος, η Λογιστική Παλινδρόμηση ανέδειξε την εργασία πέραν του συμβατικού ωραρίου (OverTime\_Yes) ως τον κρισιμότερο προγνωστικό παράγοντα ώθησης προς την αποχώρηση, δείχνοντας πως η συστηματική υπερεργασία και η πίεση χρόνου ταυτίζονται άμεσα με τη σταδιακή επαγγελματική εξουθένωση και τη μείωση της δέσμευσης του εργαζομένου και στα δύο σενάρια.

Ομοιότητες παρατηρούνται και στον οικονομικό παράγοντα, όπου και στα δύο σύνολα δεδομένων διακρίνεται έντονη συσχέτιση με προθέσεις φυγής ή την ίδια την φυγή (Attrition). Η οικονομική ικανοποίηση στα πρωτογενή δεδομένα (q11) παρουσιάζει ισχυρή αρνητική συσχέτιση με την πρόθεση αποχώρησης ( $r = -0.52$ ). Στην πράξη, το 55.6% όσων δηλώνουν απόλυτα έτοιμοι να

παραιτηθούν άμεσα εμφανίζουν χαμηλή έως πολύ χαμηλή οικονομική ικανοποίηση, καθιστώντας τη μισθολογική ανεπάρκεια τον κυρίαρχο παράγοντα ώθησης στην αγορά. Αντίστοιχα, η διμεταβλητή ανάλυση στο δεύτερο σκέλος επιβεβαιώνει ότι οι εργαζόμενοι με χαμηλότερο μηνιαίο εισόδημα (MonthlyIncome) παρουσιάζουν στατιστικά σημαντικά μεγαλύτερη τάση αποχώρησης, ενώ η μεταβλητή αυτή εμφανίζει αρνητική συσχέτιση με το Attrition, δείχνοντας πως οι αμοιβές παραμένουν θεμελιώδης παράγοντας διακράτησης.

Επιπροσθέτως, η ηλικία δείχνει να είναι ένας εξίσου καθοριστικός παράγοντας φυγής και στα δύο σκέλη. Στην πρωτογενή έρευνα, ο αλγόριθμος K-Prototypes διαχώρισε την ομάδα υψηλού κινδύνου φυγής (Cluster 1) ως άτομα νεότερης ηλικίας (26-41 ετών), με μεσαία προϋπηρεσία (6-10 έτη) και χαμηλή οικονομική ικανοποίηση, οι οποίοι σκέφτονται την αλλαγή εργοδότη κάθε μήνα. Αντίθετα, στο Cluster 2 υπάρχει υψηλότερη επαγγελματική ωριμότητα (20+ έτη εμπειρίας). Στο δεύτερο σκέλος το φαινόμενο του attrition πλήττει κυρίως το νεότερο ηλικιακά και ιεραρχικά προσωπικό (χαμηλές τιμές στις μεταβλητές Age, JobLevel, TotalWorkingYears και YearsAtCompany). Επομένως, οι νεότεροι και ιεραρχικά χαμηλότεροι εργαζόμενοι, που δεν έχουν προλάβει να αναπτύξουν στενούς δεσμούς με τον οργανισμό, είναι οι πλέον επιρρεπείς στην εθελούσια αποχώρηση.

Από την ολοκλήρωση της διασταύρωσης των αποτελεσμάτων προκύπτουν συγκεκριμένες διοικητικές και στρατηγικές προτάσεις για τον οργανισμό. Αρχικά η ελληνική αγορά εργασίας παρουσιάζει σαφή προτίμηση για ευέλικτα σχήματα εργασίας, εργοδοτική υποστήριξη και ανταγωνιστικές απολαβές. Εάν η εταιρεία υιοθετήσει και προβάλλει ένα δομημένο Υβριδικό Μοντέλο Εργασίας και ένα ελκυστικό πακέτο παροχών, θα αποκτήσει σημαντικό ανταγωνιστικό πλεονέκτημα έναντι των ανταγωνιστών της που επιμένουν αποκλειστικά στη διά ζώσης εργασία, προσελκύοντας στελέχη υψηλής κατάρτισης που αναζητούν καλύτερες συνθήκες.

Η προσέλκυση νέων ταλέντων, όμως, καθίσταται αναποτελεσματική εάν δεν υποστηρίζεται από μια κουλτούρα που εμπνέει σταθερότητα και εμπιστοσύνη. Η διακράτηση του προσωπικού πρέπει να βασιστεί στην αποκατάσταση της ισορροπίας μεταξύ επαγγελματικής και προσωπικής ζωής (work-life balance). Τα ευρήματα του προγνωστικού μοντέλου (βλ. Κεφάλαιο 5) υπέδειξαν ότι οι υπερωρίες και τα συχνά ταξίδια αποτελούν τους κύριους παράγοντες φυγής. Συνεπώς, προτείνεται η άμεση θέσπιση ορίων στις υπερωρίες και η ορθολογικότερη κατανομή των ταξιδιών, η υιοθέτηση ενός Ολιστικού Συστήματος Αμοιβών και Παροχών (Total Rewards), το οποίο θα περιλαμβάνει σύγχρονες παροχές (π.χ. κάρτες σίτισης, προγράμματα ιδιωτικής ασφάλισης υγείας, παροχές εταιρικών οχημάτων leasing) και η δημιουργία εξατομικευμένων πλάνων επαγγελματικής εξέλιξης (career paths), ειδικά για τους εργαζόμενους σε χαμηλότερα ιεραρχικά επίπεδα που εμφανίζουν μεγαλύτερη τάση φυγής.

Η εφαρμογή των παραπάνω μέτρων αναμένεται να μειώσει δραστικά το κόστος που σχετίζεται με την απώλεια προσωπικού και τη διαδικασία στελέχωσης (turnover costs), αναβαθμίζοντας παράλληλα τη φήμη της εταιρείας ως κορυφαίου εργοδότη.

## 6.4 Προτάσεις για μελλοντική έρευνα

Παρά τα σημαντικά συμπεράσματα, η παρούσα μελέτη παρουσιάζει ορισμένους περιορισμούς που ανοίγουν τον δρόμο για μελλοντική έρευνα. Αρχικά οι χρονικοί περιορισμοί και το μέγεθος

δείγματος είναι δύο από τους βασικότερους παράγοντες βελτίωσης της διαδικασίας. Ο περιορισμένος χρόνος εκπόνησης της έρευνας περιόρισε το μέγεθος του δείγματος της πρωτογενούς έρευνας ( $N=120$ ). Μια μελλοντική έρευνα με μεγαλύτερο και πιο αντιπροσωπευτικό δείγμα θα επέτρεπε την ασφαλέστερη γενίκευση των συμπερασμάτων για το σύνολο της ελληνικής αγοράς εργασίας.

Το δεύτερο σκέλος της εργασίας βασίστηκε σε κλασικούς αλγορίθμους μηχανικής μάθησης. Η μελλοντική έρευνα θα μπορούσε να επεκταθεί στην εφαρμογή αρχιτεκτονικών Βαθιάς Μάθησης (Deep Learning), όπως τα Πολυεπίπεδα Περσέπτρονα (MLP) ή νευρωνικά δίκτυα κατάλληλα για tabular δεδομένα, για τη διερεύνηση πιθανής αύξησης της προγνωστικής ισχύος.

Τέλος, η παρούσα μελέτη λειτούργησε ως δοκιμή ιδέας (Proof-of-Concept) χρησιμοποιώντας ένα καλά δομημένο σύνολο δεδομένων στο δεύτερο σκέλος της. Σε πραγματικές συνθήκες, τα ενδοεταιρικά δεδομένα του HR συχνά χαρακτηρίζονται από έλλειψη δομής, ελλειπείς τιμές και ασυνέπειες. Συνεπώς, η επιτυχία τέτοιων προγνωστικών μοντέλων εξαρτάται άμεσα από την ύπαρξη αξιόπιστων pipelines και σύγχρονων συστημάτων αποθήκευσης και καθαρισμού της πληροφορίας.

## Βιβλιογραφία

- Bergsma, W. (2013). A note on Cramer's V and Tschuprow's T. *Journal of the Korean Statistical Society*. doi:10.1016/j.jkss.2012.10.002
- Bolino, M. C., & Klotz, A. C. (2022). When Quiet Quitting Is Worse Than the Real Thing. *Harvard Business Review*. Ανάκτηση από <https://hbr.org/2022/09/when-quiet-quitting-is-worse-than-the-real-thing>
- Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python*. doi:<https://doi.org/10.1080/00401706.2021.1904738>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. doi:<https://dl.acm.org/doi/10.1145/2939672.2939785>
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. doi:<https://doi.org/10.4324/9780203771587>
- Cramer, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press. doi:0691080046, 9780691080048
- Dias, S., Cruz, B., Luis, S., Jardim da Palma, P., & Pereira, M. (2025). Professional factors influencing internal migration: a systematic review. doi:[https://doi.org/10.1007/s12546-025-09390-1?urlappend=%3Futm\\_source%3Dresearchgate.net%26utm\\_medium%3Darticle](https://doi.org/10.1007/s12546-025-09390-1?urlappend=%3Futm_source%3Dresearchgate.net%26utm_medium%3Darticle)
- Field, A. (2013). *Discovering Statistics Using IBM SPSS Statistics*. doi:1446249174, 9781446249178
- Fitz-enz, J., & Mattox, J. (2014). *Predictive Analytics for Human Resources*.
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly.
- Great Expectations: Making Hybrid Work Work. (2022). *Microsoft Work Trend Index*. Ανάκτηση από [https://d110erj175o600.cloudfront.net/wp-content/uploads/2022/03/17112751/2022\\_Work\\_Trend\\_Index\\_Annual\\_Report.pdf](https://d110erj175o600.cloudfront.net/wp-content/uploads/2022/03/17112751/2022_Work_Trend_Index_Annual_Report.pdf)
- Guenole, N. F. (2017). *The Power of People*.
- Hom, P., Allen, D., & Griffith, R. (2019). *Employee Retention and Turnover: Why Employees Stay or Leave*.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Ανάκτηση από <https://www.casact.org/sites/default/files/2022-12/James-G.-et-al.-2nd-edition-Springer-2021.pdf>
- Japkowicz, N., & Shah, M. (2011). *Evaluating Learning Algorithms, A Classification Perspective*. doi:<https://doi.org/10.1017/CBO9780511921803>
- Johnson, R. A. (1988). *Applied multivariate statistical analysis*. doi:ISBN: 978-0-13-041146-4
- Ke, G., Meng, Q., Finley, T., & Wang, T. (2017). LightGBM: a highly efficient gradient boosting decision tree. Ανάκτηση από [https://www.researchgate.net/publication/378480234\\_LightGBM\\_A\\_Highly\\_Efficient\\_Gradient\\_Boosting\\_Decision\\_Tree](https://www.researchgate.net/publication/378480234_LightGBM_A_Highly_Efficient_Gradient_Boosting_Decision_Tree)
- Kuhn, M., & Kjell, J. (2019). *Feature Engineering and Selection: A Practical Approach for Predictive Models*. doi:<https://doi.org/10.1201/9781315108230>
- Mann, P. S. (2013). *Introductory Statistics*. doi:978-1118318706
- Markman, J. (2026). *Forbs*. Ανάκτηση από <https://www.forbes.com/sites/jonmarkman/2026/04/06/oracles-massive-30000-layoff-as-ai-spending-surges/>
- Maslach, C., & Jackson, S. (1981). The Measurement of Experienced Burnout. doi:10.1002/job.4030020205

- Meyer, J. P. (1991). A three-component conceptualization of organizational commitment. *Human Resource Management Review*. doi:[https://doi.org/10.1016/1053-4822\(91\)90011-Z](https://doi.org/10.1016/1053-4822(91)90011-Z)
- Pandey, A., Maheshwari, M., & Malik, N. (2024). A systematic literature review on employee well-being: Mapping multi-level antecedents, moderators, mediators and future research agenda. Ανάκτηση από <https://www.sciencedirect.com/science/article/pii/S0001691825003932>
- Pandley, D. (2019). Job Hopping Tendency in Millenials. *NCC Journal*. doi:<https://doi.org/10.3126/nccj.v4i1.24733>
- Park, J. F. (2024). *Developing an advanced prediction model for new employee turnover intention utilizing machine learning techniques*. doi:[https://doi.org/10.1038/s41598-023-50593-4?urlappend=%3Futm\\_source%3Dresearchgate.net%26utm\\_medium%3Darticle](https://doi.org/10.1038/s41598-023-50593-4?urlappend=%3Futm_source%3Dresearchgate.net%26utm_medium%3Darticle)
- Team, G. (2026). *GeeksForGeeks XGBClassifier documentation*. Ανάκτηση από <https://www.geeksforgeeks.org/machine-learning/xgbclassifier/>
- Team, I. I. (2026). *Imbalanced-learn SMOTE documentation*. Ανάκτηση από [https://imbalanced-learn.org/stable/references/generated/imblearn.over\\_sampling.SMOTE.html](https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTE.html)
- Team, M. D. (2026). *LGBMClassifier Documentation*. Ανάκτηση από <https://lightgbm.readthedocs.io/en/latest/pythonapi/lightgbm.LGBMClassifier.html>
- Team, M. D. (2026). *Matplotlib documentation*. Ανάκτηση από [https://matplotlib.org/stable/api/pyplot\\_summary.html](https://matplotlib.org/stable/api/pyplot_summary.html)
- Team, N. D. (2026). *NumPy v.2.4 : the absolute basics for beginners*. Ανάκτηση από [https://numpy.org/doc/2.4/user/absolute\\_beginners.html](https://numpy.org/doc/2.4/user/absolute_beginners.html)
- Team, S. L. (2026). *Scikit-learn LogisticRegression documentation*. Ανάκτηση από [https://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LogisticRegression.html](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html)
- Team, S. L. (2026). *Scikit-learn RandomForestClassifier documentation*. Ανάκτηση από <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
- Team, S. L. (2026). *Scikit-learn StandardScaler documentation*. Ανάκτηση από <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>
- Team, S. L. (2026). *Scikit-learn SVM documentation*. Ανάκτηση από <https://scikit-learn.org/stable/modules/svm.html>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley. doi:0201076160
- Zhao, Y. H. (2018). Employee turnover prediction with machine learning: A reliable approach. doi:<https://doi.org/10.1007/978-3-030-01057-7>



## Παράρτημα Ι – Γλωσσάριο

- **Employee Turnover (Κινητικότητα/Εναλλαγή Προσωπικού):** Ο ρυθμός με τον οποίο οι εργαζόμενοι εγκαταλείπουν έναν οργανισμό και αντικαθίστανται από νέο προσωπικό.
- **Οικειοθελής Αποχώρηση (Voluntary Turnover):** Η μορφή αποχώρησης όπου η πρωτοβουλία για τη διακοπή της εργασιακής σχέσης ανήκει στον εργαζόμενο και συνδέεται με την ικανοποίηση και τη δέσμευσή του.
- **Αναγκαστική Αποχώρηση (Involuntary Turnover):** Η διακοπή της σύμβασης με πρωτοβουλία του εργοδότη, συνήθως λόγω ανεπαρκούς απόδοσης, πειθαρχικών παραπτωμάτων ή αναδιάρθρωσης.
- **Παράγοντες Ωθής (Push Factors):** Οι λόγοι που «ωθούν» έναν εργαζόμενο μακριά από την εταιρεία, όπως η επαγγελματική στασιμότητα και η έλλειψη υποστήριξης από τη διοίκηση.
- **Παράγοντες Έλξης (Pull Factors):** Λόγοι που προσελκύουν έναν εργαζόμενο σε μια νέα θέση, όπως καλύτερες απολαβές, ευελιξία και η φήμη ενός οργανισμού.
- **Συναισθηματική Δέσμευση (Affective Commitment):** Η ισχυρότερη μορφή δέσμευσης, όπου ο εργαζόμενος νιώθει συναισθηματικά δεμένος με την εταιρεία και αποδέχεται πλήρως τις αξίες της.
- **Κανονιστική Δέσμευση (Normative Commitment):** Δέσμευση που πηγάζει από ένα αίσθημα ηθικής υποχρέωσης ή καθήκοντος προς τον εργοδότη.
- **Δέσμευση Συνέχειας (Continuance Commitment):** Η παραμονή στον οργανισμό λόγω του υψηλού κόστους αποχώρησης (οικονομικού ή επαγγελματικού), γεγονός που συχνά οδηγεί σε αίσθημα «εγκλωβισμού».
- **Job Hopping:** Η στρατηγική επιλογή συχνής εναλλαγής εργοδοτών σε σύντομα χρονικά διαστήματα (συνήθως 1-2 έτη) με σκοπό την ταχύτερη μισθολογική εξέλιξη και την απόκτηση εμπειριών.
- **Quiet Quitting (Σιωπηρή Παραίτηση):** Η κατάσταση όπου ένας εργαζόμενος περιορίζει την προσπάθειά του αυστηρά στα βασικά του καθήκοντα, ως αντίδραση στην επαγγελματική εξουθένωση ή την έλλειψη δέσμευσης.
- **Επαγγελματική Εξουθένωση (Burnout):** Μια κατάσταση σωρευτικής κόπωσης και συναισθηματικής εξάντλησης που προκύπτει από το εργασιακό στρες και τον υπερβολικό φόρτο εργασίας.
- **Εργασιακή Ευεξία (Employee Well-being):** Η συνολική ποιότητα της εμπειρίας ενός εργαζομένου, η οποία περιλαμβάνει σωματικές, ψυχικές, κοινωνικές, οικονομικές και πνευματικές διαστάσεις.
- **Ισορροπία Επαγγελματικής και Προσωπικής Ζωής (Work-Life Balance):** Η ισορροπία μεταξύ των επαγγελματικών υποχρεώσεων και του προσωπικού χρόνου, η οποία έχει αναδειχθεί σε βασική απαίτηση των εργαζομένων μετά την πανδημία.
- **Υβριδικό Μοντέλο Εργασίας (Hybrid Work):** Ένας συνδυασμός εργασίας από το γραφείο και εξ αποστάσεως εργασίας, που αποτελεί την ιδανική προτίμηση για τη συντριπτική πλειοψηφία των εργαζομένων.
- **People Analytics (HR Analytics):** Η συστηματική εφαρμογή στατιστικών μεθόδων και τεχνολογίας στα δεδομένα του ανθρώπινου δυναμικού για τη βελτίωση των επιχειρηματικών αποτελεσμάτων.

- **Προγνωστική Ανάλυση (Predictive Analytics):** Η χρήση ιστορικών δεδομένων και αλγορίθμων για την πρόβλεψη μελλοντικών γεγονότων, όπως η πιθανότητα αποχώρησης ενός υπαλλήλου.
- **Πολυδιασπασιμότητα:** Η κατάσταση όπου μια μεταβλητή παρουσιάζει έναν υπερβολικά μεγάλο αριθμό διαφορετικών τιμών ή κατηγοριών.
- **Διασπορά:** Η έκταση με την οποία οι τιμές μιας μεταβλητής απλώνονται ή κατανέμονται μέσα σε ένα σύνολο δεδομένων.
- **Ερευνητική Ανάλυση Δεδομένων (EDA):** Η διαδικασία εξερεύνησης ενός συνόλου δεδομένων για τον εντοπισμό μοτίβων, ανωμαλιών και συσχετίσεων πριν από τη μοντελοποίηση.
- **Εποπτευόμενη Μάθηση (Supervised Learning):** Τύπος μηχανικής μάθησης όπου το μοντέλο εκπαιδεύεται σε δεδομένα που περιλαμβάνουν ήδη την απάντηση-στόχο (π.χ. Attrition: Yes/No).
- **Μη Επιβλεπόμενη Μάθηση (Unsupervised Learning):** Μέθοδος όπου ο αλγόριθμος αναζητά κρυφές δομές ή ομάδες στα δεδομένα χωρίς προκαθορισμένες ετικέτες, όπως στην περίπτωση της συσταδοποίησης.
- **Clustering (Συσταδοποίηση):** Η ομαδοποίηση παρατηρήσεων (εργαζομένων) με βάση τις ομοιότητες στα χαρακτηριστικά τους.
- **SMOTE (Synthetic Minority Over-sampling Technique):** Τεχνική παραγωγής συνθετικών δεδομένων για την εξισορρόπηση ενός συνόλου δεδομένων όπου η μία κλάση (π.χ. όσοι αποχωρούν) υποεκπροσωπείται.
- **One-Hot Encoding:** Μέθοδος μετατροπής κατηγορικών μεταβλητών (π.χ. Τμήμα) σε αριθμητική μορφή (0 και 1) ώστε να μπορούν να επεξεργαστούν από τους αλγορίθμους.
- **ROC AUC Score:** Μια μετρική που αξιολογεί την ικανότητα ενός μοντέλου να διαχωρίζει σωστά τις δύο κλάσεις (παραμονή vs αποχώρηση).
- **Precision (Πιστότητα) & Recall (Ανάκληση):** Η Πιστότητα μετρά την ακρίβεια των θετικών προβλέψεων, ενώ η Ανάκληση μετρά την ικανότητα του μοντέλου να εντοπίζει όλες τις πραγματικές περιπτώσεις αποχώρησης.
- **Λειτουργική & Δυσλειτουργική Αποχώρηση (Functional & Dysfunctional Turnover):** Η λειτουργική αφορά στην αποχώρηση εργαζομένων με χαμηλή απόδοση, ενώ η δυσλειτουργική αφορά την απώλεια των λεγόμενων "High performers" (εργαζόμενοι με υψηλή απόδοση).
- **Αποφεύξιμη & Μη Αποφεύξιμη Αποχώρηση (Avoidable & Unavoidable Turnover):** Αποφεύξιμες είναι οι αποχωρήσεις που προλαμβάνονται με διοικητικές παρεμβάσεις (π.χ. αύξηση μισθού), ενώ μη αποφεύξιμες είναι αυτές που οφείλονται σε εξωτερικούς παράγοντες (π.χ. υγεία, οικογένεια).
- **Κεντρικότητα της Εργασίας (Work Centrality):** Ο βαθμός στον οποίο η εργασία κατέχει κεντρικό ρόλο στη ζωή του ατόμου σε σχέση με άλλους τομείς, όπως η προσωπική και οικογενειακή ζωή.
- **Ολιστικό Σύστημα Αμοιβών (Total Rewards):** Μια στρατηγική που περιλαμβάνει όχι μόνο τον μισθό, αλλά και παροχές όπως ιδιωτική ασφάλιση, κάρτες σίτισης και εταιρικά οχήματα, με σκοπό τη διακράτηση του προσωπικού.
- **Προσέλκυση & Διακράτηση Ταλέντων (Talent Acquisition & Retention):** Οι στρατηγικές διαδικασίες για την εύρεση και τη διατήρηση ικανών στελεχών εντός του οργανισμού.

- **Ακραίες Τιμές (Outliers):** Παρατηρήσεις που απέχουν σημαντικά από το υπόλοιπο σύνολο δεδομένων. Στην εργασία χρησιμοποιήθηκε η μέθοδος "Tukey's Fences" για τον εντοπισμό τους.
- **Ελλιπείς Τιμές (Missing Values):** Κενά σε ένα σύνολο δεδομένων που απαιτούν διαχείριση (π.χ. διαγραφή ή αντικατάσταση/imputation) για να μην αλλοιωθούν τα αποτελέσματα της ανάλυσης.
- **Κλίμακα Likert:** Ψυχομετρική κλίμακα (συνήθως 1-5) που χρησιμοποιείται στα ερωτηματολόγια για τη μέτρηση στάσεων και απόψεων (π.χ. 1: Καθόλου - 5: Πάρα πολύ).
- **Συντελεστές Pearson & Spearman:** Στατιστικά μέτρα που υπολογίζουν τη συσχέτιση μεταξύ μεταβλητών. Ο Spearman χρησιμοποιείται ειδικά για δεδομένα τακτικής κλίμακας, όπως οι ερωτήσεις Likert.
- **Cramer's V:** Δείκτης που μετρά την ισχύ της συσχέτισης μεταξύ δύο κατηγορικών μεταβλητών.
- **Σκόπιμη Δειγματοληψία & Δειγματοληψία Χιονοστιβάδας (Purposive & Snowball Sampling):** Μέθοδοι συλλογής δειγμάτων μέσω στοχευμένων επιλογών ή μέσω συστάσεων από τους ίδιους τους συμμετέχοντες.
- **Μηχανική Χαρακτηριστικών (Feature Engineering):** Η διαδικασία μετασχηματισμού των πρωτογενών δεδομένων σε μορφή που μεγιστοποιεί την πληροφοριακή τους αξία για τους αλγορίθμους.
- **Υπερεκπαίδευση (Overfitting):** Το φαινόμενο όπου ένα μοντέλο "απομνημονεύει" τα δεδομένα εκπαίδευσης και αδυνατεί να κάνει σωστές προβλέψεις σε νέα, άγνωστα δεδομένα.
- **Πίνακας Σύγχυσης (Confusion Matrix):** Εργαλείο αξιολόγησης που δείχνει τις σωστές και λανθασμένες προβλέψεις ενός μοντέλου (True/False Positives & Negatives).
- **Μπεϋζιανή Βελτιστοποίηση (Bayesian Optimization):** Σύγχρονη μέθοδος εύρεσης των βέλτιστων παραμέτρων ενός μοντέλου, η οποία είναι πιο αποδοτική από την παραδοσιακή αναζήτηση σε πλέγμα (Grid Search).
- **Silhouette Score & Elbow Method:** Τεχνικές που χρησιμοποιούνται στη συσταδοποίηση (clustering) για τον προσδιορισμό του βέλτιστου αριθμού ομάδων (K).
- **Διαρροή Δεδομένων (Data Leakage):** Ένα κρίσιμο σφάλμα όπου πληροφορίες από το σύνολο δοκιμής (test set) "διαρρέουν" στο σύνολο εκπαίδευσης, οδηγώντας σε πλασματικά υψηλή ακρίβεια.
- **Proof-of-Concept (Απόδειξη Ιδέας):** Μια δοκιμαστική εφαρμογή (όπως η ανάλυση του dataset της IBM) που σκοπό έχει να αποδείξει τη σκοπιμότητα και την αποτελεσματικότητα μιας μεθοδολογίας.
- **K-Prototypes:** Ο εξειδικευμένος αλγόριθμος συσταδοποίησης που χρησιμοποιήθηκε στην εργασία, ο οποίος μπορεί να διαχειριστεί ταυτόχρονα αριθμητικά και κατηγορικά δεδομένα συνδυάζοντας τις λογικές των αλγορίθμων K-Means και K-Modes.
- **Πίνακας Αποστάσεων Gower (Gower Distance):** Μια μετρική που επιτρέπει τον υπολογισμό της «απόστασης» (ομοιότητας) μεταξύ παρατηρήσεων που περιλαμβάνουν μείγμα ποσοτικών και ποιοτικών μεταβλητών.
- **Z-score Standardization (StandardScaler):** Η διαδικασία μετασχηματισμού των αριθμητικών δεδομένων ώστε να έχουν μέσο όρο 0 και τυπική απόκλιση 1, διασφαλίζοντας ότι μεταβλητές με διαφορετικές κλίμακες (π.χ. μισθός vs ηλικία) θα αντιμετωπίζονται ισότιμα από το μοντέλο.

- **Αδράνεια (Inertia):** Το άθροισμα των τετραγώνων των αποστάσεων κάθε δείγματος από το πλησιέστερο κέντρο της συστάδας του, που χρησιμοποιείται στη μέθοδο Elbow για την εύρεση του βέλτιστου αριθμού ομάδων.
- **RBF Kernel (Radial Basis Function):** Ένας μη γραμμικός πυρήνας που χρησιμοποιήθηκε στον αλγόριθμο SVM για να επιτρέψει τον διαχωρισμό δεδομένων που παρουσιάζουν πολύπλοκες και μη γραμμικές σχέσεις.
- **Διασταυρούμενη Επικύρωση (Cross-Validation):** Μια τεχνική αξιολόγησης όπου το σύνολο δεδομένων χωρίζεται σε πολλαπλά τμήματα (folds) για να διασφαλιστεί ότι το μοντέλο είναι σταθερό και δεν έχει υπερεκπαιδευτεί σε ένα συγκεκριμένο κομμάτι των δεδομένων.
- **Platt Scaling:** Μια μέθοδος βαθμονόμησης που χρησιμοποιείται στον SVM για να μετατρέψει τις αποστάσεις από το επίπεδο διαχωρισμού σε πραγματικές πιθανότητες αποχώρησης.
- **Πολυσυγγραμμικότητα (Multicollinearity):** Το φαινόμενο όπου δύο ή περισσότερες ανεξάρτητες μεταβλητές συνδέονται τόσο έντονα μεταξύ τους (π.χ. Monthly Income και Job Level), που δυσκολεύουν τη στατιστική ερμηνεία της συνεισφοράς της καθεμίας.
- **Σιγμοειδής Συνάρτηση (Sigmoid Function):** Η μαθηματική συνάρτηση που χρησιμοποιεί η Λογιστική Παλινδρόμηση για να «συμπίεσει» οποιαδήποτε αριθμητική τιμή στο διάστημα μεταξύ 0 και 1, μετατρέποντάς την σε πιθανότητα.
- **Διαρροή Δεδομένων (Data Leakage):** Ένα κρίσιμο σφάλμα στη μηχανική μάθηση όπου πληροφορίες από το σύνολο δοκιμής «μολύνουν» το σύνολο εκπαίδευσης, οδηγώντας σε πλασματικά υψηλή ακρίβεια.
- **Στρωματοποιημένη Δειγματοληψία (Stratified Sampling):** Μια μέθοδος διαχωρισμού των δεδομένων που διατηρεί την αρχική αναλογία των κλάσεων (π.χ. το ποσοστό όσων έφυγαν vs όσων έμειναν) τόσο στην εκπαίδευση όσο και στη δοκιμή.
- **White-Collar Workers (Υπάλληλοι Γραφείου):** Ο πληθυσμός-στόχος της έρευνας, που περιλαμβάνει εργαζόμενους οι οποίοι εκτελούν κυρίως πνευματική ή διοικητική εργασία.
- **Η Μεγάλη Επαναξιολόγηση (The Great Reshuffle):** Ο όρος που περιγράφει τη μαζική τάση των εργαζομένων μετά την πανδημία να αλλάζουν προτεραιότητες, θέτοντας την ευεξία πάνω από την καριέρα.
- **Work Centrality (Κεντρικότητα της Εργασίας):** Ο βαθμός στον οποίο η εργασία αποτελεί το επίκεντρο της ταυτότητας και της ζωής ενός ατόμου.
- **Ψυχολογικό Συμβόλαιο (Psychological Contract):** Οι άγραφοι κανόνες και οι προσδοκίες μεταξύ εργοδότη και εργαζομένου, η ρήξη των οποίων (π.χ. λόγω αδιαφορίας για την ευεξία) οδηγεί συχνά σε αποχώρηση.
- **Μηχανισμός Προσαρμογής (Coping Mechanism):** Η χρήση πρακτικών όπως η «σιωπηρή παραίτηση» (Quiet Quitting) ως αμυντική αντίδραση απέναντι στην υποτιμημένη εργασία ή την εργοδοτική αδιαφορία.
- **GDPR (Γενικός Κανονισμός Προστασίας Δεδομένων):** Το ευρωπαϊκό πλαίσιο προστασίας προσωπικών δεδομένων που τηρήθηκε κατά τη συλλογή των απαντήσεων του ερωτηματολογίου.

## Παράρτημα II – Ερωτηματολόγιο και Κώδικας

### Ακαδημαϊκή Έρευνα για τις Σύγχρονες Τάσεις στην Ελληνική Αγορά Εργασίας

**B I U**  

Το παρόν ερωτηματολόγιο σχεδιάστηκε στο πλαίσιο εκπόνησης Μεταπτυχιακής / Διπλωματικής εργασίας. Στόχος της έρευνας είναι η μελέτη των σύγχρονων εργασιακών τάσεων (όπως το Job Hopping και το Quiet Quitting), καθώς και η ανάλυση των παραγόντων που επηρεάζουν την εργασιακή ευεξία και την πρόθεση αλλαγής καριέρας στην Ελλάδα.

#### Πληροφορίες Συμμετοχής:

**Target Group:** Απευθύνεται αποκλειστικά σε εργαζόμενους γραφείου και πνευματικής εργασίας (**white-collar workers**) που δραστηριοποιούνται στην ελληνική αγορά.

**Δομή & Χρόνος:** Αποτελείται από 33 σύντομες ερωτήσεις. Ο εκτιμώμενος χρόνος συμπλήρωσης είναι περίπου **5-10 λεπτά**.

**Διασφάλιση Απορρήτου (GDPR):** Η συμμετοχή σας είναι απολύτως οικειοθελής. Οι απαντήσεις συλλέγονται με πλήρη **ανωνυμία**, δεν καταγράφονται διευθύνσεις email ή IP, και τα δεδομένα θα χρησιμοποιηθούν αποκλειστικά για στατιστική ανάλυση στο πλαίσιο της παρούσας ακαδημαϊκής μελέτης, τηρώντας όλες τις διατάξεις του Ευρωπαϊκού Κανονισμού Προστασίας Δεδομένων (GDPR).

Σας ευχαριστώ θερμά για τον χρόνο και τη συμβολή σας στην έρευνα!

...

1. Φύλο



☒ Multiple choice

☐ Άνδρας

☐ Γυναίκα

☐ Άλλο

☐ Add option or [Add "Other"](#)



Required ☒



Εικόνα 76 - Ερωτηματολόγιο εικ.1

2. Ηλικιακή Ομάδα \*

- ☐ 18-25 (Gen Z)
- ☐ 26-41 (Millennials)
- ☐ 42-57 (Gen X)
- ☐ 58+ (Baby Boomers)

3. Επίπεδο Εκπαίδευσης \*

- ☐ Δευτεροβάθμια Εκπαίδευση
- ☐ Πτυχίο ΑΕΙ-ΤΕΙ
- ☐ Μεταπτυχιακό Δίπλωμα
- ☐ Διδακτορικό Δίπλωμα

4. Εργάζεστε, ως "White-Collar Worker" (Εργαζόμενος γραφείου/πνευματική εργασία), σε \*  
έναν εργοδότη ή παραπάνω από έναν;

- ☐ Δεν ειμαι White-Collar Worker
- ☐ Δουλεύω σε έναν εργοδότη
- ☐ Δουλεύω σε παραπάνω από έναν εργοδότη

Εικόνα 77 - Ερωτηματολόγιο εικ.2

#### 5. Κλάδος Απασχόλησης

- ☐ Τεχνολογία & Πληροφορική
- ☐ Οικονομικά, Τράπεζες & Ασφάλειες
- ☐ Μάρκετινγκ & Επικοινωνία
- ☐ Ανθρώπινο Δυναμικό (HR)
- ☐ Διοικητική Υποστήριξη
- ☐ Πωλήσεις & Εξυπηρέτηση Πελατών
- ☐ Other: .....

#### 6. Ιεραρχικό Επίπεδο Θέσης \*

- ☐ Entry Level
- ☐ Mid-level
- ☐ Senior
- ☐ Management
- ☐ Executive

#### 7. Μέγεθος Εταιρείας \*

- ☐ Πολύ μικρή (έως 10 άτομα)
- ☐ Μικρομεσαία (11-250 άτομα)
- ☐ Μεγάλη - Πολυεθνική (250+ άτομα)

Εικόνα 78 - Ερωτηματολόγιο εικ.3

8. Συνολική Εργασιακή Εμπειρία (σε έτη) \*

- ☐ 0-2
- ☐ 3-5
- ☐ 6-10
- ☐ 11-20
- ☐ 20+

9. Χρόνος Παραμονής στον Τρέχοντα Εργοδότη \*

- ☐ Λιγότερο από 1 έτος
- ☐ 1-2 έτη
- ☐ 3-5 έτη
- ☐ Πάνω από 5 έτη

10. Πόσο ικανοποιημένος/η είστε από την τρέχουσα εργασία σας; \*

- |         |                       |                       |                       |                       |                       |           |
|---------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------|
|         | 1                     | 2                     | 3                     | 4                     | 5                     |           |
| Καθόλου | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | Πάρα πολύ |

11. Πόσο ικανοποιημένος/η είστε από τις τρέχουσες οικονομικές απολαβές σας; \*

- |         |                       |                       |                       |                       |                       |           |
|---------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------|
|         | 1                     | 2                     | 3                     | 4                     | 5                     |           |
| Καθόλου | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | Πάρα πολύ |



12. Ποιο είναι το μέγιστο διάστημα που θεωρείτε ιδανικό για παραμονή σε έναν εργοδότη; \*

- ☐ Λιγότερο από 1 έτος
- ☐ 1-2 έτη
- ☐ 3-5 έτη
- ☐ Πάνω από 5 έτη

...

13. Πόσο συχνά ενημερώνετε το επαγγελματικό σας προφίλ (π.χ. LinkedIn) ή παρακολουθείτε αγγελίες εργασίας; \*

- ☐ Πολύ σπάνια
- ☐ Κάθε χρόνο
- ☐ Κάθε 6 μήνες
- ☐ Κάθε 3 μήνες
- ☐ Κάθε μήνα
- ☐ Κάθε εβδομάδα ή πιο συχνά

14. Πόσο συχνά σκέφτεστε να αλλάξετε εργοδότη; \*

- ☐ Δεν το σκέφτομαι
- ☐ Κάθε χρόνο
- ☐ Κάθε 6 μήνες
- ☐ Κάθε 3 μήνες
- ☐ Κάθε μήνα
- ☐ Κάθε εβδομάδα

Εικόνα 80 - Ερωτηματολόγιο εικ.5

15. Γνωρίζετε τον όρο "Job Hopping"; \*

☐ Ναι

☐ Όχι

#### Ορισμός Job Hopping

Ως Job Hopping ορίζεται η στρατηγική επιλογή συχνής αλλαγής εργοδοτών (συνήθως ανά 1-2 έτη) με στόχο την ταχύτερη μισθολογική και επαγγελματική εξέλιξη.

16. Πόσο πιστεύετε ότι ωφελεί τον εργαζόμενο η συγκεκριμένη πρακτική; \*

|                 | 1                     | 2                     | 3                     | 4                     | 5                     |              |
|-----------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|--------------|
| Καθόλου ωφέλιμη | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | Πολύ ωφέλιμη |

17. Έχετε εφαρμόσει ποτέ τη συγκεκριμένη πρακτική; \*

☐ Ναι

☐ Όχι

...

18. Επιθυμείτε να αλλάξετε εργοδότη στην παρούσα χρονική στιγμή; \*

☐ Ναι

☐ Όχι

Εικόνα 81 - Ερωτηματολόγιο εικ.6

19. Πόσους εργοδότες έχετε αλλάξει κατά την τελευταία 5ετία; \*

- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3+

20. Αισθάνεστε ότι η προσπάθειά σας ανταμείβεται δίκαια (οικονομικά ή ηθικά); \*

- ☐ Καθόλου
- ☐ Λίγο
- ☐ Μέτρια
- ☐ Πολύ
- ☐ Πάρα πολύ

21. Πόσο συχνά νιώθετε ότι καταβάλλετε την ελάχιστη δυνατή προσπάθεια απλώς για να διατηρήσετε τη θέση σας; \*

- ☐ Δεν το κάνω
- ☐ Πολύ σπάνια
- ☐ Σπάνια
- ☐ Μέτρια
- ☐ Συχνά
- ☐ Πολύ συχνά

22. Έχετε σκεφτεί να αλλάξετε εργοδότη τους τελευταίους 3 μήνες, αλλά κρίνατε ότι δεν \*  
σας συνέφερε να αποχωρήσετε άμεσα;

- ☐ Ναι
- ☐ Όχι

#### Ορισμός Quiet Quitting

Ως Quiet Quitting ορίζεται η επιλογή του εργαζομένου να περιορίζεται αυστηρά στα καθήκοντα που ορίζει η σύμβασή του, αποφεύγοντας την επιπλέον εθελοντική εργασία ή την ψυχολογική ταύτιση με τους στόχους της εταιρείας. Με λίγα λόγια, ένας εργαζόμενος κάνει το λιγότερο δυνατό για να μην απολυθεί, έχοντας συνήθως απώτερο σκοπό την προσωπική του ευημερία ή την παράλληλη εύρεση εργασίας αλλού.

23. Έχετε εφαρμόσει ποτέ το Quiet Quitting; \*

- ☐ Ναι
- ☐ Όχι
- ☐ Δεν ξέρω - Δεν απαντώ

24. Πόσο πιστεύετε ότι ωφελεί τον εργαζόμενο (π.χ. σε θέματα ψυχικής υγείας, \*  
οικονομικά) η συγκεκριμένη πρακτική;

|           |                       |                       |                       |                       |                       |           |
|-----------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------|
|           | 1                     | 2                     | 3                     | 4                     | 5                     |           |
| Πολύ λίγο | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | Πάρα πολύ |

25. Ποιο μοντέλο εργασίας εφαρμόζετε αυτή τη στιγμή; \*

- ☐ Δια ζώσης (On-Site)
- ☐ Τηλεργασία (Remote)
- ☐ Υβριδικό (Hybrid)

26. Ποιο μοντέλο εργασίας θα προτιμούσατε αν είχατε την επιλογή; \*

- ☐ Δια ζώσης (On-site)
- ☐ Τηλεργασία (Remote)
- ☐ Υβριδικό (Hybrid)

27. Πόσο συχνά εργάζεστε εκτός του συμβατικού σας ωραρίου (μέρες τον χρόνο); \*

- ☐ Πολύ λίγο (1-15 μέρες)
- ☐ Λίγο (16 - 30 μέρες)
- ☐ Μέτρια (31 - 60 μέρες)
- ☐ Πολύ (61 - 90 μέρες)
- ☐ Πάρα πολύ (91+ μέρες)

28. Πόσο συχνά νιώθετε συναισθηματική εξάντληση στο τέλος της εργάσιμης ημέρας; \*

- ☐ Πολύ λίγες φορές τον χρόνο
- ☐ Λίγες φορές τον χρόνο
- ☐ Μέτρια συχνότητα
- ☐ Πολλές φορές τον χρόνο
- ☐ Πάρα πολλές φορές τον χρόνο

Εικόνα 84 - Ερωτηματολόγιο εικ.9

29. Τι επίπεδα εργασιακού άγχους (stress) βιώνετε στην καθημερινότητά σας; \*

- ☐ Καθόλου έντονο
- ☐ Λίγο έντονο
- ☐ Μέτρια έντονο
- ☐ Πολύ έντονο
- ☐ Πάρα πολύ έντονο

30. Πόσο πιστεύετε ότι το επίπεδο άγχους σας συνδέεται με το μοντέλο εργασίας που ακολουθείτε; \*

- ☐ Δεν ξέρω - Δεν απαντώ
- ☐ Καμία σύνδεση μεταξύ τους
- ☐ Ελάχιστη σύνδεση
- ☐ Μέτρια σύνδεση
- ☐ Άμεση σύνδεση

...

31. Θεωρείτε ότι ο εργοδότης σας ενδιαφέρεται έμπρακτα για την ευεξία σας; \*

- ☐ Δεν ξέρω
- ☐ Δεν ενδιαφέρεται
- ☐ Λίγο ενδιαφέρον
- ☐ Μέτριο ενδιαφέρον
- ☐ Ενδιαφέρεται
- ☐ Πολύ ενδιαφέρον

Εικόνα 85 - Ερωτηματολόγιο εικ.10

32. Στην παρούσα φάση, πόσο ψηλά ιεραρχείτε την εργασία σε σχέση με την προσωπική σας ζωή; \*

|             | 1                     | 2                     | 3                     | 4                     | 5                     |            |
|-------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|------------|
| Πολύ χαμηλά | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | Πολύ υψηλά |

33. Πόσο πιθανό θεωρείτε να αλλάξετε εργοδότη μέσα στους επόμενους 12 μήνες; \*


|         | 1                     | 2                     | 3                     | 4                     | 5                     |             |
|---------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|-------------|
| Απίθανο | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | <input type="radio"/> | Πολύ πιθανό |

Εικόνα 86 - Ερωτηματολόγιο εικ.11


Github link πηγαίου κώδικα:

[https://github.com/chrisimak60/Thesis-Machine\\_Learning\\_on\\_work\\_trends\\_and\\_employee\\_retention](https://github.com/chrisimak60/Thesis-Machine_Learning_on_work_trends_and_employee_retention)

## Παράρτημα III – Εικόνες



Εικόνα 87 - Litmaps use example 1



Εικόνα 88 - Litmaps use example 2



## Greek Grammar Checker (Free & No Signup)

Για λόγους **σαφίνειας**, τα περιεχόμενα του πίνακα σύγκρισης θα εξηγηθούν για το σενάριο που εξετάζεται:

- TP: Οι εργαζόμενοι που αποχώρησαν και προβλέφθηκε σωστά ότι αποχώρησαν.
- FP: Οι εργαζόμενοι που παρέμειναν και προβλέφθηκε λάθος ότι αποχώρησαν.
- FN: Οι εργαζόμενοι που αποχώρησαν και προβλέφθηκε λάθος ότι παρέμειναν.
- TN: Οι εργαζόμενοι που παρέμειναν και προβλέφθηκε σωστά ότι παρέμειναν.

Word Count: 59/1000

Για λόγους **σαφήνειας**, τα περιεχόμενα του πίνακα σύγκρισης θα εξηγηθούν για το σενάριο που εξετάζεται:


- TP: Οι εργαζόμενοι που αποχώρησαν και προβλέφθηκε σωστά ότι αποχώρησαν.
- FP: Οι εργαζόμενοι που παρέμειναν και προβλέφθηκε λάθος ότι αποχώρησαν.
- FN: Οι εργαζόμενοι που αποχώρησαν και προβλέφθηκε λάθος ότι παρέμειναν.
- TN: Οι εργαζόμενοι που παρέμειναν και προβλέφθηκε σωστά ότι παρέμειναν.

Word Count: 59


Greek

Check Grammar


Εικόνα 89 - Παράδειγμα χρήσης textgens.com για ορθογραφία




Εικόνα 90 - Παράδειγμα σημείωσης πηγών σε επιπρόσθετο αρχείο




Εικόνα 91 - Stress work model




Εικόνα 92 - work-life priority




Εικόνα 93 - Change probability in 12 months




Εικόνα 94 - gender




Εικόνα 95 - education level




Εικόνα 96 - white-collar status




Εικόνα 97 - company size




Εικόνα 98 - total experience




Εικόνα 99 - tenure at current employer




Εικόνα 100 - thought change frequency



Εικόνα 101 - job hopping awareness




Εικόνα 102 - attrition intent




Εικόνα 103 - employers changed in 5 years







Εικόνα 104 - fair reward perception




Εικόνα 105 - overtime frequency




Εικόνα 106 - emotional exhaustion frequency




Εικόνα 107 – Part2 Categorical values BusinessTravel




Εικόνα 108 – Part2 Categorical values Education




Εικόνα 109 – Part2 Categorical values EducationField




Εικόνα 110 – Part2 Categorical values EnvironmentSatisfaction




Εικόνα 111 – Part2 Categorical values Gender




Εικόνα 112 – Part2 Categorical values JobInvolvement




Εικόνα 113 – Part2 Categorical values JobLevel




Εικόνα 114 – Part2 Categorical values JobSatisfaction




Εικόνα 115 – Part2 Categorical values MaritalStatus



Εικόνα 116 – Part2 Categorical values OverTime




Εικόνα 117 – Part2 Categorical values RelationshipSatisfaction  
StockOptionLevel




Εικόνα 118 – Part2 Categorical values

Category of DailyRate  
Mean : 802.4857142857143  
Median : 802.0  
Standard Deviation : 403.50909994352816  
Minimum value : 102.0  
Maximum value : 1499.0




Εικόνα 119 - Part2 Numerical Values DailyRate

Category of HourlyRate  
Mean : 65.89115646258503  
Median : 66.0  
Standard Deviation : 20.329427593996165  
Minimum value : 30.0  
Maximum value : 100.0




Εικόνα 120 - Part2 Numerical Values HourlyRate

Category of MonthlyRate  
Mean : 14313.103401360544  
Median : 14235.5  
Standard Deviation : 7117.786844059976  
Minimum value : 2894.0  
Maximum value : 26999.0




Eikóna 121 - Part2 Numerical Values MonthlyRate

Category of NumCompaniesWorked  
Mean : 2.6931972789115646  
Median : 2.0  
Standard Deviation : 2.498009006070747  
Minimum value : 0.0  
Maximum value : 9.0




Eikóna 122 - Part2 Numerical Values NumCompaniesWorked

Category of PercentSalaryHike  
Mean : 15.209523809523809  
Median : 14.0  
Standard Deviation : 3.6599377165396407  
Minimum value : 11.0  
Maximum value : 25.0




Eikóna 123 - Part2 Numerical Values PercentSalaryHike

Category of TotalWorkingYears  
Mean : 11.279591836734694  
Median : 10.0  
Standard Deviation : 7.780781675514997  
Minimum value : 0.0  
Maximum value : 40.0




Eikóna 124 - Part2 Numerical Values TotalWorkingYears

Category of TrainingTimesLastYear  
 Mean : 2.7993197278911564  
 Median : 3.0  
 Standard Deviation : 1.2892706207958455  
 Minimum value : 0.0  
 Maximum value : 6.0





Εικόνα 125 - Part2 Numerical Values TrainingTimesLastYear



Category of YearsWithCurrManager  
 Mean : 4.12312925170068  
 Median : 3.0  
 Standard Deviation : 3.5681361205404376  
 Minimum value : 0.0  
 Maximum value : 17.0





Εικόνα 126 - Part2 Numerical Values YearsWithCurrManager





Εικόνα 127 - Bivariate analysis - Department





Εικόνα 128 - Bivariate analysis - EducationField




Εικόνα 129 - Bivariate analysis - Gender




Εικόνα 130 - Bivariate analysis - BusinessTravel



Εικόνα 131 - Bivariate analysis - JobRole



Εικόνα 132 - Bivariate analysis - MaritalStatus



Εικόνα 133 - Bivariate analysis - MonthlyIncome